



Universitat
de les Illes Balears

TREBALL DE FI DE GRAU

ESTUDI DE MÈTODES DE SEGMENTACIÓ AUTOMÀTICA DE VASOS SANGUINIS DE LA RETINA I LA SEVA AGREGACIÓ

Sinty Garau Chen

Grau de Matemàtiques

Escola Politècnica Superior

Any acadèmic 2025-26

ESTUDI DE MÈTODES DE SEGMENTACIÓ AUTOMÀTICA DE VASOS SANGUINIS DE LA RETINA I LA SEVA AGREGACIÓ

Sinty Garau Chen

Treball de Fi de Grau

Escola Politècnica Superior

Universitat de les Illes Balears

Any acadèmic 2025-26

Paraules clau del treball: angiografies, vasos retinals, segmentació, agregació

Tutor: Manuel González Hidalgo, Marc Munar Covas

SUMARI

Sumari	i
Índex de figures	iii
Índex de taules	v
Acrònims	vii
Resum	ix
1 Introducció	1
1.1 Contextualització	1
1.2 Objectius i estructura del treball	2
2 Fonaments i conceptes teòrics	3
2.1 Imatge digital	3
2.2 Segmentació	5
2.3 Agregació	9
2.4 Mètriques d'avaluació	26
2.4.1 IoU	27
2.4.2 FPR	27
2.4.3 PPV	27
2.4.4 ACC	27
2.4.5 TPR	28
2.4.6 ROC	28
2.5 Contrastos d'hipòtesi	28
2.6 Comentaris finals	30
3 Procés de segmentació i agregació	31
3.1 Base de dades	31
3.2 Especificacions tècniques	33
3.3 Mètodes de segmentació	33
3.3.1 Mètode de segmentació de Chaudhuri et al. (Segm1989Chaudhuri)	33
3.3.2 Mètode de segmentació de Zana i Klein (Segm2001ZanaKlein) .	34
3.3.3 Mètode de segmentació de Heneghan et al. (Segm2002Heneghan)	34
3.3.4 Mètode de Chanwimaluang (Segm2003Chanwimaluang)	35
3.3.5 Mètode de segmentació de Zapater et al. (Segm2005Zapater) . .	36
3.3.6 Mètode GMM de Soares et al. (Segm2008SoaresGMM)	36

3.3.7	Mètode KNN de Soares et al. (Segm2008SoaresKNN)	38
3.3.8	Mètode LMSE de Soares et al. (Segm2008SoaresLMSE)	38
3.3.9	Mètode de segmentació de Bankhead et al. (Segm2012Bankhead)	38
3.3.10	Mètode d'Azzopardi et al. (Segm2015Azzopardi)	39
3.3.11	Mètode de segmentació de Bibiloni et al. (Segm2019Bibiloni)	40
3.4	Mètodes de segmentació binària	40
3.4.1	Otsu	41
3.4.2	Otsu adaptatiu	43
3.4.3	Medina-Carnicer	44
3.5	Funcions d'agregació	45
3.6	Descripció del procés	46
4	Experimentació	49
4.1	Obtenció de paràmetres	49
4.2	Comparativa de processos de segmentació	52
4.3	Discussió de resultats	56
5	Conclusions i treball futur	59
5.1	Conclusions	59
5.2	Treball futur	60
A	Demostracions i resultats	61
	Bibliografia	81

ÍNDIX DE FIGURES

2.1	Desglossament gràfic de les característiques clau de la corba f , en verd, i la recta g , en vermell. Per entendre'n millor el comportament, es recomana consultar l'enllaç de GeoGebra: https://www.geogebra.org/m/q2b5abwx . .	21
2.2	Desglossament gràfic del comportament de la hipèrbola w_n , en blau. Per entendre'n millor el comportament, es pot consultar el gràfic a l'enllaç de GeoGebra: https://www.geogebra.org/m/arefzevn	22
3.1	Mostra d'angiografies oculars originals de la base de dades junt amb la seva segmentació binària de veritat fonamental: (a) imatge de <i>Digital Retinal Images for Vessel Extraction</i> (DRIVE) sense patologies, (b) imatge de DRIVE amb patologies, (c) imatge de <i>Structured Analysis of the Retina</i> (STARE) sense patologies, (d) imatge de STARE amb patologies.	32
3.2	Primera columna d'angiografies oculars originals, segona columna de segmentacions en escala de grisos, tercera columna de segmentacions binàries, per als mètodes de segmentació següents: (a) Segm1989Chaudhuri , (b) Segm2001ZanaKlein , (c) Segm2002Heneghan , (d) Segm2003Chanwimaluang , (e) Segm2005Zapater , (f) Segm2008SoaresGMM , (g) Segm2008SoaresKNN , (h) Segm2008SoaresLMSE , (i) Segm- -2012Bankhead , (j) Segm2015Azzopardi , (k) Segm2019Bibiloni	42
3.3	Esquema del procés d'experimentació seguit per tal d'assolir els objectius del treball.	48
3.4	Processos de segmentació inclosos a cada ordenació.	48
4.1	Corba <i>Receiver Operating Characteristic curve</i> (ROC) de línia contínua blava dels candidats a lllindar th pel mètode Segm2001ZanaKlein amb $k = 9$ fixat, punt blau on es minimitza $\mu_m(FPR/TPR)$, recta de pendent 1 en línia discontinua blava, i segment diagonal de referència en línia de punts negres.	50
4.2	D'esquerra a dreta: imatge de veritat fonamental i processos GZK , FAE2 i RBGMV . Amb les binaritzacions (a) Medina-Carnicer, (b) Otsu, (c) Otsu adaptatiu.	58
4.3	D'esquerra a dreta: angiografia original, segmentació de veritat fonamental, resultat del millor procés de segmentació sense agregació, ot-MGGM , i resultat del millor procés de segmentació, que és amb agregació, ot-RSAmE	58
A.1	Desglossament gràfic de les característiques clau de la corba f , en verd, i la recta g , en vermell. Per entendre'n millor el comportament, es recomana consultar l'enllaç de GeoGebra: https://www.geogebra.org/m/q2b5abwx . .	71

A.2	Desglossament gràfic del comportament de la hipèrbola w_n , en blau. Per entendre'n millor el comportament, es pot consultar el gràfic a l'enllaç de GeoGebra: https://www.geogebra.org/m/arefzevn	72
-----	--	----

ÍNDIX DE TAULES

3.1	Taula d'abreviacions pels noms dels mètodes de segmentació i funcions d'agregació sota estudi.	47
3.2	Taula d'abreviacions per les aplicacions a realitzar.	47
4.1	Taula reduïda de llindars òptims obtinguts amb el mètode de la corba ROC, on s'indica a cada fila el mètode de segmentació que aplica el llindar amb valor indicat, i el quocient $\mu_m(FPR/TPR)$ pel qual ha resultat ser l'òptim. .	51
4.2	Taula d'una mostra dels candidats a M del mètode Segm2002Heneghan , i el respectiu valor $\mu_m(IoU)$. Se'n destaca en negreta el valor òptim.	51
4.3	Taula reduïda de paràmetres òptims obtinguts, on s'indica a cada fila el procés de segmentació que inclou el paràmetre amb el valor trobat, i el coeficient $\mu_m(IoU)$ pel qual ha resultat ser l'òptim.	51
4.4	Resultats calculats sobre la mesura d'avaluació <i>Intersection over Union</i> (IoU) dels mètodes de segmentació principals: mitjana, desviació típica, p -valors de normalitat individual, resultat de normalitat individual i resultat de normalitat ajustada, on si el valor de les columnes de normalitat és 0, s'accepta H_0 , si és 1 es rebutja H_1	54
4.5	Resultats calculats sobre la mesura d'avaluació IoU dels mètodes de segmentació principals: contrast d'igualtat i desigualtat de mitjanes per parelles, on = indica que el mètode de la fila és estadísticament equivalent al de la columna, < indica que el mètode de la fila és estadísticament inferior al de la columna, i > indica que el mètode de la fila és estadísticament superior al de la columna. La resta de casos no aplica.	55
4.6	Resultats calculats sobre la mesura d'avaluació IoU dels mètodes de segmentació principals: a quants altres mètodes supera, quants altres mètodes el superen, i quina posició de l'ordenació ocupen.	55
4.7	Ordenacions finals de les diferents agrupacions de mètodes de segmentació, en ordre. De cada agrupació s'especifiquen el nom de cada mètode i a quants altres mètodes del grup superen estadísticament. S'indiquen només en negreta els mètodes que han superat a més que 4 altres mètodes.	56
4.8	Ordenacions finals de les diferents agrupacions de processos de segmentació amb agregació de tots els mètodes, en ordre. De cada agrupació s'especifiquen el nom de cada mètode i a quants altres mètodes del grup superen estadísticament.	56

4.9	Ordenacions finals de les diferents agrupacions de processos de segmentació amb agregació d'un nombre reduït de mètodes, en ordre. De cada agrupació s'especifiquen el nom de cada mètode i a quants altres mètodes del grup superen estadísticament.	56
4.10	Ordenacions finals dels millors processos de segmentació sense i amb agregació. De cada agrupació de processos s'especifiquen l'ordre, el nom de cada procés i a quants altres processos del grup superen estadísticament. .	57
4.11	Ordenació final entre el millor procés de segmentació sense agregació i el millor procés de segmentació amb agregació. S'especifiquen l'ordre, el nom de cada procés i a quants altres processos superen estadísticament.	57
A.1	Taula completa de llindars òptims obtinguts amb el mètode de la corba ROC, on s'indica a cada fila el mètode de segmentació que aplica el llindar amb valor indicat, i el quocient $\mu_m(FPR/TPR)$ per al qual ha resultat ser l'òptim.	79
A.2	Taula completa de paràmetres òptims obtinguts, on s'indica a cada fila el procés de segmentació que inclou el paràmetre amb el valor trobat, i el coeficient $\mu_m(IoU)$ pel qual ha resultat ser l'òptim.	79
A.3	Resultats calculats sobre la mesura d'avaluació IoU dels mètodes de segmentació principals: contrast d'igualtat de mitjanes per parelles, on = indica que el mètode de la fila és estadísticament equivalent al de la columna i $\neq$ indica que són estadísticament diferents. La resta de casos no aplica.	80
A.4	Resultats calculats sobre la mesura d'avaluació IoU dels mètodes de segmentació principals: contrast d'igualtat i desigualtat de variàncies per parelles, on = indica que el mètode de la fila és estadísticament equivalent al de la columna, < indica que la variància del mètode de la fila és estadísticament inferior al de la columna, i > indica que la variància del mètode de la fila és estadísticament superior al de la columna. La resta de casos no aplica.	80

ACRÒNIMS

ACC *Accuracy*

BUM *Basic Unit-interval Monotone*

COSFIRE *COmbined Selection of Filter REsponses*

DoG *Difference of Gaussians*

DRIVE *Digital Retinal Images for Vessel Extraction*

FN *False Negatives*

FP *False Positives*

FPR *False Positive Ratio*

GMM *Gaussian Mixture Model*

IoU *Intersection over Union*

OWA *Ordered Weighted Averaging*

MEOWA *Maximum Entropy OWA*

KNN *k-Nearest Neighbors*

LMSE *Linear Minimum Squared Error*

MVOWA *Minimum Variance OWA*

PPV *Positive Predictive Value*

RDM *Regular Decreasing Monotone*

RGB *Red Green Blue*

RIM *Regular Increasing Monotone*

ROC *Receiver Operating Characteristic curve*

RUM *Regular UniModal*

STARE *Structured Analysis of the Retina*

TFG *Treball Final de Grau*

TN *True Negatives*

TP *True Positives*

TPR *True Positive Rate*

RESUM

Aquest Treball Final de Grau s'emmarca en el camp del processament d'imatges mèdiques i s'enfoca en la segmentació automàtica de vasos sanguinis en angiografies de la retina, una etapa fonamental en el procés de diagnòstic d'anomalies i patologies oculars. L'objectiu principal és avaluar l'eficiència de diversos mètodes de segmentació existents comparant els resultats amb el criteri d'experts oftalmòlegs, així com determinar si la combinació d'aquests mètodes mitjançant funcions d'agregació permet millorar els resultats individuals.

Per a la fase experimental, es disposa d'un conjunt d'angiografies retinals a color procedents de bases de dades públiques: 40 imatges de DRIVE i 20 de STARE. S'analitzen 11 mètodes de segmentació, extraient de cada un la segmentació en escala de grisos i la segmentació binària (vasos blancs sobre fons negre). A més, per tal d'avaluar els mètodes de forma independent a la seva binarització d'origen, es binaritza cada segmentació en escala de grisos amb tres mètodes diferents: Otsu, Otsu adaptatiu i Medina-Carnicer. A continuació, s'apliquen funcions d'agregació sobre la totalitat de les segmentacions en escala de grisos i sobre subconjunts seleccionats mitjançant contrastos d'hipòtesis dos a dos per descartar els mètodes de menor rendiment en mètriques d'avaluació seleccionades. Finalment, es tornen a aplicar les tres binaritzacions per acabar de comparar tots els processos considerats i determinar quina configuració ofereix la millor aproximació a les segmentacions de referència.

L'anàlisi estadística realitzada permet concloure que el procés de segmentació òptim inclou una combinació de mètodes de segmentació, confirmant que l'ús de funcions d'agregació supera el rendiment de qualsevol mètode individual considerat. Així mateix, l'estudi posa en relleu la sensibilitat dels resultats respecte a la tria de paràmetres i procediments, obrint la porta a futures ampliacions del conjunt de dades i de les tècniques avaluades.

INTRODUCCIÓ

1.1 Contextualització

Moltes patologies de la vista requereixen proves concretes per confirmar el diagnòstic. Una de les tècniques emprades són les angiografies oculars, fotografies del fons retinal que capturen l'estat dels vasos sanguinis de dins i darrera de la retina, i permeten detectar anomalies o variacions de l'estat òptim del fons ocular. El procediment per realitzar l'angiografia és el següent: es dilata la pupila amb unes gotes que s'apliquen directament a l'ull, s'injecta via intravenosa un colorant que arribarà als vasos oculars, i amb una càmera especial es captura la imatge amb els vasos destacats. Els oftalmòlegs especialitzats poden analitzar les angiografies i a partir de l'estat en què es troben –variacions respecte a angiografies anteriors com encolliment o tortuositat dels vasos, decoloració del nervi òptic, taques i zones amb certs patrons– poden determinar la salut visual del pacient i com procedir en cas de ser necessari amb algun tractament o operació.

L'objectiu dels avenços tecnològics és agilitzar o fins i tot substituir aquesta càrrega de treball. Així s'han anat creant durant anys un seguit d'algorismes que podrien assumir passos del procés de diagnòstic: detecció de vasos sanguinis [1, 2], segmentació de vasos sanguinis [3, 4], segmentació del disc òptic [5, 6], entre d'altres. És natural entendre que els resultats retornats no són completament exactes i certs, igual que no sempre tenen per què ser-ho les conclusions dels professionals, però sí que els d'aquests últims es poden considerar com a tals i l'objectiu sempre és que la màquina pugui donar els mateixos o fins i tot millors diagnòstics.

Partint d'aquest motiu, el treball pretén analitzar l'eficiència d'un seguit d'algorismes de segmentació de vasos oculars comparant els resultats amb els d'experts, i estudiar si una combinació d'aquests resultats pot millorar les solucions individuals.

1.2 Objectius i estructura del treball

Donat un conjunt d'angiografies sota estudi, es consideren 11 mètodes de segmentació, 3 algorismes de segmentació binària, i 8 funcions d'agregació. Els mètodes de segmentació parteixen de l'angiografia inicial i permeten obtenir una còpia en blanc i negre, on en blanc es marquen els vasos oculars i en negre la resta. Abans de passar al blanc i negre, hi ha un punt intermedi en aquests mètodes on la imatge està en tons de grisos. A aquestes imatges se les denomina segmentació en escala de grisos, i es processen de dues formes: amb un mètode de binarització que converteix aquestes imatges en grisos a blanc i negre; o bé es combinen amb altres segmentacions en escala de grisos segons la funció d'agregació aplicada, per obtenir el resultat final en blanc i negre aplicant igualment un mètode de binarització.

Les dues formes de processament difereixen en l'aplicació o no d'aquestes funcions d'agregació, que l'únic que fan és emprar informació de més d'un mètode de segmentació. Inicialment, fer una combinació de resultats podria donar lloc a un resultat encara millor, ja que podria tenir en compte els punts forts de cada mètode i descartar-ne els punts debils. Per això, aquest Treball Final de Grau (TFG) pretén reafirmar o desmentir aquesta idea amb evidències sòlides, definint com a objectius dos punts clau: obtenir quin és el procés de segmentació d'entre tots els considerats que retorna un resultat més pròxim al d'un especialista, i concloure si aplicar una agregació de segmentacions és millor que no fer cap combinació intermèdia.

Per arribar a les respostes pertinents, el treball s'estructura en: una introducció en aquest capítol 1; les bases teòriques per entendre tots els mètodes, funcions, mètriques i contrastos aplicats es poden trobar al capítol 2; els detalls del problema en qüestió amb quins mètodes i funcions concrets es fan servir al capítol 3; els resultats experimentals obtinguts es presenten al capítol 4; i les conclusions finals al darrer capítol, el 5. A més, el recull de totes les imatges, el codi i els resultats associats a aquest TFG es troba disponible en un repositori de GitHub¹.

¹ Es pot accedir al repositori de GitHub mitjançant l'enllaç <https://github.com/sintygc/mathematics-TFG-retinal-vessel-segmentation-aggregation>.

FONAMENTS I CONCEPTES TEÒRICS

En aquest capítol s'introdueixen els conceptes teòrics necessaris per entendre el procés que s'ha portat a terme en la realització d'aquest TFG. Així, es cobreixen els fonaments bàsics de la forma més autocontinguda possible, en l'ordre en què s'han necessitat per executar el treball: a una mostra d'imatges digitals se li han aplicat diverses combinacions de mètodes de segmentació en escala de grisos i mètodes de segmentació binària amb funcions d'agregació. A més, s'ha fet ús de mètriques d'avaluació que han permès determinar els valors de paràmetres intrínsecs a aquests processos, i els contrastos d'hipòtesi realitzats han conduït i sostingut les decisions que s'han pres a cada moment.

2.1 Imatge digital

Aquest treball es basa en l'estudi d'imatges amb unes característiques concretes, però abans d'explicar quines cal entendre en detall què són les imatges digitals i com es podrà fer feina amb elles. Aquesta és la motivació de la secció, que explica tots els fonaments basats en el contingut de [7].

Definició 2.1.1 (Imatge). Una imatge f es pot entendre com una funció de dues dimensions, $f : \mathbb{R} \times \mathbb{R} \rightarrow \mathbb{R}^n$, on $x, y \in \mathbb{R}$ són les coordenades espacials i $f(x, y) \in \mathbb{R}^n$ és la intensitat de la imatge en aquest punt.

Definició 2.1.2 (Imatge digital). Una imatge f és digital quan tots els valors x, y i $f(x, y)$ són finits i discrets. És a dir, definim ara tota imatge digital com una funció

$$i : D \subset \mathbb{R} \times \mathbb{R} \rightarrow U \subset \mathbb{R}^n,$$

on D és el conjunt de totes les coordenades i U el conjunt de les intensitats que pot prendre cada posició. D'aquesta manera, tota imatge digital està composta per un nombre finit d'elements anomenats píxels, cadascun determinat per la seva localització i la seva intensitat particulars.

El procés de convertir una imatge a imatge digital s'anomena digitalització, on digitalitzar les coordenades s'anomena mostreig, o *sampling* en anglès, i digitalitzar la intensitat s'anomena quantificació. El resultat de la digitalització és una matriu d' M files i N columnes de la qual s'indiquen les coordenades (x, y) amb (r, c) , on la posició $(r, c) = (1, 1)$ indica el píxel de la primera fila i primera columna de la matriu. Així, el conjunt de coordenades de la imatge passa a ser

$$D = \{(r, c) \in \mathbb{Z}^+ \times \mathbb{Z}^+ : 1 \leq r \leq M, 1 \leq c \leq N\} = M \times N \subset \mathbb{Z}^+ \times \mathbb{Z}^+,$$

i la imatge es pot definir com la matriu

$$I = \begin{bmatrix} i_{11} & i_{12} & \dots & i_{1c} & \dots & i_{1N} \\ i_{21} & i_{22} & \dots & i_{2c} & \dots & i_{2N} \\ \vdots & \vdots & \ddots & \vdots & \ddots & \vdots \\ i_{r1} & i_{r2} & \dots & i_{rc} & \dots & i_{rN} \\ \vdots & \vdots & \ddots & \vdots & \ddots & \vdots \\ i_{M1} & i_{M2} & \dots & i_{Mc} & \dots & i_{MN} \end{bmatrix} \in \mathcal{M}_{M \times N}(U),$$

on cada i_{rc} és un píxel amb posició (r, c) i intensitat $i(r, c)$.

A partir d'ara, sempre que es mencioni el terme imatge s'estarà fent referència a una imatge digital representada per una matriu $I \in \mathcal{M}_{M \times N}(U)$, on cada píxel i_{rc} estarà localitzat a la fila $r \in \{1, \dots, M\}$ i columna $c \in \{1, \dots, N\}$ i tindrà intensitat $i(r, c) \in U$.

Definició 2.1.3 (Imatge monocromàtica). Una imatge $I \in \mathcal{M}_{M \times N}(U)$ és monocromàtica quan $U \subset \mathbb{R}$, amb intensitats a cada píxel $i(r, c) \in U$ per $r \in \{1, \dots, M\}$ i $c \in \{1, \dots, N\}$. També se'n denomina imatge en escala de grisos, ja que la intensitat resulta ser un nivell de gris que va del color negre al color blanc.

Definició 2.1.4 (Imatge RGB). Una imatge RGB és una imatge $I \in \mathcal{M}_{M \times N}(U)$ on $U \subset \mathbb{R}^3$, i cada píxel i_{rc} té intensitat $i(r, c) = (i_1(r, c), i_2(r, c), i_3(r, c)) \in U$ per $r \in \{1, \dots, M\}$ i $c \in \{1, \dots, N\}$. Aquesta imatge segueix el sistema RGB, del *Red Green Blue* (RGB) en anglès, pel que també es pot interpretar com una matriu tridimensional $\tilde{I} \in \mathcal{M}_{M \times N \times 3}(\tilde{U})$ amb $\tilde{U} \subset \mathbb{R}$, on cada matriu bidimensional és una imatge monocromàtica anomenada component o imatge primària que representa un dels canals de color vermell, verd o blau. Tenint en compte ambdues notacions, es defineixen les tres imatges primàries com:

- $IR = \tilde{I}_{D \times 1}$ la matriu del camp vermell o *red* en anglès, on cada píxel $iR_{rc} = \tilde{i}_{rc1}$ té intensitat $i_1(r, c)$,
- $IG = \tilde{I}_{D \times 2}$ la matriu del camp verd o *green* amb intensitats $i_2(D)$,
- $IB = \tilde{I}_{D \times 3}$ la matriu del camp blau o *blue* amb intensitats $i_3(D)$,

on $D = \{1, \dots, M\} \times \{1, \dots, N\}$, el conjunt de totes les files i totes les columnes.

De fet, aquestes tres imatges primàries són per si soles imatges en escala de grisos. Els dispositius de visualització associen un llum de color específic –vermell, verd o blau– a cada component IR , IG o IB , i és aquesta combinació de llums dels tres canals de colors de les pantalles digitals el que permet reproduir les imatges a color.

Definició 2.1.5 (Imatge binària). Una imatge $I \in \mathcal{M}_{M \times N}(U)$ és binària quan únicament té dos colors, determinats per dues intensitats que se solen considerar mínima i màxima, és a dir, $U = \{u_1, u_2\}$.

En aquest treball les imatges binàries són exclusivament en blanc i negre, on el negre sol estar determinat amb $u_1 = 0$ i el blanc u_1 sol ser un altre valor fix que depèn de la classe de dades que es faci servir per determinar les intensitats dels píxels.

2.2 Segmentació

La secció que segueix cobreix la teoria bàsica que permetrà entendre els mètodes de segmentació que s'empren en aquest treball i s'expliquen a les seccions 3.3 i 3.4. El contingut es pot ampliar amb les referències als articles del capítol següent i amb el llibre [7].

Definició 2.2.1 (Problema de segmentació). Sigui una imatge qualsevol $I \in \mathcal{M}_{M \times N}(U)$ amb $U \subset \mathbb{R}^3$, el problema de segmentació és el problema de particionar la regió global R que representa la imatge al complet I en n subregions $R_1, \dots, R_n$, que satisfan les següents propietats:

- $\bigcup_{i=1}^n R_i = R$,
- R_i és una regió connexa, $i = 1, \dots, n$,
- $R_i \cap R_j = \emptyset \ \forall i, j = 1, \dots, n, i \neq j$,
- $P(R_i) = 1 \ \forall i = 1, \dots, n$,
- $P(R_i \cup R_j) = 0$, per a totes regions adjacents R_i i R_j .

Cada subregió R_i identifica una entitat coherent que variarà en funció de la tasca. No hi ha cap definició exacta d'entitat coherent, però sol correspondre a un objecte anomenable o descriptible, com podria ser un material concret o una peça geomètrica físicament distingible.

Definició 2.2.2 (Segmentació). Donada una imatge qualsevol $I \in \mathcal{M}_{M \times N}(U)$ amb $U \subset \mathbb{R}^3$, la segmentació I_S és la solució al problema de segmentació, on cada subregió R_j ve determinada per un valor d'intensitat concret $u_j \in U_S = \{u_1, \dots, u_n\} \subset U$, $j = 1, \dots, n$. Cal destacar que dues regions no adjacents R_i, R_j poden tenir el mateix valor d'intensitat u_j , per tant $|U_S| \leq n$.

Definició 2.2.3 (Mètode de segmentació). Donats els conjunts d'intensitats $U \subset \mathbb{R}^3$ i $U_S \subset U$, i una imatge qualsevol $I \in \mathcal{M}_{M \times N}(U)$, la funció

$$\text{Segm} : I \in \mathcal{M}_{M \times N}(U) \rightarrow I_S \in \mathcal{M}_{M \times N}(U_S),$$

anomenada mètode de segmentació, és un seguit de transformacions sobre I que permet obtenir la segmentació I_S .

Definició 2.2.4 (Segmentació en escala de grisos). Donada una imatge qualsevol $I \in \mathcal{M}_{M \times N}(U)$ amb $U \subset \mathbb{R}^3$, la segmentació en escala de grisos I_G és la solució al problema de segmentació, on cada subregió R_j ve determinada per un valor d'intensitat concret $u_j \in U_G = \{u_1, \dots, u_n\} \subset \mathbb{R} \subset U$, $j = 1, \dots, n$. Cal destacar que dues regions no adjacents R_i, R_j poden tenir el mateix valor d'intensitat u_j , per tant $|U_G| \leq n$, i I_G resulta ser una imatge en escala de grisos.

Definició 2.2.5 (Mètode de segmentació en escala de grisos). Donats els conjunts d'intensitats $U \subset \mathbb{R}^3$ i $U_G \subset \mathbb{R} \subset U$, i una imatge qualsevol $I \in \mathcal{M}_{M \times N}(U)$, la funció

$$\text{SegmG}: I \in \mathcal{M}_{M \times N}(U) \rightarrow I_G \in \mathcal{M}_{M \times N}(U_G),$$

anomenada mètode de segmentació en escala de grisos, és un seguit de transformacions sobre I que permet obtenir la segmentació en escala de grisos I_G .

Definició 2.2.6 (Segmentació binària). Donada una imatge qualsevol $I \in \mathcal{M}_{M \times N}(U)$ amb $U \subset \mathbb{R}^3$, la segmentació binària I_{BW} és la solució al problema de segmentació, on cada subregió R_j ve determinada per un valor d'intensitat concret $u_j \in U_{BW} \subset \mathbb{R} \subset U$, $j = 1, \dots, n$. En aquest cas només hi ha dos valors d'intensitat possibles, $U_{BW} = \{u_1, u_2\}$, i I_{BW} resulta ser una imatge binària.

Definició 2.2.7 (Mètode de segmentació binària). Considerats els conjunts d'intensitats $U \subset \mathbb{R}^3$, $U_G \subset \mathbb{R} \subset U$ i $U_{BW} = \{u_1, u_2\} \subset U_G$, i una imatge qualsevol $I \in \mathcal{M}_{M \times N}(U)$, la funció

$$\text{SegmBW}: I \in \mathcal{M}_{M \times N}(U) \rightarrow I_{BW} \in \mathcal{M}_{M \times N}(U_{BW}),$$

anomenada mètode de segmentació binària, o simplement mètode de binarització, és un seguit de transformacions sobre I que permet obtenir la segmentació binària I_{BW} .

La majoria, o gairebé tots els mètodes de segmentació que es treballaran, inclouran una primera transformació de la imatge RGB I a una imatge en escala de grisos inicial I_0 , obtinguda amb una de les dues operacions següents.

Definició 2.2.8 (Canal verd). Donada una imatge RGB $I \in \mathcal{M}_{M \times N}(U)$ amb $U \subset \mathbb{R}^3$, la funció canal verd G permet obtenir la imatge en escala de grisos corresponent a la component del camp verd de I . És a dir,

$$G(I) = IG.$$

Definició 2.2.9 (RGB a escala de grisos). Donada una imatge RGB $I \in \mathcal{M}_{M \times N}(U)$ amb $U \subset \mathbb{R}^3$, la funció RGB a escala de grisos CG permet obtenir la imatge en escala de grisos corresponent a una combinació de les components dels camps vermell, verd i blau de I . És a dir,

$$CG(I) = 0.2989 * IR + 0.5870 * IG + 0.1140 * IB.$$

Obtinguda la imatge en escala de grisos, alguns mètodes requeriran calcular la inversa de la imatge, una mena de negatiu fotogràfic on les intensitats clares es tornen fosques i les fosques passen a ser clares.

Definició 2.2.10 (Inversa). Donada una imatge qualsevol $I \in \mathcal{M}_{M \times N}(U)$ amb $U \subset \mathbb{R}$, la funció inversa inv permet obtenir la imatge inversa I_{inv} d'intensitats donades per

$$i_{inv}(r, c) = inv(i(r, c)) = \max(U) - i(r, c).$$

Una de les operacions que poden incloure $SegmG(I)$ i $SegmBW(I)$ és la convolució, que s'obté aplicant un filtre a la imatge I .

Definició 2.2.11 (Filtre). Un filtre és una matriu qualsevol $F \in \mathcal{M}_{P \times Q}(\mathbb{R})$. Cada filtre afecta d'una forma diferent en funció de la seva mida i els seus valors, a més de la funció amb la que s'aplica a I . Exemples de filtres són:

- Filtre mitjà, amb mida i valors constants a partir de $Q \in \mathbb{R}$, definit com

$$F = H_M(Q) = \frac{1}{Q \cdot Q} \mathcal{M}_{Q \times Q}(1).$$

- Filtre gaussià, que suavitza la imatge, definit com $F = H_G(P, Q, \sigma)$ on la intensitat de cada píxel ve donada per

$$h_G(p, q) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{x^2 + y^2}{2\sigma^2}\right),$$

on (x, y) és la posició de (p, q) respecte al centre.

- Filtre laplacià de Gauss, que detecta canvis d'intensitat i pot retornar valors negatius, ve definit com $F = H_L(P, Q, \sigma)$ on la intensitat de cada píxel ve donada per

$$h_L(p, q) = \frac{1}{\pi\sigma^4} \left(\frac{x^2 + y^2}{2\sigma^2} - 1\right) \exp\left(-\frac{x^2 + y^2}{2\sigma^2}\right),$$

on (x, y) és la posició de (r, c) respecte al centre.

- Filtre diferència de gaussians, o *Difference of Gaussians* (DoG) en anglès, dissenyat per detectar vores i definit com $F = H_D(\sigma_1, \sigma_2)$, on la intensitat de cada píxel és

$$h_D(r, c) = \frac{1}{2\pi\sigma_1^2} \exp\left(-\frac{r^2 + c^2}{2\sigma_1^2}\right) - \frac{1}{2\pi\sigma_2^2} \exp\left(-\frac{r^2 + c^2}{2\sigma_2^2}\right).$$

Definició 2.2.12 (Convolució). Siguin un filtre $F \in \mathcal{M}_{P \times Q}(\mathbb{R})$ i una imatge $I \in \mathcal{M}_{M \times N}(U)$ amb $U \subset \mathbb{R}$ qualssevol, on les intensitats de F venen definides per f i les de I per i , es defineix la convolució de F i I com l'operació $F * I$ donada per

$$(F * I)(r, c) = \sum_{s=1}^P \sum_{t=1}^Q f(s, t) \cdot i(r - s + 1, c - t + 1),$$

on $r \in \{1, \dots, M\}$ i $c \in \{1, \dots, N\}$ sempre i quan els índexs donin intensitats vàlides, sinó s'omet aquella component del sumatori.

També s'hi aplicaran les operacions de morfologia matemàtica següents, que es realitzen amb el suport d'elements estructurants.

Definició 2.2.13 (Element estructurant). Es defineix com element estructurant a tota matriu $L \in \mathcal{M}_{S \times T}(\mathbb{R})$ que actua com a plantilla o màscara per les operacions de morfologia matemàtica. Se'ls sol dotar d'una forma concreta per ajudar a detectar estructures coincidents, com ara línies, cercles o quadrats.

Si en alguna operació es necessita un element estructurant però no se'n defineix cap, es determina per defecte la matriu $L \in \mathcal{M}_{3 \times 3}(0)$.

Definició 2.2.14 (Dilatació). Donat un element estructurant $L \in \mathcal{M}_{S \times T}(\mathbb{R})$ i una imatge $I \in \mathcal{M}_{M \times N}(U)$ amb $U \subset \mathbb{R}$ qualssevol, es defineix la dilatació de I per L com la funció $\delta_L(I)$ donada per

$$\delta_L(i(r, c)) = \max_{(s, t) \in S \times T} \{i(r_s, c_t) + l(s, t)\},$$

on (r_s, c_t) és la coordenada de I corresponent a la posició (s, t) de l'element estructurant, havent disposat L fent coincidir-ne el seu centre sobre la coordenada (r, c) de la imatge.

Definició 2.2.15 (Erosió). Donat un element estructurant $L \in \mathcal{M}_{S \times T}(\mathbb{R})$ i una imatge $I \in \mathcal{M}_{M \times N}(U)$ amb $U \subset \mathbb{R}$ qualssevol, es defineix l'erosió de I per L com la funció $\epsilon_L(I)$ donada per

$$\epsilon_L(i(r, c)) = \min_{(s, t) \in S \times T} \{i(r_s, c_t) - l(s, t)\},$$

on (r_s, c_t) és la coordenada de I corresponent a la posició (s, t) de l'element estructurant, havent disposat L fent coincidir-ne el seu centre sobre la coordenada (r, c) de la imatge.

Definició 2.2.16 (Obertura). Donat un element estructurant $L \in \mathcal{M}_{S \times T}(\mathbb{R})$ i una imatge $I \in \mathcal{M}_{M \times N}(U)$ amb $U \subset \mathbb{R}$ qualssevol, es defineix l'obertura de I per L com

$$\gamma_L(I) = \delta_{L^t}(\epsilon_L(I)),$$

on L^t és L transposat.

Definició 2.2.17 (Tancament). Donat un element estructurant $L \in \mathcal{M}_{S \times T}(\mathbb{R})$ i una imatge $I \in \mathcal{M}_{M \times N}(U)$ amb $U \subset \mathbb{R}$ qualssevol, es defineix el tancament de I per L com

$$\phi_L(I) = \epsilon_{L^t}(\delta_L(I)),$$

on L^t és L transposat.

Definició 2.2.18 (Dilatació geodèsica). Donades dues imatges $I, J \in \mathcal{M}_{M \times N}(U)$ amb $U \subset \mathbb{R}$ qualssevol, on $i(r, c) \leq j(r, c)$ per a cada $(r, c) \in M \times N$, es defineix la dilatació geodèsica de mida 1 de I per J com

$$\delta_J^{(1)}(I) = \max\{\delta(I), J\}.$$

L'erosió geodèsica de mida n es defineix recursivament com

$$\delta_J^{(n)}(I) = \delta_J^{(1)}(\delta_J^{(n-1)}(I)).$$

Definició 2.2.19 (Erosió geodèsica). Donades dues imatges $I, J \in \mathcal{M}_{M \times N}(U)$ amb $U \subset \mathbb{R}$ qualssevol, on $i(r, c) \leq j(r, c)$ per a cada $(r, c) \in M \times N$, es defineix l'erosió geodèsica de mida 1 de I per J com

$$\epsilon_J^{(1)}(I) = \min\{\epsilon(I), J\}.$$

L'erosió geodèsica de mida n es defineix recursivament com

$$\epsilon_J^{(n)}(I) = \epsilon_J^{(1)}(\epsilon_J^{(n-1)}(I)).$$

Definició 2.2.20 (Obertura geodèsica). Donades dues imatges $I, J \in \mathcal{M}_{M \times N}(U)$ amb $U \subset \mathbb{R}$ qualssevol, es defineix l'obertura geodèsica de I per J com

$$\gamma_J^{rec}(I) = \lim_{n \rightarrow +\infty} \delta_J^{(n)}(I).$$

Definició 2.2.21 (Tancament geodèsic). Donades dues imatges $I, J \in \mathcal{M}_{M \times N}(U)$ amb $U \subset \mathbb{R}$ qualssevol, es defineix el tancament geodèsic de I per J i L com

$$\phi_J^{rec}(I) = \lim_{n \rightarrow +\infty} \epsilon_J^{(n)}(I).$$

2.3 Agregació

A la secció anterior s'han introduït els fonaments necessaris per entendre els mètodes de segmentació explicats a les seccions 3.3 i 3.4, els quals retornaran cadascun un resultat particular. Es podrà donar el cas que una estructura obtinguda amb un mètode no s'hagi detectat amb un altre mètode, i que a la vegada aquest segon mètode tingui una estructura no detectada amb el primer. Per evitar aquesta pèrdua de dades i intentar obtenir solucions més properes a la partició real, s'inclou la possibilitat de combinar els resultats obtinguts entre diversos mètodes mitjançant les funcions d'agregació.

Basats en el contingut de [8], en aquesta secció s'expliquen els fonaments teòrics per poder aplicar a les imatges en escala de grisos I_G , extrems del procés de segmentació en escala de grisos descrit a la secció 3.3, les funcions d'agregació detallades a la secció 3.5, les quals permetran barrejar de diferents formes aquests resultats. Es destaca que aquestes operacions es faran píxel a píxel, per la qual cosa es restringeixen tots els conceptes de la secció a un píxel concret de la imatge.

Per poder fer aquesta barreja de resultats, es defineix primer el vector que els conté.

Definició 2.3.1 (Vector de graus de pertinença). Es denota per $\mathbf{x} = (x_1, x_2, \dots, x_n)$ el vector de graus de pertinença, on cada $x_i \in [0, 1]$ és una component de $\mathbf{x}$ que representa el grau de pertinença a cada posició $i \in \{1, \dots, n\}$.

Sobre aquest vector s'aplica la funció que permet extreure el nou valor assignat al píxel en qüestió, obtingut tenint en compte tots els resultats anteriors.

Definició 2.3.2 (Funció d'agregació). Una funció d'agregació és una funció d' $n > 1$ arguments que assigna el cub unitat n -dimensional a l'interval unitat, $f: [0, 1]^n \rightarrow [0, 1]$, amb les següents propietats:

- preservació de frontera, $f(\underbrace{0, 0, \dots, 0}_{n\text{-vegades}}) = 0$ i $f(\underbrace{1, 1, \dots, 1}_{n\text{-vegades}}) = 1$,
- i monotonia creixent, $\mathbf{x} \leq \mathbf{y} \Rightarrow f(\mathbf{x}) \leq f(\mathbf{y}) \quad \forall \mathbf{x}, \mathbf{y} \in [0, 1]^n$, on $\mathbf{x} \leq \mathbf{y}$ vol dir que $x_i \leq y_i \quad \forall i \in \{1, \dots, n\}$.

A continuació es defineixen més propietats que poden caracteritzar les funcions d'agregació.

Definició 2.3.3 (Monotonia estrictament creixent). Una funció d'agregació f és monòtona estrictament creixent si

$$\mathbf{x} \leq \mathbf{y}, \mathbf{x} \neq \mathbf{y} \Rightarrow f(\mathbf{x}) < f(\mathbf{y}) \quad \forall \mathbf{x}, \mathbf{y} \in [0, 1]^n,$$

on $\mathbf{x} \leq \mathbf{y}$, $\mathbf{x} \neq \mathbf{y}$ vol dir que $x_i \leq y_i \quad \forall i \in \{1, \dots, n\}$ i $\exists j$ tal que $x_j < y_j$.

Definició 2.3.4 (Idempotència). Una funció d'agregació f és idempotent si

$$f(t, t, \dots, t) = t \quad \forall t \in [0, 1].$$

Definició 2.3.5 (Simetria). Sigui $P = (P(1), P(2), \dots, P(n))$ una permutació del vector $(1, 2, \dots, n)$ i $\mathbf{x}_P = (x_{P(1)}, x_{P(2)}, \dots, x_{P(n)})$ el vector $\mathbf{x} \in [0, 1]^n$ amb les components reordenades per aquesta permutació P , una funció d'agregació f és simètrica si el seu valor no depèn de la permutació dels seus arguments, i.e., si

$$f(x_1, x_2, \dots, x_n) = f(x_{P(1)}, x_{P(2)}, \dots, x_{P(n)}) \quad \forall \mathbf{x}, \forall P.$$

Vistes les definicions i propietats necessàries, es defineixen els següents tipus de funcions d'agregació amb les propietats que es considera adient explicar.

Dues funcions d'agregació principals són el mínim i el màxim, que modelen respectivament la intersecció i la unió de conjunts, i que són les úniques que satisfan certes propietats teòriques de conjunts especificades a [9].

Definició 2.3.6 (Funcions d'agregació mínim i màxim). Sigui $\mathbf{x} \in [0, 1]^n$ un vector de graus de pertinença, es defineixen les funcions d'agregació mínim i màxim respectivament com

$$\min(\mathbf{x}) = \min\{x_1, \dots, x_n\}, \quad \max(\mathbf{x}) = \max\{x_1, \dots, x_n\}.$$

Moltes classes de funcions d'agregació inclouen el mínim i el màxim com a membres o com a casos de frontera. Considerar-los com delimitadors permet definir un nou tipus de funció d'agregació, on el valor resultant es pot considerar un representant de tots els valors d'entrada.

Definició 2.3.7 (Funció d'agregació compensatòria). Sigui $\mathbf{x} \in [0, 1]^n$ un vector de graus de pertinença, una funció d'agregació f és una funció d'agregació compensatòria si per a cada $\mathbf{x}$ satisfà

$$\min(\mathbf{x}) \leq f(\mathbf{x}) \leq \max(\mathbf{x}).$$

Proposició 2.1. Les funcions d'agregació compensatòries són idempotents, i viceversa.

Demostració. Sigui $\mathbf{x} \in [0, 1]^n$ un vector de graus de pertinença, i f una funció d'agregació. Es vol demostrar que

$$\forall \mathbf{x} \in [0, 1]^n, \min(\mathbf{x}) \leq f(\mathbf{x}) \leq \max(\mathbf{x}) \iff \forall t \in [0, 1] \text{ amb } \mathbf{t} = (t, \dots, t), f(\mathbf{t}) = t.$$

Recordant que les funcions d'agregació satisfan les propietats

- $f(\mathbf{0}) = 0, f(\mathbf{1}) = 1,$
- $\mathbf{x} \leq \mathbf{y} \Rightarrow f(\mathbf{x}) \leq f(\mathbf{y}) \quad \forall \mathbf{x}, \mathbf{y} \in [0, 1]^n,$

es demostren les dues implicacions.

$\Rightarrow) \forall t \in [0, 1]$ amb $\mathbf{t} = (t, \dots, t)$, $\min(\mathbf{t}) = t$ i $\max(\mathbf{t}) = t$:

$$\min(\mathbf{t}) \leq f(\mathbf{t}) \leq \max(\mathbf{t}) \Rightarrow t \leq f(\mathbf{t}) \leq t \Rightarrow f(\mathbf{t}) = t.$$

$\Leftarrow) \forall \mathbf{x} \in [0, 1]^n$ amb $\min(\mathbf{x}) = m$, $\max(\mathbf{x}) = M$, $\mathbf{m} = (m, \dots, m)$ i $\mathbf{M} = (M, \dots, M)$, es satisfà que $\forall i = 1, \dots, n$, $m \leq x_i \leq M$. Llavors:

$$\mathbf{m} \leq \mathbf{x} \leq \mathbf{M} \Rightarrow f(\mathbf{m}) \leq f(\mathbf{x}) \leq f(\mathbf{M}) \Rightarrow m \leq f(\mathbf{x}) \leq M \Rightarrow \min(\mathbf{x}) \leq f(\mathbf{x}) \leq \max(\mathbf{x}).$$

□

Es defineix formalment la funció mitjana com segueix.

Definició 2.3.8 (Funció mitjana). Sigui $\mathbf{x} \in [0, 1]^n$ un vector de graus de pertinença, qualsevol funció f amb la propietat

$$\min(\mathbf{x}) \leq f(\mathbf{x}) \leq \max(\mathbf{x})$$

és una funció mitjana.

És a dir, una funció mitjana és simplement una funció f amb la propietat esmentada on $f(\mathbf{x})$ és un valor que descriu o resumeix el conjunt $\mathbf{x}$. Tot i que ho pot semblar, les mitjanes i les funcions d'agregació compensatòries no són el mateix. Hi ha funcions compensatòries que no són mitjanes –d'acord amb la definició clàssica de [10]–, i hi ha mitjanes que no satisfan la propietat de monotonia, per la qual cosa no són funcions d'agregació. Un cas concret de funció mitjana que també és funció d'agregació compensatòria és la mitjana aritmètica, que representa el valor central o punt d'equilibri.

Definició 2.3.9 (Mitjana aritmètica). La mitjana aritmètica, o simplement mitjana, de n valors és la funció

$$M(\mathbf{x}) = \frac{1}{n}x_1 + \frac{1}{n}x_2 + \dots + \frac{1}{n}x_n = \frac{1}{n}(x_1 + x_2 + \dots + x_n) = \frac{1}{n} \sum_{i=1}^n x_i.$$

Aquesta funció assigna a cada component del vector de graus de pertinença un pes constant $1/n$, però es podrien atorgar valors diferents amb cada x_i . Es defineix així el vector de ponderacions, que permet alhora formalitzar una nova funció: la mitjana aritmètica ponderada.

Definició 2.3.10 (Vector de ponderacions). Un vector $\mathbf{w} = (w_1, \dots, w_n)$ s'anomena vector de ponderacions si

$$w_i \in [0, 1] \text{ per } i = 1, \dots, n \quad \text{i} \quad \sum_{i=1}^n w_i = 1.$$

Definició 2.3.11 (Mitjana aritmètica ponderada). Donat un vector de ponderacions $\mathbf{w}$, i sigui $\mathbf{x}$ un vector de graus de pertinença, la mitjana aritmètica ponderada és la funció

$$M_{\mathbf{w}}(\mathbf{x}) = w_1x_1 + w_2x_2 + \dots + w_nx_n = \sum_{i=1}^n w_ix_i = \langle \mathbf{w}, \mathbf{x} \rangle.$$

Definició 2.3.12 (Vectors ordenats). Es denota per $\mathbf{x}_{\nearrow}$ el vector $\mathbf{x}$ ordenat en forma creixent, això és, $\mathbf{x}_{\nearrow} = \mathbf{x}_P$ on P és la permutació tal que $x_{P(1)} \leq x_{P(2)} \leq \dots \leq x_{P(n)}$.

Es denota per $\mathbf{x}_{\searrow}$ el vector $\mathbf{x}$ ordenat en forma no creixent, això és, $\mathbf{x}_{\searrow} = \mathbf{x}_P$ on P és la permutació tal que $x_{P(1)} \geq x_{P(2)} \geq \dots \geq x_{P(n)}$.

Fent ús dels vectors ordenats es pot obtenir una nova forma de definir les funcions d'agregació simètriques.

Definició 2.3.13 (Simetria). Una funció d'agregació f és simètrica si per a cada $\mathbf{x}$ satisfà

$$f(\mathbf{x}) = f(\mathbf{x}_{\nearrow}) \quad (\text{o } f(\mathbf{x}) = f(\mathbf{x}_{\searrow})).$$

Un cas particular de funcions d'agregació compensatòries introduïdes per Yager [11] són les funcions compensatòries ponderades ordenades o funcions *Ordered Weighted Averaging* (OWA) en anglès, que associen els pesos no amb l'ordre de les entrades, sinó amb l'ordre donat pels valors de cada component.

Definició 2.3.14 (OWA). Donat un vector de ponderacions $\mathbf{w}$, i sigui $\mathbf{x}$ un vector de graus de pertinença, la funció OWA és

$$OWA_{\mathbf{w}}(\mathbf{x}) = \sum_{i=1}^n w_i x_{(i)} = \langle \mathbf{w}, \mathbf{x}_{\searrow} \rangle,$$

on $\mathbf{x}_{\searrow}$ és el vector $\mathbf{x}$ reordenat en ordre no-creixent $x_{(1)} \geq x_{(2)} \geq \dots \geq x_{(n)}$.

Algunes de les funcions que s'han vist abans d'aquesta definició resulten ser casos especials d'OWAs.

- Si tots els pesos són iguals, $\mathbf{w} = (\frac{1}{n}, \frac{1}{n}, \dots, \frac{1}{n})$, la OWA és la mitjana aritmètica $OWA_{\mathbf{w}}(\mathbf{x}) = M(\mathbf{x})$.
- Si $\mathbf{w} = (1, 0, \dots, 0)$, llavors $OWA_{\mathbf{w}}(\mathbf{x}) = \max(\mathbf{x})$.
- Si $\mathbf{w} = (0, \dots, 0, 1)$, llavors $OWA_{\mathbf{w}}(\mathbf{x}) = \min(\mathbf{x})$.

Una altra OWA d'importància és la OWA inversa.

Definició 2.3.15 (OWA inversa). Sigui $\mathbf{w}$ un vector de ponderacions i la funció OWA determinada per aquest vector $OWA_{\mathbf{w}}$, es defineix la respectiva OWA inversa com la funció $OWA_{\mathbf{w}_d}$, és a dir, la determinada pel vector de ponderacions $\mathbf{w}_d = (w_n, w_{n-1}, \dots, w_1)$.

A les funcions d'agregació compensatòries se'ls pot assignar un valor numèric que mesura el seu caràcter actitudinal conegut com *orness* en anglès. Bàsicament, l'*orness* d'una funció d'agregació compensatòria mesura com de llunyana és de la funció mínim. A continuació es defineix aquesta mesura enunciant un seguit de resultats extrets de [11, 12, 13] i dos teoremes de [14], amb les demostracions que es consideren d'interès.

Definició 2.3.16 (Mesura orness). Sigui f una funció d'agregació compensatòria i integrable. La seva mesura orness és

$$\text{orness}(f) = \frac{\int_{[0,1]^n} f(\mathbf{x}) d\mathbf{x} - \int_{[0,1]^n} \min(\mathbf{x}) d\mathbf{x}}{\int_{[0,1]^n} \max(\mathbf{x}) d\mathbf{x} - \int_{[0,1]^n} \min(\mathbf{x}) d\mathbf{x}}.$$

Proposició 2.2. Siguin $\min$ i $\max$ les funcions d'agregació mínim i màxim, i f una funció d'agregació compensatòria qualsevol. Es satisfà que

$$\text{orness}(\min) = 0, \quad \text{orness}(\max) = 1 \quad \text{i} \quad \text{orness}(f) \in [0, 1].$$

Corol·lari 2.0.1. Es satisfan les següents igualtats:

$$\int_{[0,1]^n} \max(\mathbf{x}) d\mathbf{x} = \frac{n}{n+1} \quad \text{i} \quad \int_{[0,1]^n} \min(\mathbf{x}) d\mathbf{x} = \frac{1}{n+1}.$$

Proposició 2.3. Sigui $OWA_{\mathbf{w}}$ la OWA determinada pel vector de ponderacions $\mathbf{w}$. La seva mesura orness donada a la definició 2.3.16 es pot obtenir amb

$$\text{orness}(OWA_{\mathbf{w}}) = \sum_{i=1}^n w_i \frac{n-i}{n-1} = OWA_{\mathbf{w}} \left(1, \frac{n-2}{n-1}, \dots, \frac{1}{n-1}, 0 \right).$$

Proposició 2.4. La mesura orness satisfà les següents propietats:

- i) Siguin $OWA_{\mathbf{w}}$ una funció OWA i $OWA_{\mathbf{w}_d}$ la seva OWA inversa. Les seves mesures orness es relacionen per

$$\text{orness}(OWA_{\mathbf{w}}) = 1 - \text{orness}(OWA_{\mathbf{w}_d}).$$

- ii) L'orness d'una OWA és 0 si, i només si, és la funció mínim $\min$, on $\mathbf{w} = (0, \dots, 0, 1)$.

- iii) L'orness d'una OWA és 1 si, i només si, és la funció màxim $\max$, on $\mathbf{w} = (1, 0, \dots, 0)$.

- iv) L'orness de la mitjana aritmètica M , on $\mathbf{w} = (\frac{1}{n}, \dots, \frac{1}{n})$, és $\frac{1}{2}$, però també pot ser $\frac{1}{2}$ per a altres OWAs.

Demostració. La demostració es pot trobar a l'apèndix A.1. □

Amb la fórmula detallada de la proposició 2.3 és senzill calcular l'orness de funcions OWA a partir només dels seus vectors de ponderació, cosa que facilita les demostracions dels dos teoremes següents.

Teorema 2.1. L'orness de la funció OWA amb ponderacions donades per

$$w_i = \frac{1}{n} \sum_{j=i}^n \frac{1}{j}$$

és $3/4$ independentment de n , on n és el nombre d'objectes agregats.

Demostració. Al càlcul de l'orness s'empren els resultats d'aquests dos sumatoris:

$$\begin{aligned} \sum_{i=1}^n \sum_{j=i}^n \frac{1}{j} &= \sum_{j=1}^n \frac{1}{j} + \sum_{j=2}^n \frac{1}{j} + \sum_{j=3}^n \frac{1}{j} + \dots + \sum_{j=n}^n \frac{1}{j} = \frac{1}{1} + 2 \sum_{j=2}^n \frac{1}{j} + \sum_{j=3}^n \frac{1}{j} + \dots + \sum_{j=n}^n \frac{1}{j} = \\ &= \frac{1}{1} + 2 \frac{1}{2} + 3 \sum_{j=3}^n \frac{1}{j} + \dots + \sum_{j=n}^n \frac{1}{j} = \sum_{i=1}^n i \cdot \frac{1}{i} = \sum_{i=1}^n 1 = n, \\ \sum_{i=1}^n \sum_{j=1}^n \frac{j}{i} &= \sum_{i=1}^n \frac{1}{i} \sum_{j=1}^i j = \sum_{i=1}^n \frac{1}{i} \left(\frac{i(1+i)}{2} \right) = \sum_{i=1}^n \frac{1+i}{2} = \frac{1}{2} \left(\sum_{i=1}^n 1 + \sum_{i=1}^n i \right) = \\ &= \frac{1}{2} \left(n + \frac{n(1+n)}{2} \right) = \frac{n^2 + 3n}{4}. \end{aligned}$$

Així doncs, el valor de l'orness de la funció OWA indicada és

$$\begin{aligned} \text{orness}(\text{OWA}_{\mathbf{w}}) &= \sum_{i=1}^n w_i \frac{n-i}{n-1} = \sum_{i=1}^n \left(\frac{1}{n} \sum_{j=i}^n \frac{1}{j} \right) \frac{n-i}{n-1} = \frac{1}{n(n-1)} \sum_{i=1}^n \left((n-i) \sum_{j=i}^n \frac{1}{j} \right) = \\ &= \frac{1}{n(n-1)} \sum_{i=1}^n \left(n \sum_{j=i}^n \frac{1}{j} - i \sum_{j=i}^n \frac{1}{j} \right) = \frac{1}{n(n-1)} \left(n \sum_{i=1}^n \sum_{j=i}^n \frac{1}{j} - \sum_{i=1}^n \sum_{j=i}^n \frac{i}{j} \right) = \\ &= \frac{1}{n(n-1)} \left(n \cdot n - \frac{n^2 + 3n}{4} \right) = \frac{1}{(n-1)} \left(\frac{3(n-1)}{4} \right) = \frac{3}{4}. \end{aligned}$$

□

Teorema 2.2. L'orness de la funció OWA amb ponderacions donades per

$$w_i = \frac{(n-i+1)}{\sum_{j=1}^n (n-j+1)} = \frac{2(n-i+1)}{n(n+1)}$$

és $2/3$ independentment de n , on n és el nombre d'objectes agregats.

Demostració. Primer de tot es prova la igualtat de la dreta. És a dir, es vol provar

$$\frac{(n-i+1)}{\sum_{j=1}^n (n-j+1)} = \frac{2(n-i+1)}{n(n+1)} \Rightarrow \frac{1}{\sum_{j=1}^n (n-j+1)} = \frac{2}{n(n+1)},$$

que efectivament es satisfà, ja que

$$\sum_{j=1}^n (n-j+1) = \sum_{j=1}^n n - \sum_{j=1}^n j + \sum_{j=1}^n 1 = n^2 - \frac{n(1+n)}{2} + n = \frac{n(n+1)}{2}.$$

Emprant el valor del sumatori

$$\sum_{i=1}^n i^2 = \frac{n}{6}(2n+1)(n+1),$$

l'orness de la funció OWA indicada és

$$\begin{aligned} \text{orness}(\text{OWA}_{\mathbf{w}}) &= \sum_{i=1}^n w_i \frac{n-i}{n-1} = \sum_{i=1}^n \left(\frac{2(n+1-i)}{n(n+1)} \right) \frac{n-i}{n-1} = \\ &= \frac{2}{n(n+1)(n-1)} \sum_{i=1}^n (n^2 + n + i^2 - (2n+1)i) = \\ &= \frac{2}{n(n+1)(n-1)} \left((n^2 + n) \sum_{i=1}^n 1 + \sum_{i=1}^n i^2 - (2n+1) \sum_{i=1}^n i \right) = \\ &= \frac{2}{n(n+1)(n-1)} \left(n(n^2 + n) + \frac{n}{6}(2n+1)(n+1) - (2n+1) \frac{n(n+1)}{2} \right) = \\ &= \frac{2}{(n-1)} \left(n + \frac{(2n+1)}{6} - \frac{(2n+1)}{2} \right) = \frac{1}{3(n-1)} (6n + 2n + 1 - 3(2n+1)) = \frac{2}{3}. \end{aligned}$$

□

Acabada d'estudiar l'orness, una mesura associada a les funcions d'agregació compensatòries, s'introdueix a continuació una mesura associada als vectors de ponderacions, de la qual es detallen la definició i un seguit de propietats.

Definició 2.3.17 (Entropia o dispersió de ponderacions). Donat un vector de ponderacions $\mathbf{w}$, la seva mesura de dispersió o entropia és

$$\text{Disp}(\mathbf{w}) = - \sum_{i=1}^n w_i \log w_i,$$

amb la convenció $0 \cdot \log 0 = 0$. A més, s'entén per entropia d'una funció d'agregació ponderada f a l'entropia del seu vector de ponderacions.

L'entropia determina el grau en què una funció d'agregació ponderada f té en compte totes les entrades. Per exemple, prenent els vectors $\mathbf{w}_1 = (0, 1)$ i $\mathbf{w}_2 = (0.5, 0.5)$ es té $\text{Disp}(\mathbf{w}_1) = 0$ i $\text{Disp}(\mathbf{w}_2) = 0.3$, que coincideix amb el fet que el primer vector només té en consideració una de dues entrades d'informació, mentre que el segon vector en considera les dues.

Cal notar que en cap moment s'han definit les funcions d'agregació ponderades. Simplement són funcions d'agregació on a cada entrada se li assigna una ponderació. Un exemple és la mitjana aritmètica ponderada que sí s'ha enunciat, un altre són les OWAs. Donar-ne una definició més formal escapa del contingut d'aquest TFG, i es disposa de [8] per ampliar el concepte.

Proposició 2.5. L'entropia satisfà les següents propietats:

- i) Sigui $OWA_{\mathbf{w}}$ una funció OWA i $OWA_{\mathbf{w}_d}$ la seva OWA inversa. Les seves entropies es relacionen per

$$\text{Disp}(\mathbf{w}) = \text{Disp}(\mathbf{w}_d).$$

De fet, l'entropia d'un vector és constant respecte a permutacions d'aquest.

- ii) S'obté el mínim de Disp si, i només si, $\mathbf{w}$ és tal que $w_k = 1$ i $w_i = 0 \ \forall i \neq k$, és a dir, a l'ordre estàtic, i l'entropia d'aquest vector de ponderacions val 0.
- iii) Si no s'especifica l'orness, s'obté el màxim de Disp a $OWA_{\mathbf{w}} = M$, és a dir, a la mitjana aritmètica on $\mathbf{w} = (\frac{1}{n}, \dots, \frac{1}{n})$, i l'entropia d'aquest vector de ponderacions val $\log n$.

Demostració. La demostració completa de la proposició es pot consultar a l'apèndix A.2. Aquí es desenvolupa la demostració de l'apartat iii) quasi en la seva totalitat.

- iii) $\max(\text{Disp}(\mathbf{w})) = \log n$ quan $\mathbf{w} = (\frac{1}{n}, \dots, \frac{1}{n})$.

Es prova amb el mètode dels multiplicadors de Lagrange resolent el problema d'optimització

$$\begin{aligned} \max \quad & \text{Disp}(\mathbf{w}) = - \sum_{i=1}^n w_i \log w_i \\ \text{subjecte a} \quad & \sum_{i=1}^n w_i = 1, \\ & w_i \geq 0, \quad i = 1, \dots, n. \end{aligned}$$

La funció de Lagrange és

$$L(\mathbf{w}, \lambda) = - \sum_{i=1}^n w_i \log w_i + \lambda \left(\sum_{i=1}^n w_i - 1 \right),$$

on $\lambda \in \mathbb{R}$ és un multiplicador de Lagrange. S'obté $\mathbf{w}$ resolent el sistema següent:

$$\begin{aligned} \frac{\partial L}{\partial w_j} = 0 &\Rightarrow -\log w_j - 1 + \lambda = 0 \Rightarrow w_j = e^{\lambda-1}, \quad j = 1, \dots, n, \\ \frac{\partial L}{\partial \lambda} = 0 &\Rightarrow \sum_{i=1}^n w_i - 1 = 0 \Rightarrow \sum_{i=1}^n e^{\lambda-1} - 1 = 0 \Rightarrow n e^{\lambda-1} = 1 \Rightarrow e^{\lambda-1} = \frac{1}{n}. \end{aligned}$$

Per tant, $w_j = \frac{1}{n}$ per $j = 1, \dots, n$, és a dir, $\mathbf{w} = (\frac{1}{n}, \dots, \frac{1}{n})$, i el valor de l'entropia d'aquest vector és

$$\text{Disp} \left(\frac{1}{n}, \dots, \frac{1}{n} \right) = - \sum_{i=1}^n \frac{1}{n} \log \frac{1}{n} = - \frac{n}{n} \log \frac{1}{n} = -(\log 1 - \log n) = \log n.$$

L'única solució obtinguda no és un mínim per la propietat *ii*, i la concavitat estricta de l'entropia en el seu domini garanteix que sí correspon al màxim.

□

Una forma d'escollir les ponderacions d'una OWA és imposant que l'entropia sigui màxima donat un cert valor α de l'orness. Es defineix així la OWA de màxima entropia o *Maximum Entropy OWA* (MEOWA) en anglès, de la qual es donen la definició i un seguit de resultats que permetran completar la demostració de [15].

Definició 2.3.18 (MEOWA). La OWA de màxima entropia MEOWA és $MEOWA_{\mathbf{w}} = OWA_{\mathbf{w}}$ amb vector de ponderacions $\mathbf{w}$ donat per la solució del problema d'optimització

$$\begin{aligned} \max \quad & \text{Disp}(\mathbf{w}) = - \sum_{i=1}^n w_i \log w_i \\ \text{subjecte a} \quad & \sum_{i=1}^n w_i \frac{n-i}{n-1} = \alpha, \\ & \sum_{i=1}^n w_i = 1, \\ & w_i \geq 0, \quad i = 1, \dots, n. \end{aligned}$$

Proposició 2.6. Sigui $\alpha = \text{orness}(MEOWA_{\mathbf{w}})$, la MEOWA satisfà les següents propietats:

- i) Si $\alpha = 0$, la MEOWA és la OWA min, amb vector de ponderacions $\mathbf{w} = (0, \dots, 0, 1)$, i el valor màxim de l'entropia és 0.
- ii) Si $\alpha = 1$, la MEOWA és la OWA max, amb vector de ponderacions $\mathbf{w} = (1, 0, \dots, 0)$, i el valor màxim de l'entropia torna a ser 0.
- iii) Si $\alpha = \frac{1}{2}$, la MEOWA és la OWA M , amb vector de ponderacions $\mathbf{w} = (\frac{1}{n}, \dots, \frac{1}{n})$, i el valor màxim de l'entropia és $\log n$.

Demostració. La demostració es pot trobar a l'apèndix A.3. $\square$

Proposició 2.7. Per $\tilde{\alpha} \in (\frac{1}{2}, 1)$, el vector de ponderacions $\tilde{\mathbf{w}}$ de la MEOWA corresponent és $\mathbf{w}_d$, el vector de ponderacions revers de $\mathbf{w}$, solució del problema d'optimització plantejat per $\alpha = 1 - \tilde{\alpha} \in (0, \frac{1}{2})$.

Proposició 2.8. Siguin $MEOWA_{\tilde{\mathbf{w}}}$ la MEOWA amb vector de ponderacions $\tilde{\mathbf{w}}$ determinat per $\text{orness}(MEOWA_{\tilde{\mathbf{w}}}) = \tilde{\alpha}$, i $MEOWA_{\mathbf{w}}$ la MEOWA amb vector de ponderacions $\mathbf{w}$ determinat per $\text{orness}(MEOWA_{\mathbf{w}}) = \alpha$ on $\alpha \in (0, \frac{1}{2})$. Llavors resulta que $\tilde{\alpha} = 1 - \alpha \in (\frac{1}{2}, 1)$ i $\tilde{\mathbf{w}} = \mathbf{w}_d$, on $\mathbf{w}_d$ és el vector de ponderacions revers de $\mathbf{w}$.

Demostració. Sigui $\mathbf{w}$ el vector de ponderacions de la $MEOWA_{\mathbf{w}}$ pel valor de l'orness imposat $\alpha \in (0, \frac{1}{2})$. Per ser $\mathbf{w}$ vector de ponderacions, aquest i qualsevol permutació dels seus components satisfà les condicions

$$\sum_{i=1}^n w_i = 1 \quad \text{i} \quad w_i \geq 0, \quad i = 1, \dots, n.$$

Es recorda de la propietat i de l'entropia (veure proposició 2.5) que

$$\text{Disp}(\mathbf{w}) = \text{Disp}(\mathbf{w}_d),$$

però, en canvi, per la propietat i de l'orness (proposició 2.4) es té

$$\text{orness}(MEOWA_{\mathbf{w}}) = 1 - \text{orness}(MEOWA_{\mathbf{w}_d}),$$

que és el mateix que

$$\text{orness}(MEOWA_{\mathbf{w}_d}) = 1 - \alpha,$$

on $MEOWA_{\mathbf{w}_d}$ és una nova MEOWA amb valor d'orness imposat $\tilde{\alpha} = 1 - \alpha \in (\frac{1}{2}, 1)$ i vector de ponderacions $\tilde{\mathbf{w}} = \mathbf{w}_d$. $\square$

Ja es tenen les MEOWAs per $\alpha = 0$, $\alpha = 1$ i $\alpha = \frac{1}{2}$, i com trobar les que tenen $\alpha \in (\frac{1}{2}, 1)$. Per tant, només falta trobar l'expressió dels vectors de ponderacions de les MEOWAs amb $\alpha \in (0, \frac{1}{2})$.

Proposició 2.9. La solució del problema d'optimització plantejat a la definició 2.3.18 subjecte a $\alpha \in (0, \frac{1}{2})$ ve donada per

$$w_i = (w_1^{n-i} w_n^{i-1})^{\frac{1}{n-1}}, \quad i = 2, \dots, n-1,$$

$$w_n = \frac{((n-1)\alpha - n)w_1 + 1}{(n-1)\alpha + 1 - nw_1},$$

i w_1 l'única solució a l'interval $(0, \frac{1}{n})$ de l'equació

$$w_1 [(n-1)\alpha + 1 - nw_1]^n = ((n-1)\alpha)^{n-1} [((n-1)\alpha - n)w_1 + 1].$$

Demostració. Siguin $n > 1$ i $\alpha \in (0, \frac{1}{2})$, primer es demostraran les expressions enunciades emprant el mètode dels multiplicadors de Lagrange, i després la unicitat de w_1 amb el perquè de l'interval on pertany¹.

¹Tots els detalls de la demostració, a causa de la seva longitud, es poden consultar a l'apèndix A.4.

La funció de Lagrange del problema d'optimització plantejat és

$$L(\mathbf{w}, \lambda_1, \lambda_2) = - \sum_{i=1}^n w_i \log w_i + \lambda_1 \left(\sum_{i=1}^n w_i \frac{n-i}{n-1} - \alpha \right) + \lambda_2 \left(\sum_{i=1}^n w_i - 1 \right),$$

on $\lambda_1, \lambda_2 \in \mathbb{R}$ són els multiplicadors de Lagrange.

Per trobar els valors de $\mathbf{w}$, λ_1 i λ_2 , es resol el sistema d'equacions que surt d'igualar les derivades parcials de $L(\mathbf{w}, \lambda_1, \lambda_2)$ a 0:

$$\begin{aligned} \frac{\partial L}{\partial w_j} = 0 &\Rightarrow -\log w_j - 1 + \lambda_1 \frac{n-j}{n-1} + \lambda_2 = 0, \quad j = 1, \dots, n, \\ \frac{\partial L}{\partial \lambda_1} = 0 &\Rightarrow \sum_{i=1}^n w_i \frac{n-i}{n-1} - \alpha = 0, \\ \frac{\partial L}{\partial \lambda_2} = 0 &\Rightarrow \sum_{i=1}^n w_i - 1 = 0. \end{aligned}$$

De les primeres n equacions es té que:

- per $j = n$: $-\log w_n - 1 + \lambda_2 = 0 \Rightarrow \lambda_2 = 1 + \log w_n$,
- per $j = 1$: $-\log w_1 - 1 + \lambda_1 + \lambda_2 = 0 \Rightarrow \lambda_1 = \log w_1 - \log w_n$,
- per $j = 2, \dots, n-1$ i emprant les λ_1 i λ_2 trobades,

$$\begin{aligned} -\log w_j - 1 + (\log w_1 - \log w_n) \frac{n-j}{n-1} + (1 + \log w_n) &= 0 \\ \log w_j &= \frac{n-j}{n-1} \log w_1 - \frac{n-j}{n-1} \log w_n + \frac{n-1}{n-1} \log w_n \\ \log w_j &= \frac{n-j}{n-1} \log w_1 + \frac{j-1}{n-1} \log w_n \\ w_j &= \sqrt[n-1]{w_1^{n-j} w_n^{j-1}}. \end{aligned}$$

Així doncs, el sistema a resoldre passa a ser el següent:

$$\begin{aligned} \frac{\partial L}{\partial w_j} = 0 &\Rightarrow w_j = \sqrt[n-1]{w_1^{n-j} w_n^{j-1}}, \quad j = 2, \dots, n-1, \\ \frac{\partial L}{\partial \lambda_1} = 0 &\Rightarrow \sum_{i=1}^n w_i \frac{n-i}{n-1} - \alpha = 0, \\ \frac{\partial L}{\partial \lambda_2} = 0 &\Rightarrow \sum_{i=1}^n w_i - 1 = 0. \end{aligned}$$

Per facilitar els càlculs, s'introdueixen a les equacions les notacions $u_1 = \sqrt[n-1]{w_1}$ i $u_n = \sqrt[n-1]{w_n}$, de forma que el sistema plantejat queda com

$$\frac{\partial L}{\partial w_j} = 0 \Rightarrow w_j = u_1^{n-j} u_n^{j-1}, \quad j = 2, \dots, n-1, \quad (2.1)$$

$$\frac{\partial L}{\partial \lambda_1} = 0 \Rightarrow \sum_{i=1}^n u_1^{n-i} u_n^{i-1} (n-i) = \alpha(n-1), \quad (2.2)$$

$$\frac{\partial L}{\partial \lambda_2} = 0 \Rightarrow \sum_{i=1}^n u_1^{n-i} u_n^{i-1} = 1. \quad (2.3)$$

Es calculen els sumatoris que apareixen en aquestes equacions, amb els quals es poden trobar els valors de w_1 i w_n emprant les equacions (2.2) i (2.3) del sistema i, finalment, desfent la notació emprada, s'arriba a les expressions enunciades:

$$\begin{cases} \frac{\partial L}{\partial w_j} = 0 & \Rightarrow w_j = (w_1^{n-j} w_n^{j-1})^{\frac{1}{n-1}}, \quad j = 2, \dots, n-1, \\ \frac{\partial L}{\partial \lambda_1} = 0 & \Rightarrow (\alpha(n-1))^{n-1} ((\alpha(n-1) - n)w_1 + 1) = w_1 (\alpha(n-1) - nw_1 + 1)^n, \\ \frac{\partial L}{\partial \lambda_2} = 0 & \Rightarrow w_n = \frac{(\alpha(n-1) - n)w_1 + 1}{\alpha(n-1) - nw_1 + 1}. \end{cases}$$

Per acabar la demostració, s'estudia la solució w_1 de l'equació

$$w_1 [(n-1)\alpha + 1 - nw_1]^n = ((n-1)\alpha)^{n-1} [((n-1)\alpha - n)w_1 + 1]. \quad (2.4)$$

Cal fixar-se que la part de la dreta de la igualtat és un polinomi de grau 1 i la part de l'esquerra un polinomi de grau $n+1$, per tant les solucions w_1 d'aquesta equació corresponen als punts d'intersecció entre la corba

$$f(w_1) = w_1 [(n-1)\alpha + 1 - nw_1]^n$$

i la recta

$$g(w_1) = ((n-1)\alpha)^{n-1} [((n-1)\alpha - n)w_1 + 1].$$

Se n'estudia, doncs, el seu comportament, recordant que $w_1 \in [0, 1]$ per ser una ponderació i que s'ha restringit $\alpha \in (0, \frac{1}{2})$.

Es calculen de g els talls amb els eixos i la monotonia:

- $g(0) = ((n-1)\alpha)^{n-1} > 0 \Rightarrow g$ talla l'eix OY al punt $(0, ((n-1)\alpha)^{n-1})$,
- $0 = ((n-1)\alpha)^{n-1} [((n-1)\alpha - n)w_1 + 1] \Rightarrow \check{w}_1 = \frac{1}{n - (n-1)\alpha} \in \left(\frac{1}{n}, 1\right) \Rightarrow g$ talla l'eix OX al punt $\left(\frac{1}{n - (n-1)\alpha}, 0\right)$,
- $g'(w_1) = -((n-1)\alpha)^{n-1} (n - (n-1)\alpha) < 0 \Rightarrow g$ és decreixent.

Ara s'estudia el comportament de f :

- $f(0) = 0 \Rightarrow f$ passa per l'origen de coordenades $(0, 0)$.
- De la primera derivada

$$\begin{aligned} f'(w_1) &= [(n-1)\alpha - nw_1 + 1]^n - n^2 w_1 [(n-1)\alpha - nw_1 + 1]^{n-1} = \\ &= ((n-1)\alpha - nw_1 + 1 - n^2 w_1) [(n-1)\alpha - nw_1 + 1]^{n-1}, \end{aligned}$$

cal notar que

$$f'\left(\frac{1}{n}\right) = ((n-1)\alpha - n) [(n-1)\alpha]^{n-1} = g'\left(\frac{1}{n}\right),$$

i que, de fet,

$$f\left(\frac{1}{n}\right) = \frac{1}{n}[(n-1)\alpha]^n = g\left(\frac{1}{n}\right),$$

és a dir, a $w_1 = \frac{1}{n}$, f i g coincideixen i són tangents.

A més, s'obtenen els punts crítics de la igualtat $f'(w_1) = 0$:

$$\begin{cases} (n-1)\alpha - nw_1 + 1 - n^2w_1 = 0 & \Rightarrow \widehat{w}_1 = \frac{(n-1)\alpha + 1}{n(n+1)} \in \left(0, \frac{1}{n}\right), \\ (n-1)\alpha - nw_1 + 1 = 0 & \Rightarrow \widetilde{w}_1 = \frac{(n-1)\alpha + 1}{n} \in \left(\frac{1}{n}, 1\right), \end{cases}$$

on $f(\widetilde{w}_1) = 0$, per tant $(\widetilde{w}_1, 0)$ és un altre punt de tall de f amb l'eix OX .

- Amb la segona derivada,

$$\begin{aligned} f''(w_1) &= -2n^2[(n-1)\alpha - nw_1 + 1]^{n-1} + n^3(n-1)w_1[(n-1)\alpha - nw_1 + 1]^{n-2} = \\ &= -n^2(2((n-1)\alpha + 1) - nw_1(n+1))[(n-1)\alpha - nw_1 + 1]^{n-2}, \end{aligned}$$

s'estudia la curvatura als punts d'interès:

$$f''(0) = -2n^2[(n-1)\alpha + 1]^{n-1} < 0,$$

$$f''(\widehat{w}_1) = -n((n-1)\alpha + 1) \left[\frac{n((n-1)\alpha + 1)}{n+1} \right]^{n-2} < 0,$$

$$f''\left(\frac{1}{n}\right) = n^2(n-1)(1-2\alpha)[(n-1)\alpha]^{n-2} > 0,$$

$$f''(\widetilde{w}_1) = 0,$$

$$f''(1) = n^2(n(1-2\alpha) + 2(1-\alpha) + n^2)[-(n-1)(1-\alpha)]^{n-2} \begin{cases} > 0 & \text{per } n \text{ parell,} \\ < 0 & \text{per } n \text{ senar.} \end{cases}$$

D'aquests càlculs s'extreu que la recta g és decreixent i talla els eixos de coordenades en valors positius, i que la corba f comença creixent fins que arriba a un màxim, decreix fins a un mínim o fins a un punt d'inflexió sobre l'eix de coordenades, i creix o decreix per la resta de valors. Més en detall es poden concloure els següents punts, que es visualitzen a la figura 2.1 amb les corresponents etiquetes.

- A $w_1 = 0$ la corba f val 0 i la recta g talla l'eix d'ordenades a un valor superior. A més, la recta és decreixent i la corba en aquest punt és creixent i convexa.
- La corba f té un màxim a $\widehat{w}_1 \in (0, \frac{1}{n})$.
- A $w_1 = \frac{1}{n}$ la recta f i la corba g es tallen i tenen el mateix pendent. A més, per ser $f''(\frac{1}{n}) > 0$, en un entorn d'aquest punt la corba és convexa, per tant està per sobre de la recta.
- La recta, que es troba per sota de la corba, segueix decreixent fins a tallar l'eix de coordenades a $\widetilde{w}_1 > \frac{1}{n}$.




Figura 2.1: Desglossament gràfic de les característiques clau de la corba f , en verd, i la recta g , en vermell. Per entendre'n millor el comportament, es recomana consultar l'enllaç de GeoGebra: <https://www.geogebra.org/m/q2b5abwx>.

- (e) La corba talla l'eix de coordenades a $\widetilde{w}_1 \in (\check{w}_1, 1)$, i en aquest punt hi té un mínim, si n és parell, o un punt d'inflexió, si n és senar.
- (f) Si n és parell, des del punt mínim la corba segueix creixent i té un valor positiu a $w_1 = 1$, i si n és senar, des del punt d'inflexió la corba segueix decreixent i té un valor negatiu a $w_1 = 1$.

Per tant, pels punts (b) i (c), el màxim de la corba es troba per damunt de la recta, i, com els únics punts crítics de la corba han estat aquest màxim a $\widehat{w}_1$ i el mínim o punt d'inflexió a $\widetilde{w}_1 > \frac{1}{n}$, es pot assegurar que la corba i la recta s'intersequen una única vegada entre 0 i $\frac{1}{n}$, és a dir, existeix una única solució de l'equació (2.4) a $w_1 \in (0, \frac{1}{n})$.

Ara bé, en el cas que n sigui senar, s'ha vist que la corba té un punt d'inflexió a $\widetilde{w}_1$ i que decreix a partir de llavors. Pels punts (d) i (e), una intersecció amb $w_1 > \frac{1}{n}$ succeiria només en un valor $w_1 > \widehat{w}_1$. Per acabar la demostració s'estudia com afectaria això al valor w_n .

Recordant que l'expressió de w_n depèn del valor de w_1 , es pot considerar la funció

$$w_n(w_1) = \frac{(\alpha(n-1) - n)w_1 + 1}{\alpha(n-1) - nw_1 + 1},$$

que és una funció racional. Més en concret, $w_n(w_1)$ és una hipèrbola amb asymptota vertical exactament a

$$w_1 = \frac{\alpha(n-1) + 1}{n} = \widehat{w}_1,$$

i a més és decreixent perquè

$$w'_n = \frac{-\alpha(n-1)^2(1-\alpha)}{(\alpha(n-1) - nw_1 + 1)^2} < 0.$$

Per tant, la hipèrbola és de la forma de la figura 2.2a i, com $w_n(1) = 1$, sempre passa pel punt $Q = (1, 1)$. Visualitzant aquest fet amb més claredat a la figura 2.2b es veu que per qualsevol $w_1 \in (\widehat{w}_1, 1)$ l'altura de la hipèrbola resulta en un valor major que 1, i considerar aquesta altra possible solució de w_1 que duu a un valor $w_n > 1$ contradiria la restricció $\sum_{i=1}^n w_i = 1$ del problema plantejat.

□




Figura 2.2: Desglossament gràfic del comportament de la hipèrbola w_n , en blau. Per entendre'n millor el comportament, es pot consultar el gràfic a l'enllaç de GeoGebra: <https://www.geogebra.org/m/arefzevn>.

Acabada d'estudiar la MEOWA, una segona opció per escollir les ponderacions d'una OWA és imposar que la variància sigui mínima donat un cert valor α de l'orness. Es defineixen, doncs, la variància de ponderacions i la OWA de mínima variància o *Minimum Variance OWA* (MVOWA) en anglès, i s'inclouen els resultats i les demostracions que es consideren d'interès i que permetran reproduir la demostració de [16] amb més detall.

Definició 2.3.19 (Variància de ponderacions). Donat un vector de ponderacions $\mathbf{w}$, la seva variància és

$$D^2(\mathbf{w}) = \frac{1}{n} \sum_{i=1}^n (w_i - M(\mathbf{w}))^2,$$

on $M(\mathbf{w})$ és la mitjana aritmètica de $\mathbf{w}$. A més, s'entén per variància d'una funció d'agregació ponderada f a la variància del seu vector de ponderacions.

Proposició 2.10. Donat un vector de ponderacions $\mathbf{w}$, la seva variància es pot obtenir amb

$$D^2(\mathbf{w}) = \frac{1}{n} \sum_{i=1}^n w_i^2 - \frac{1}{n^2}.$$

Demostració. Per la definició de vector de ponderacions 2.3.10, resulta que

$$M(\mathbf{w}) = \frac{1}{n} \sum_{i=1}^n w_i = \frac{1}{n}.$$

Així doncs, es té que

$$\begin{aligned} D^2(\mathbf{w}) &= \frac{1}{n} \sum_{i=1}^n (w_i - M(\mathbf{w}))^2 = \frac{1}{n} \sum_{i=1}^n \left(w_i - \frac{1}{n} \right)^2 = \frac{1}{n} \sum_{i=1}^n \left(w_i^2 - \frac{2}{n} w_i + \frac{1}{n^2} \right) = \\ &= \frac{1}{n} \sum_{i=1}^n w_i^2 - \frac{2}{n^2} \sum_{i=1}^n w_i + \frac{1}{n^3} \sum_{i=1}^n 1 = \frac{1}{n} \sum_{i=1}^n w_i^2 - \frac{2}{n^2} + \frac{n}{n^3} = \frac{1}{n} \sum_{i=1}^n w_i^2 - \frac{1}{n^2}. \end{aligned}$$

□

Proposició 2.11. La variància satisfà les següents propietats:

- i) Siguin $OWA_{\mathbf{w}}$ una funció OWA i $OWA_{\mathbf{w}_d}$ la seva OWA inversa. Les seves variàncies es relacionen per

$$D^2(\mathbf{w}) = D^2(\mathbf{w}_d).$$

- ii) S'obté el mínim de D^2 a $OWA_{\mathbf{w}} = M$, és a dir, a la mitjana aritmètica on es té $\mathbf{w} = (\frac{1}{n}, \dots, \frac{1}{n})$, i la variància d'aquest vector de ponderacions val 0.

Demostració. Es demostren una a una les propietats mencionades.

i) $D^2(\mathbf{w}) = D^2(\mathbf{w}_d)$.

$$D^2(\mathbf{w}) = \frac{1}{n} \sum_{i=1}^n w_i^2 - \frac{1}{n^2} = \frac{1}{n} \sum_{i=1}^n w_{n-i+1}^2 - \frac{1}{n^2} = D^2(\mathbf{w}_d).$$

- ii) $\min(D^2(\mathbf{w})) = 0$ quan $\mathbf{w} = (\frac{1}{n}, \dots, \frac{1}{n})$. Es prova amb el mètode dels multiplicadors de Lagrange resolent el problema d'optimització

$$\begin{aligned} \min \quad & D^2(\mathbf{w}) = \frac{1}{n} \sum_{i=1}^n w_i^2 - \frac{1}{n^2} \\ \text{subjecte a} \quad & \sum_{i=1}^n w_i = 1, \\ & w_i \geq 0, \quad i = 1, \dots, n. \end{aligned}$$

La funció de Lagrange és

$$L(\mathbf{w}, \lambda) = \frac{1}{n} \sum_{i=1}^n w_i^2 - \frac{1}{n^2} + \lambda \left(\sum_{i=1}^n w_i - 1 \right),$$

on $\lambda \in \mathbb{R}$ és un multiplicador de Lagrange. Llavors s'obté $\mathbf{w}$ resolent el sistema següent:

$$\begin{aligned} \frac{\partial L}{\partial w_j} = 0 \quad & \Rightarrow \quad \frac{2}{n} w_j + \lambda = 0 \Rightarrow w_j = -\frac{\lambda}{2} n, \quad j = 1, \dots, n, \\ \frac{\partial L}{\partial \lambda} = 0 \quad & \Rightarrow \quad \sum_{i=1}^n w_i - 1 = 0 \Rightarrow \sum_{i=1}^n -\frac{\lambda}{2} n - 1 = 0 \Rightarrow -\frac{\lambda}{2} n^2 = 1 \Rightarrow \lambda = -\frac{2}{n^2}. \end{aligned}$$

Per tant, $w_j = \frac{1}{n}$ per $j = 1, \dots, n$, és a dir, $\mathbf{w} = (\frac{1}{n}, \dots, \frac{1}{n})$. Per acabar es calcula el valor de la variància d'aquest vector:

$$D^2\left(\frac{1}{n}, \dots, \frac{1}{n}\right) = \frac{1}{n} \sum_{i=1}^n \left(\frac{1}{n}\right)^2 - \frac{1}{n^2} = \frac{n}{n} \cdot \frac{1}{n^2} - \frac{1}{n^2} = 0.$$

□

Definició 2.3.20 (MVOWA). La OWA de mínima variància MVOWA és $MVOWA_{\mathbf{w}} = OWA_{\mathbf{w}}$ amb vector de ponderacions $\mathbf{w}$ donat per la solució del problema d'optimització

$$\begin{aligned} \min \quad & D^2(\mathbf{w}) = \frac{1}{n} \sum_{i=1}^n w_i^2 - \frac{1}{n^2} \\ \text{subjecte a} \quad & \sum_{i=1}^n w_i \frac{n-i}{n-1} = \alpha, \\ & \sum_{i=1}^n w_i = 1, \\ & w_i \geq 0, \quad i = 1, \dots, n. \end{aligned} \tag{2.5}$$

Proposició 2.12. Sigui $\alpha = \text{orness}(MVOWA_{\mathbf{w}})$, la MVOWA satisfà les següents propietats:

- i) Si $\alpha = 0$, la MVOWA és la OWA min, amb vector de ponderacions $\mathbf{w} = (0, \dots, 0, 1)$, i el valor mínim de la variància és $\frac{1}{n} \left(1 - \frac{1}{n}\right)$.
- ii) Si $\alpha = 1$, la MVOWA és la OWA max, amb vector de ponderacions $\mathbf{w} = (1, 0, \dots, 0)$, i el valor mínim de la variància torna a ser $\frac{1}{n} \left(1 - \frac{1}{n}\right)$.
- iii) Si $\alpha = \frac{1}{2}$, la MVOWA és la OWA M , amb vector de ponderacions $\mathbf{w} = \left(\frac{1}{n}, \dots, \frac{1}{n}\right)$, i el valor mínim de la variància és 0.

Demostració. Sigui $\alpha = \text{orness}(MVOWA_{\mathbf{w}})$, es demostren una a una les propietats mencionades emprant les propietats de l'orness i de la variància, vistes a les proposicions 2.4 i 2.11 respectivament.

- i) $\alpha = 0 \Rightarrow MVOWA_{\mathbf{w}} = \min$, on $\mathbf{w} = (0, \dots, 0, 1)$, i $\min(D^2(\mathbf{w})) = \frac{1}{n} \left(1 - \frac{1}{n}\right)$.

Per la propietat ii de l'orness (proposició 2.4), si $\alpha = 0$, la MVOWA resulta ser la OWA min, amb vector de ponderacions $\mathbf{w} = (0, \dots, 0, 1)$, i, com $D^2(\mathbf{w}) = \frac{1}{n} \left(1 - \frac{1}{n}\right)$, el valor mínim de la variància resulta ser $\frac{1}{n} \left(1 - \frac{1}{n}\right)$.

- ii) $\alpha = 1 \Rightarrow MEOWA_{\mathbf{w}} = \max$, on $\mathbf{w} = (1, 0, \dots, 0)$, i $\min(D^2(\mathbf{w})) = \frac{1}{n} \left(1 - \frac{1}{n}\right)$.

Per la propietat iii de l'orness (veure proposició 2.4), si $\alpha = 1$, la MVOWA resulta ser la OWA max, amb vector de ponderacions $\mathbf{w} = (1, 0, \dots, 0)$, i el valor mínim de la variància torna a ser $\frac{1}{n} \left(1 - \frac{1}{n}\right)$.

- iii) $\alpha = \frac{1}{2} \Rightarrow MEOWA_{\mathbf{w}} = M$, on $\mathbf{w} = \left(\frac{1}{n}, \dots, \frac{1}{n}\right)$, i $\min(D^2(\mathbf{w})) = 0$.

De la propietat iv de l'orness (veure proposició 2.4) es sap que hi ha més d'una OWA que pot tenir $\alpha = \frac{1}{2}$, però una d'elles –la M – és la que minimitza la variància, com s'ha vist a la propietat ii de la variància (a la proposició 2.11), per tant la solució del problema en aquest cas és el vector de ponderacions $\left(\frac{1}{n}, \dots, \frac{1}{n}\right)$, amb valor mínim de la variància 0.

□

Proposició 2.13. Siguin $MVOWA_{\tilde{\mathbf{w}}}$ la MVOWA amb vector de ponderacions $\tilde{\mathbf{w}}$ determinat per $\text{orness}(MVOWA_{\tilde{\mathbf{w}}}) = \tilde{\alpha}$, i $MVOWA_{\mathbf{w}}$ la MVOWA amb vector de ponderacions $\mathbf{w}$ determinat per $\text{orness}(MVOWA_{\mathbf{w}}) = \alpha$ on $\alpha \in \left(0, \frac{1}{2}\right)$. Llavors resulta que $\tilde{\alpha} = 1 - \alpha \in \left(\frac{1}{2}, 1\right)$ i $\tilde{\mathbf{w}} = \mathbf{w}_d$, on $\mathbf{w}_d$ és el vector de ponderacions revers de $\mathbf{w}$.

Demostració. Anàloga a la demostració de la proposició 2.8, considerant la MVOWA en comptes de la MEOWA, i la propietat de la variància i de la proposició 2.11 en comptes de la propietat de l'entropia i de la proposició 2.5.

□

Ja es tenen les MVOWAs per $\alpha = 0$, $\alpha = 1$ i $\alpha = \frac{1}{2}$, i com trobar les que tenen $\alpha \in \left(\frac{1}{2}, 1\right)$. A continuació es demostra l'expressió dels vectors de ponderacions de les MVOWAs amb $\alpha \in \left(0, \frac{1}{2}\right)$.

Proposició 2.14. La solució del problema d'optimització plantejat a la definició 2.3.20 subjecte a $\alpha \in (0, \frac{1}{2})$ ve donada pel vector $\mathbf{w} = (0, \dots, 0, w_r, \dots, w_n)$, és a dir,

$$w_j = 0, \quad j < r, \quad (2.6)$$

$$w_r = \frac{6(n-1)\alpha - 2(n-r-1)}{(n-r+1)(n-r+2)}, \quad (2.7)$$

$$w_n = \frac{2(2n-2r+1) - 6(n-1)\alpha}{(n-r+1)(n-r+2)}, \quad (2.8)$$

i

$$w_j = w_r + \frac{j-r}{n-r}(w_n - w_r), \quad r < j < n, \quad (2.9)$$

on r satisfà les desigualtats

$$n - 3(n-1)\alpha - 1 < r \leq n - 3(n-1)\alpha. \quad (2.10)$$

Demostració. La demostració d'aquesta proposició, amb tots els detalls, es pot consultar a l'apèndix A.5. $\square$

Fins ara s'han considerat OWAs construïdes a partir de certs criteris que s'havien de complir, però de vegades no cal que es satisfacin tots els criteris, sinó una porció d'aquests. S'introdueixen així els quantificadors lingüístics, funcions que es defineixen a continuació i que permeten representar conceptes difusos com “per a tot”, “existeix”, “identitat”, “la majoria”, “almenys la meitat” o “tants com sigui possible”.

Definició 2.3.21 (Funció BUM). Les funcions monòtones contínues, també conegudes com funcions monòtones d'interval unitat bàsiques o *Basic Unit-interval Monotone* (BUM) en anglès, són les que satisfan

$$Q : [0, 1] \rightarrow [0, 1], \quad Q(0) = 0, Q(1) = 1.$$

Definició 2.3.22 (Quantificador RIM). Donada una funció BUM Q , aquesta s'anomena quantificador monòton creixent regular o *Regular Increasing Monotone* (RIM) en anglès si satisfà

$$x > y \Rightarrow Q(x) \geq Q(y).$$

Alguns d'aquests quantificadors es poden expressar com

$$Q_{a,b}(t) = \begin{cases} 0, & \text{si } t \leq a, \\ \frac{t-a}{b-a}, & \text{si } a < t < b, \\ 1, & \text{si } t \geq b, \end{cases}$$

on $Q(t)$ representa fins a quin punt el valor t satisfà el concepte difús que representa el quantificador, i permeten expressar els conceptes anteriors com segueix:

- “per a tot”: $Q_{\text{per a tot}}(t) = 0$ per a tot $t \in [0, 1)$ i $Q_{\text{per a tot}}(1) = 1$,
- “existeix”: $Q_{\text{existeix}}(0) = 0$ i $Q_{\text{existeix}}(t) = 1$ per a tot $t \in (0, 1]$,
- “identitat”: $Q_{\text{Id}}(t) = Q_{0,1}(t) = t$,

- “la majoria”: $Q_{0.3,0.8}(t)$,
- “almenys la meitat”: $Q_{0,0.5}(t)$,
- “tants com sigui possible”: $Q_{0.5,1}(t)$.

També existeixen els quantificadors monòtons decreixents regulars, *Regular Decreasing Monotone* (RDM) en anglès, i els quantificadors unimodals regulars, *Regular UniModal* (RUM) en anglès. En aquest treball només s’empren els RIM, però es pot ampliar la informació a [11, 17, 18]. És en aquestes referències on Yager introdueix les noves OWAs basades en quantificadors lingüístics, de forma que les ponderacions donades per qualsevol n es calculen amb

$$w_i = Q\left(\frac{i}{n}\right) - Q\left(\frac{i-1}{n}\right).$$

De fet, les OWAs que corresponen als tres primers quantificadors ja s’han explicat:

- “per a tot”: $\mathbf{w} = (0, 0, \dots, 0, 1)$, $OWA_{\mathbf{w}} = \min$,
- “existeix”: $\mathbf{w} = (1, 0, 0, \dots, 0)$, $OWA_{\mathbf{w}} = \max$,
- “identitat”: $\mathbf{w} = (\frac{1}{n}, \dots, \frac{1}{n})$, $OWA_{\mathbf{w}} = \text{mean}$.

2.4 Mètriques d’avaluació

Una vegada vists els fonaments necessaris per entendre els mètodes de segmentació i les funcions d’agregació, hi haurà algorismes dels quals s’hauran d’obtenir paràmetres que optimitzin el seu funcionament, i serà necessari poder comparar dos o més processos per decidir quin és millor amb l’aplicació dels contrastos d’hipòtesi que es veuran a la secció 2.5. Ambdues accions es realitzaran fent ús de les mètriques d’avaluació que s’expliquen a continuació, i al capítol dels resultats experimentals 4 s’especificarà quan i com s’han emprat. Mencionar a més que aquestes mètriques no són exclusives del nostre problema, sinó que s’han escollit per la seva aparició en la literatura referent a qüestions de classificació [5, 19].

Siguin $A \in \mathcal{M}_{M \times N}(U)$ una imatge binària amb valors que es consideren certs i $B \in \mathcal{M}_{M \times N}(U)$ una altra imatge binària amb valors que representen una predicció, on un píxel blanc és positiu i un de negre negatiu. Es defineixen els següents conceptes, necessaris per entendre les mètriques.

- Verdaders positius, *True Positives* (TP) en anglès: nombre de píxels positius de B que també són positius a A , definit com $TP(A, B) = \sum_{r=1}^M \sum_{c=1}^N 1_{\{A(r,c)=1, B(r,c)=1\}}$.
- Verdaders negatius, *True Negatives* (TN) en anglès: nombre de píxels negatius de B que també són negatius a A , definit com $TN(A, B) = \sum_{r=1}^M \sum_{c=1}^N 1_{\{A(r,c)=0, B(r,c)=0\}}$.
- Falsos positius, *False Positives* (FP) en anglès: nombre total de píxels positius de B que són negatius a A , definit com $FP(A, B) = \sum_{r=1}^M \sum_{c=1}^N 1_{\{A(r,c)=0, B(r,c)=1\}}$.
- Falsos negatius, *False Negatives* (FN) en anglès: nombre total de píxels negatius de B que són positius a A , definit com $FN(A, B) = \sum_{r=1}^M \sum_{c=1}^N 1_{\{A(r,c)=1, B(r,c)=0\}}$.

Es poden introduir així les mètriques següents: la intersecció sobre unió (IoU), la raó de falsos positius (FPR), el valor predictiu positiu (PPV), l'exactitud (ACC), la taxa de veritables positius (TPR) i, finalment, la corba ROC.

2.4.1 IoU

També conegut com índex de Jaccard, la raó d'intersecció sobre unió, *Intersection over Union* (IoU) en anglès, mesura la proporció entre píxels positius encertats i la totalitat de píxels marcats com a positius, és a dir, els que són veritaderament positius més els predits a com positius. És la mètrica més emprada per calcular la similitud entre les imatges reals i les predites en problemes de classificació binària, ja que l'objectiu d'aquests és fer que es reconguin com a tals el major nombre de píxels positius possible. La seva fórmula és

$$IoU(A, B) = \frac{TP(A, B)}{TP(A, B) + FN(A, B) + FP(A, B)}.$$

Valors pròxims a 1 indiquen un rendiment òptim de la segmentació (o algorisme), mentre que valors pròxims a 0 signifiquen que la segmentació és deficient.

2.4.2 FPR

El rati de falsos positius, *False Positive Ratio* (FPR) en anglès, mesura la proporció de resultats que s'identifiquen incorrectament com a positius quan en realitat haurien de ser negatius. És un índex rellevant dins el camp clínic ja que sol ser prioritari detectar el major nombre de casos positius reals per fer-ne els tractaments o seguiments necessaris. La seva fórmula és

$$FPR(A, B) = \frac{FP(A, B)}{FP(A, B) + TN(A, B)}.$$

S'espera que el valor sigui tan baix com sigui possible.

2.4.3 PPV

El valor predictiu positiu, *Positive Predictive Value* (PPV) en anglès, mesura la precisió de la imatge de valors predits, donant la proporció de positius certs sobre els positius obtinguts. És a dir, aquest índex indica quina part dels positius obtinguts és realment positiva. La seva fórmula és

$$PPV(A, B) = \frac{TP(A, B)}{TP(A, B) + FP(A, B)}.$$

Un valor proper a 1 és indicador d'un bon rendiment de l'algorisme considerat.

2.4.4 ACC

L'exactitud, *Accuracy* (ACC) en anglès, mesura com de propera és la imatge predita a la imatge real, calculant la proporció de valors encertats respecte del total. La seva fórmula és

$$ACC(A, B) = \frac{TP(A, B) + TN(A, B)}{TP(A, B) + TN(A, B) + FP(A, B) + FN(A, B)}.$$

S'espera un valor el més proper a 1 possible.

2.4.5 TPR

La sensibilitat o taxa de veritables positius, *True Positive Rate* (TPR) en anglès, és la proporció de casos positius que el model classifica correctament. Aquesta mesura indica, doncs, la possibilitat que s'encertin la totalitat de valors reals positius. La seva fórmula és

$$TPR(A, B) = \frac{TP(A, B)}{TP(A, B) + FN(A, B)}.$$

Com més a prop d'1 sigui el seu valor, millor es classifiquen els casos positius i menor és el nombre de falsos negatius.

2.4.6 ROC

S'empra la corba característica operativa del receptor, ROC en anglès, per estudiar el llindar de decisió que separa les dues classes en problemes de classificació binària. Com s'ha dit, s'explicaran més endavant els detalls de quan, com i per què s'empra aquest gràfic. Aquí interessa entendre que, per a valors diferents del llindar s'obtenen diferents valors dels TP, TN, FP i FN. Aquesta corba dibuixa, doncs, els punts de coordenades

$$(FPR(A, B), TPR(A, B))$$

per a cada valor del llindar, on FPR i TPR són les mètriques que s'acaben d'explicar.

Es tanca la secció destacant que, tot i que les decisions pertinents es basaran en aquests valors quantitius, també es corroboraran simultàniament les dades amb el seu aspecte qualitatiu, és a dir, la visualització de les imatges digitals que es retornin en cada cas.

2.5 Contrastos d'hipòtesi

Com s'ha comentat, l'objecte d'estudi principal és trobar el millor –o millors en cas de no ser únic– procés de segmentació de tots els aplicats en aquest treball. Les conclusions finals es recolzaran en les evidències estadístiques obtingudes amb els contrastos d'hipòtesi, basats en el contingut de [20].

Donats n processos de segmentació $P_1, \dots, P_n$, es vol saber per a cada $i = 1, \dots, n$ quina de les dues hipòtesis següents és certa:

$$\begin{cases} H_0: \exists j \neq i \text{ tal que } P_i \text{ és pitjor o igual que } P_j, \\ H_1: P_i \text{ és millor que } P_j \quad \forall j \neq i. \end{cases}$$

A les seccions 3.6 i 4.2 es detallarà el procediment complet per arribar a la resposta final. Però l'estudi s'iniciarà sempre amb el següent raonament estadístic.

En cas de comparar-se més d'un procés $P_1, \dots, P_n$, amb mitjanes i desviacions típiques poblacionals μ_i i σ_i , per $i = 1, \dots, n$, s'ha de comprovar si n'hi almenys un de diferent amb un contrast d'igualtat de mitjanes de la mètrica d'avaluació escollida. Per saber si es pot aplicar un ANOVA, s'han d'estudiar la normalitat i l'homoscedasticitat.

Per la normalitat, s'aplica el test de Shapiro-Wilk a cada $i = 1, \dots, n$ per contrastar

$$\begin{cases} H_0: \mu_i \text{ prové d'una distribució normal,} \\ H_1: \mu_i \text{ no prové d'una distribució normal.} \end{cases}$$

Si $p\text{-valor} > 0,1/n$ s'acceptarà H_0 , si $p\text{-valor} < 0,05/n$ hi haurà evidències suficients per rebutjar H_0 i acceptar H_1 . Per la resta de contrastos mencionats a aquesta secció, la decisió es pren amb els següents criteris:

- si $p\text{-valor} > 0,1$ s'acceptarà H_0 ,
- si $p\text{-valor} < 0,05$ hi haurà evidències suficients per rebutjar H_0 i acceptar H_1 .

Pels p -valors que no satisfacin cap de les condicions anteriors els tests no decidiran, ja que seran valors de la zona de penombra, i es prendran les decisions visualitzant els diagrames de caixes pertinents.

Per l'homoscedasticitat, en cas que totes les μ_i per $i = 1, \dots, n$ provinguin de distribucions normals es realitzarà el contrast d'igualtat de variàncies amb el test de Bartlett, i en cas contrari amb el test de Levene [21],

$$\begin{cases} H_0: \sigma_1 = \dots = \sigma_n, \\ H_1: \exists i \neq j \text{ tal que } \sigma_i \neq \sigma_j. \end{cases}$$

Quan es satisfacin les condicions de normalitat i homoscedasticitat, això és, quan per tota $i = 1, \dots, n$ μ_i provengui d'una distribució normal i quan $\sigma_1 = \dots = \sigma_n$, el contrast d'igualtat de més de dues mitjanes es realitzarà amb un ANOVA, i en cas contrari amb el test de Kruskal-Wallis,

$$\begin{cases} H_0: \mu_1 = \dots = \mu_n, \\ H_1: \exists i \neq j \text{ tal que } \mu_i \neq \mu_j. \end{cases}$$

En cas de no obtenir evidències per rebutjar la hipòtesi nul·la, es finalitza l'estudi. D'obtenir evidències que sí fan rebutjar la igualtat de totes les mitjanes, s'estudia llavors la igualtat de mitjanes per a cada parell, és a dir, el contrast

$$\begin{cases} H_0: \mu_i = \mu_j, \\ H_1: \mu_i \neq \mu_j, \end{cases}$$

per a cada $i < j$. Els resultats estadístics de tots els parells s'obtenen de cop amb el test t per parelles amb ajust de Bonferroni, en cas de satisfer-se les condicions de normalitat i homoscedasticitat, o amb el test de Mann-Whitney per parelles amb ajust de Bonferroni, en cas contrari, especificant en ambdós casos que les mostres són aparellades.

Una vegada realitzats els contrastos que involucren els n processos en conjunt, es duen a terme les comparacions dels processos dos a dos.

Considerats dos processos P_i, P_j i mantenint la mètrica d'avaluació escollida, es satisfà la condició de normalitat si μ_i i μ_j provenen de distribucions normals, contrastat amb el test de normalitat de Shapiro-Wilk però ara prenent la decisió amb el criteri dels p -valors no ajustats.

En cas de satisfer-se la condició de normalitat, els contrastos d'igualtat i diferència de variàncies es realitzen amb el test F , indicant sempre mostres aparellades i especificant l'alternativa en cas de ser necessari. Per la igualtat es realitza el contrast

$$\begin{cases} H_0: \sigma_i = \sigma_j, \\ H_1: \sigma_i \neq \sigma_j, \end{cases}$$

i en cas de concloure que són no iguals, es realitza un dels dos contrastos de diferència de variàncies

$$\begin{cases} H_0: \sigma_i \leq \sigma_j, \\ H_1: \sigma_i > \sigma_j, \end{cases} \quad \text{o} \quad \begin{cases} H_0: \sigma_i \geq \sigma_j, \\ H_1: \sigma_i < \sigma_j, \end{cases}$$

que s'escull en funció de la relació entre les variàncies mostrals: el contrast de l'esquerra si $s_i > s_j$ i el de la dreta si $s_i < s_j$. De no satisfer-se la condició de normalitat, el contrast d'igualtat es realitza amb el test de Fligner-Killeen, i el contrast de diferència es decideix visualitzant els diagrames de caixes.

Pel que fa a les mitjanes, com ja s'han realitzat els contrastos d'igualtat de tots els parells de mitjanes, només quedaria fer els contrastos de diferència de mitjanes. Indicant sempre mostres aparellades i l'alternativa que correspongui, es realitzarà un dels dos contrastos

$$\begin{cases} H_0: \mu_i \leq \mu_j, \\ H_1: \mu_i > \mu_j, \end{cases} \quad \text{o} \quad \begin{cases} H_0: \mu_i \geq \mu_j, \\ H_1: \mu_i < \mu_j, \end{cases}$$

el de l'esquerra si les mitjanes mostrals satisfan $\overline{X}_i > \overline{X}_j$, i el de la dreta si $\overline{X}_i < \overline{X}_j$. En cas de satisfer-se les condicions de normalitat i igualtat de variàncies s'aplica el test t indicant igualtat de variàncies, de satisfer-se només la normalitat s'aplica el test t sense indicar igualtat de variàncies, i en cas contrari s'aplica el test de Wilcoxon.

2.6 Comentaris finals

En aquest capítol s'han treballat tots els conceptes necessaris per entendre el contingut del capítol 3 i les aplicacions que han permès obtenir els resultats que es mostraran al capítol 4.

Explicades a la secció 2.1 les imatges digitals en escala de grisos i binàries, s'ha donat una introducció als mètodes de segmentació, secció 2.2, en escala de grisos i binaris, junt amb conceptes que s'empraran en els mètodes concrets explicats al capítol que segueix 3, com són filtre, convolució, element estructurant i operacions morfològiques.

En la secció 2.3, desenvolupada en profunditat, s'han aportat totes les definicions i tots els resultats que s'han trobat pertinents per entendre les funcions d'agregació especificades. De fet, s'han presentat i estudiat totes les que s'aplicaran, junt amb conceptes a destacar com vector de graus de pertinença, vector de ponderacions, OWA, mesura orness d'una OWA, entropia o dispersió de ponderacions, variància de ponderacions, i quantificadors lingüístics. A la secció 3.5 es llistaran les funcions d'agregació que s'aplicaran a les segmentacions en escala de grisos.

Finalment, a la secció 2.4, s'han introduït les mètriques d'avaluació que s'empraran al llarg del procés experimental –IoU, FPR, PPV, ACC, TPR, ROC– formulades a partir dels valors TP, TN, FP, FN, i es detallen a la secció 2.5 tots els contrastos que es realitzaran –de normalitat, d'igualtat i diferència de diverses o dues variàncies, i d'igualtat i diferència de varies o dues mitjanes–.

PROCÉS DE SEGMENTACIÓ I AGREGACIÓ

En aquest capítol s'expliquen tots els detalls tècnics i els processos concrets que es duen a terme per a la realització del TFG aplicat: es descriu la base de dades a treballar a la secció 3.1, les eines que s'han fet servir per a tal fi a la secció 3.2, els mètodes de segmentació en escala de grisos, secció 3.3, i binaris, secció 3.4, que s'executen, i les funcions d'agregació específiques que s'apliquen per combinar aquests mètodes es llisten a la secció 3.5, amb una visió global del capítol i la successió de processos que es duen a terme per la seva aplicació, secció 3.6. Es disposa d'un repositori de GitHub¹ amb el total de les imatges treballades i la implementació de tots els processos especificats a aquest capítol.

3.1 Base de dades

Per realitzar aquest treball es disposa d'un conjunt de 60 angiografies oculars, de les quals es té la segmentació binària realitzada manualment per un especialista i que es consideren imatges de veritat fonamental. D'aquestes, 20 són de la base de dades STARE [22] i 40 de DRIVE [4].

Les imatges de STARE, són de 700×605 píxels i 24 bits per píxel a color estàndard RGB. De les 20 imatges, 10 són de pacients sense cap patologia, és a dir, angiografies que es consideren normals, i les 10 restants presenten anomalies conseqüència de patologies que enfosqueixen o confonen l'aparença dels vasos sanguinis en diferents parts de la imatge. El camp de visió d'aquestes imatges és circular amb un diàmetre d'aproximadament 650 píxels i retallades per dalt i per baix, amb una altura resultant d'uns 550 píxels.

Les imatges de DRIVE, de 565×584 píxels (les originals eren de 768×584 píxels) i 8 bits per píxel també són a color estàndard RGB. Les 40 imatges són de pacients diabètics

¹ Es pot accedir al repositori de GitHub mitjançant l'enllaç <https://github.com/sintygc/mathematics-TFG-retinal-vessel-segmentation-aggregation>.

d'entre 25 i 90 anys, 33 de les quals no tenen cap signe de retinopatia diabètica i 7 en mostren els primers indicis. El camp de visió és circular d'aproximadament 540 píxels de diàmetre.

Es guarden totes les imatges originals i les de veritat de referència, les 40 primeres de DRIVE i les 20 darreres de STARE. Es divideixen aleatòriament en dos conjunts: el 75% d'imatges són d'entrenament, que s'empren per configurar el flux de models i per ajustar els seus paràmetres, i el 25% restant són de prova, per avaluar objectivament la bondat de la segmentació dels algorismes proposats en un conjunt d'imatges independent. Aquests percentatges s'apliquen també a cada base de dades font, que correspon a 30 imatges de DRIVE i 15 de STARE resultant en 45 imatges d'entrenament, i la resta formen el conjunt de prova. En concret i amb les imatges numerades de l'1 al 60 en l'ordre mencionat a principi de paràgraf, el conjunt de prova el formen les imatges 8, 10, 13, 17, 18, 20, 30, 36, 37, 39, 47, 49, 52, 56 i 57, i la resta componen el conjunt d'entrenament.

Pel que fa als trets visuals de les angiografies, els mencionats a continuació són clau per entendre el per què dels mètodes escollits: la zona fora del camp de visió és negra; destaca el disc òptic de forma circular de color més clar i lluminós; els vasos sanguinis són estructures filamentosos amb origen al disc òptic que es ramifiquen i bifurquen tortuosament en filaments cada vegada més primos, d'un color més fosc que el fons ocular; la gamma de colors principal és ataronjada; i no es considera pertinent descriure visualment les patologies, ja que l'únic que interessa és saber que alteren de qualsevol forma les anteriors característiques. La figura 3.1 conté una mostra visual de la base de dades. L'objectiu serà que les regions blanques de les segmentacions binàries i les regions més clares de les segmentacions en escala de grisos corresponguin precisament als vasos sanguinis, com s'observa a les imatges de veritat fonamental. Per ser els mètodes inexactes, es caracteritzen aquestes zones com regions de no fons, i la resta com regions de fons.




Figura 3.1: Mostra d'angiografies oculars originals de la base de dades junt amb la seva segmentació binària de veritat fonamental: (a) imatge de DRIVE sense patologies, (b) imatge de DRIVE amb patologies, (c) imatge de STARE sense patologies, (d) imatge de STARE amb patologies.

3.2 Especificacions tècniques

Per al processament d'imatges s'empra el programa Matlab, que requereix els paquets *Image Processing Toolbox* per emprar funcions com `rgb2gray`, `graythresh`, *Signal Processing Toolbox* per la funció `findpeaks`, i *Statistics and Machine Learning Toolbox* per la funció `perfcurve`. S'unifica que a l'inici de tot processament es converteixi la imatge a classe `double`.

Tots els contrastos d'hipòtesis es calculen amb el programa RStudio, prenent com a resultats taules de dades calculades amb Matlab.

3.3 Mètodes de segmentació

A continuació s'expliquen breument els 11 mètodes de segmentació sota estudi. Per facilitar la distinció, s'ha establert que l'identificador de cada mètode sigui el terme "Segm" seguit de l'any i llinatge de l'autor o autors principals de l'article on es va publicar.

Tots els mètodes s'apliquen a una imatge a color RGB i retornen imatges binàries I_{BW} . De fet, cada segmentació és el resultat de combinar un mètode de segmentació en escala de grisos amb un mètode de segmentació binària,

$$Segm(I) = SegmBW(SegmG(I)) = I_{BW}$$

on $SegmG(I) = I_G$.

Més endavant, a la figura 3.2, s'inclou una comparació visual de les segmentacions en escala de grisos i les segmentacions finals binàries de cada mètode per a una mateixa angiografia ocular.

Per aprofundir en els conceptes que s'esmenten es pot referir al capítol 2 i als articles citats a cada subsecció, i dels mètodes que ho han requerit s'han obtingut els valors de certs paràmetres especificats al capítol 4.

3.3.1 Mètode de segmentació de Chaudhuri et al. (Segm1989Chaudhuri)

Basat en l'algorisme explicat a [1], s'inicia el mètode amb la imatge I_1 obtinguda del canal verd $I_0 = G(I)$ i descartant-li com a vasos sanguinis píxels amb intensitats molt baixes. La imatge I_2 és la convolució del filtre

$$F = H_M(5) = \mathcal{M}_{5 \times 5}(0.04)$$

sobre I_1 , és a dir,

$$i_2(r, c) = (F * I_1)(r, c) = 0.04 \sum_{s=1}^5 \sum_{t=1}^5 i_1(r-s+1, c-t+1)$$

per $r \in \{1, \dots, M\}$ i $c \in \{1, \dots, N\}$.

A continuació s'obtenen 12 convolucions de I_2 , cada una partint d'una màscara definida per Chaudhuri i aplicada amb una rotació de 15° respecte de l'anterior. Siguin $\sigma = 2$ i $L = 9$, la màscara és la matriu $K' \in \mathcal{M}_{L \times (2 \cdot 3\sigma + 1)}$ on cada element ve donat per

$$k'(x, y) = k(x, y) - m,$$

on

$$k(x, y) = -\exp\left(-\frac{u_x^2}{2\sigma^2}\right)$$

per $-3 \cdot \sigma \leq u_x \leq 3 \cdot \sigma$, $u_x \in \mathbb{Z}$, i

$$m = \frac{1}{L(2 \cdot 3\sigma + 1)} \sum_{y=1}^L \sum_{x=1}^{2 \cdot 3\sigma + 1} k(x, y).$$

Siguin doncs IC_i per $i = 1, \dots, 12$ les 12 convolucions obtingudes, la imatge en escala de grisos resultant és la imatge I_G on la intensitat de cada píxel ve donada per

$$i_g(r, c) = \max_{i=1, \dots, 12} \{i c_i(r, c)\}$$

escalada al rang d'intensitats $[0, 1]$.

S'obté la segmentació d'aquest mètode com la imatge binària I_{BW} resultant d'aplicar la binarització d'Otsu (es detalla a la subsecció 3.4.1) a la segmentació en escala de grisos I_G .

3.3.2 Mètode de segmentació de Zana i Klein (Segm2001ZanaKlein)

Aquest mètode extret de l'article [3] i que inclou els detalls de les funcions que es mencionen a continuació, aplica morfologia matemàtica a angiografies fetes amb fluoresceïna, on els vasos són més clars que el fons ocular. És per això que la imatge en escala de grisos de la qual es parteix és $I_0 = \text{inv}(CG(I))$.

Donat un element estructurant de línia L_1 de longitud $k + 4$, es consideren els elements estructurants L_i on cada un és L_1 rotat $(i - 1)15^\circ$. Així doncs, la segmentació en escala de grisos I_G d'aquest mètode es calcula seguint l'algorisme

$$\begin{aligned} I_{op} &= \gamma_{I_0}^{rec}(\max_{i=1, \dots, 12} \{\gamma_{L_i}(I_0)\}), \\ I_{sum} &= \sum_{i=1}^{12} (I_{op} - \gamma_{L_i}(I_0)), \\ I_{lap} &= \text{Laplacian}(\text{Gaussian}_{7/4}^7(I_{sum})), \\ I_1 &= \gamma_{I_{lap}}^{rec}(\max_{i=1, \dots, 12} \{\gamma_{L_i}(I_{lap})\}), \\ I_2 &= \phi_{I_1}^{rec}(\min_{i=1, \dots, 12} \{\phi_{L_i}(I_1)\}), \\ I_G &= \text{inv}(\max_{i=1, \dots, 12} \{\gamma_{L_i}^2(I_2)\}), \end{aligned}$$

amb les funcions *Laplacian* i *Gaussian* detallades a l'article de referència. Finalment, la segmentació binària I_{BW} obtinguda a partir del llindar th obtingut experimentalment, té intensitats a cada píxel donades per

$$i_{BW}(r, c) = \begin{cases} 1 & \text{si } i_G(r, c) \geq th, \\ 0 & \text{en cas contrari.} \end{cases}$$

3.3.3 Mètode de segmentació de Heneghan et al. (Segm2002Heneghan)

També partint d'angiografies de fluoresceïna, aquest mètode [23] s'inicia amb la imatge en escala de grisos $I_0 = \text{inv}(G(I))$ i aplica operacions de morfologia matemàtica.

Es realitza un primer tractament de la imatge creant la màscara M_I a partir del llindar M fixat experimentalment, on

$$m_I(r, c) = \begin{cases} 1 & \text{si } i(r, c) > M, \\ 0 & \text{en cas contrari.} \end{cases}$$

Aplicant aquesta màscara a I_0 es descarten tots els píxels amb $m(r, c) = 0$ com a possibles vasos sanguinis resultant en la imatge I_n . Considerant ara l'element estructurant de línia L_1 de longitud 17 píxels i els filtres $F_G = H_G(1, 7, 1, 75)$ i $F_L = H_L(1, 7, 1, 75)$, es construeixen els elements estructurants L_i , $F_{G,i}$ i $F_{L,i}$ on cada un és respectivament L_1 , F_G i F_L rotats $(i - 1)15^\circ$, i s'obté la segmentació en escala de grisos I_G amb l'algorisme

$$\begin{aligned} I_v &= \gamma_{I_n}^{rec}(\max_{i=1,\dots,12} \{\gamma_{L_i}(I_n)\}) - \min_{i=1,\dots,12} \{\gamma_{L_i}(I_n)\}, \\ I_d &= \max_{i=1,\dots,12} \{(I_v * F_{G,i}) * F_{L,i}\}, \\ I_{diff} &\text{ on } i_{diff}(r, c) = \begin{cases} i_d(r, c) & \text{si } i_d(r, c) > 0, \\ 0 & \text{en cas contrari,} \end{cases} \\ I_b &= \gamma_{I_{diff}}^{rec}(\max_{i=1,\dots,12} \{\gamma_{L_i}(I_{diff})\}), \\ I_G &= \phi_{I_b}^{rec}(\min_{i=1,\dots,12} \{\phi_{L_i}(I_b)\}). \end{aligned}$$

Finalment s'obté la segmentació binària I_{BW} per histèresi de I_G amb els llindars $T_{inf} = 25/255$ i $T_{sup} = 40/255$. Siguin les imatges binàries I_{inf} i I_{sup} definides per

$$\begin{aligned} i_{inf}(r, c) &= \begin{cases} 1 & \text{si } i_G(r, c) > T_{inf}, \\ 0 & \text{si } i_G(r, c) \leq T_{inf}, \end{cases} \\ i_{sup}(r, c) &= \begin{cases} 1 & \text{si } i_G(r, c) > T_{sup}, \\ 0 & \text{si } i_G(r, c) \leq T_{sup}, \end{cases} \end{aligned}$$

es calcula sobre

$$I_h = \gamma_{I_{inf}}^{rec}(I_{sup})$$

la imatge I_{reg} on el valor de cada píxel representa la mida de la regió connectada a la qual pertany. Així doncs es determinen com a regions de no fons totes les que connecten més de 170 píxels, és a dir, la imatge I_{BW} té intensitats donades per

$$i_{BW}(r, c) = \begin{cases} 1 & \text{si } i_{reg}(r, c) > 170, \\ 0 & \text{si } i_{reg}(r, c) \leq 170. \end{cases}$$

3.3.4 Mètode de Chanwimaluang (Segm2003Chanwimaluang)

Seguint les indicacions de [24], aquest mètode comença destacant les intensitats del canal verd a la imatge en escala de grisos $I_0 = CG(I_V)$ on I_V té $IR = (0)$, $IG = IG$ i $IB = (0)$. Del filtre $F_1 \in \mathcal{M}_{9 \times 13}(U)$ que s'aproxima al laplacà de Gauss amb valors donats per

$$f_1(p, q) = -\exp\left(\frac{p^2}{2\sigma^2}\right)$$

i $\sigma = 2$, s'obtenen les 12 rotacions on F_i és F_1 rotat $(i - 1)15^\circ$, i es calcula la imatge en escala de grisos

$$I_G = \max_{i=1,\dots,12} \{I_0 * F_i\}.$$

Donada una màscara binària M de valors a cada píxel

$$m(r, c) = \begin{cases} 1 & \text{si } CG(i(r, c)) > 45/225, \\ 0 & \text{en cas contrari,} \end{cases}$$

i un llindar T , basat en l'entropia local el valor del qual s'obté amb els càlculs detallats en profunditat a l'article citat, es determina una primera imatge binària I_b d'intensitats

$$i_b(r, c) = \begin{cases} 1 & \text{si } m(r, c) = 1 \text{ i } i_G(r, c) \geq T, \\ 0 & \text{en cas contrari.} \end{cases}$$

Sigui I_{reg} la imatge on el valor de cada píxel representa la mida de la regió connectada de I_b a la que pertany, la segmentació binària I_{BW} final s'obté eliminant les regions de menys de 950 píxels,

$$i_{BW}(r, c) = \begin{cases} i_b(r, c) & \text{si } i_{reg}(r, c) > 950, \\ 0 & \text{en cas contrari.} \end{cases}$$

3.3.5 Mètode de segmentació de Zapater et al. (Segm2005Zapater)

Partint del procés especificat a [25], s'aplica el mètode de Zana i Klein (explicat a la subsecció 3.3.2) amb l'element estructurant de 21 mides diferents. La segmentació en escala de grisos final s'obté al fer la mitjana de les imatges binàries obtingudes amb cada element estructurant, i un llindar determina com píxels de no fons els que el superen en intensitat.

Sigui $I_0 = inv(CG(I))$ la imatge en escala de grisos de la que es parteix, s'obtenen les imatges binàries I_k per $k = 1, \dots, 21$, on cada I_k és el resultat binari de **Segm2001ZanaKlein** per l'element estructurant de línia L_k de longitud $k + 4$ amb llindar de binarització aplicat th_k . Així doncs, la segmentació en escala de grisos d'aquest mètode és

$$I_G = \frac{1}{21} \sum_{k=1}^{21} I_k.$$

I les intensitats de la segmentació binària, on el llindar T s'ha fixat experimentalment, venen donades per

$$i_{BW}(r, c) = \begin{cases} 1 & \text{si } i_G(r, c) \geq T, \\ 0 & \text{en cas contrari.} \end{cases}$$

3.3.6 Mètode GMM de Soares et al. (Segm2008SoaresGMM)

Aquest mètode extret de [26] es basa en la classificació supervisada, això és, determinar un conjunt base amb certes característiques extretes a partir del qual es determina un classificador que permet decidir si cada píxel de les noves imatges a segmentar és un vas sanguini o no.

De les 45 imatges d'entrenament se'n determinen les següents característiques: la màscara que correspon a l'àrea fora del camp de visió, una ampliació del canal verd invertit del camp de visió, i cada imatge resultant d'aplicar a la transformada de Fourier d'aquesta ampliació la transformada de *wavelet* de Morlet en 2D (article [26]) per 4

longituds diferents. En funció de l'etiqueta corresponent a les imatges de veritat es crea una mostra aleatòria $\mathbf{x}$ de les característiques de M píxels de manera proporcionada entre totes les imatges, i es calculen la mitjana i desviació típica globals dels valors de les seves característiques excepte la màscara.

Una vegada obtinguda la mostra, s'entrena el model de mescla gaussiana o *Gaussian Mixture Model* (GMM) en anglès: es calculen les probabilitats a priori de les classes V ser vas sanguini i $\bar{V}$ no ser vas sanguini,

$$P(V) = \frac{\text{nombre de píxels de vasos sanguinis}}{\text{nombre de píxels total}},$$

$$P(\bar{V}) = \frac{\text{nombre de píxels de no vasos sanguinis}}{\text{nombre de píxels total}},$$

i les probabilitats posteriors de que cada submostra $\mathbf{x}_V$ dels píxels que són vas sanguini i $\mathbf{x}_{\bar{V}}$ dels píxels que no són vas sanguini pertanyin a cada una de les $i = 1, \dots, 20$ gaussianes,

$$P(\text{gaussiana}_i | \mathbf{x}_V) = \frac{P(\mathbf{x}_V | \text{gaussiana}_i) \cdot P(\text{gaussiana}_i)}{\sum_{j=1}^{20} P(\mathbf{x}_V | \text{gaussiana}_j) \cdot P(\text{gaussiana}_j)},$$

$$P(\text{gaussiana}_i | \mathbf{x}_{\bar{V}}) = \frac{P(\mathbf{x}_{\bar{V}} | \text{gaussiana}_i) \cdot P(\text{gaussiana}_i)}{\sum_{j=1}^{20} P(\mathbf{x}_{\bar{V}} | \text{gaussiana}_j) \cdot P(\text{gaussiana}_j)},$$

que permeten obtenir els pesos, $\omega_{V,i}$, $\omega_{\bar{V},i}$, mitjanes, $\mu_{V,i}$, $\mu_{\bar{V},i}$, i matrius de covariància, $\Sigma_{V,i}$, $\Sigma_{\bar{V},i}$, de cada classe i gaussiana.

Entrenat el model i considerada la imatge I amb les probabilitats que un píxel i_{rc} sigui o no vas sanguini,

$$P(i_{rc} | V) = \sum_{k=1}^{20} \omega_{V,k} \cdot \mathcal{N}(i_{rc} | \mu_{V,k}, \Sigma_{V,k}),$$

$$P(i_{rc} | \bar{V}) = \sum_{k=1}^{20} \omega_{\bar{V},k} \cdot \mathcal{N}(i_{rc} | \mu_{\bar{V},k}, \Sigma_{\bar{V},k}),$$

per

$$\mathcal{N}(i_{rc} | \mu, \Sigma) = \frac{1}{\sqrt{(2\pi)^{20} |\Sigma|}} \exp\left(-\frac{1}{2}(\mathbf{X}_{rc} - \mu)^T \Sigma^{-1}(\mathbf{X}_{rc} - \mu)\right),$$

on $\mathbf{X}_{rc}$ és el vector de característiques (valors de la transformada de Fourier i les 4 de Morlet) del píxel corresponent, s'obté la segmentació en escala de grisos I_G on la intensitat de cada píxel ve donada per

$$i_G(r, c) = P(V | i_{rc}) = \frac{P(i_{rc} | V) \cdot P(V)}{P(i_{rc} | V) \cdot P(V) + P(i_{rc} | \bar{V}) \cdot P(\bar{V})}.$$

Finalment es calcula la segmentació binària I_{BW} partint d'un llindar,

$$i_{BW}(r, c) = \begin{cases} 1 & \text{si } i_G(r, c) > 0.5, \\ 0 & \text{en cas contrari.} \end{cases}$$

Per a més detalls i especificacions del procés referir-se a l'article [26].

3.3.7 Mètode KNN de Soares et al. (Segm2008SoaresKNN)

Tot i que aquest mètode també sorgeix de [26] i es basa en la classificació supervisada, no requereix de més processament d'aprenentatge que extreure les característiques de les 45 imatges d'entrenament. Considerant ara simplement la mostra aleatòria $\mathbf{x}$ de M píxels, per cada píxel de la imatge I es calculen les característiques $\mathbf{X}_{rc}$, i es comparen mitjançant la distància euclidiana amb les característiques dels píxels de tota la mostra per obtenir els $k = 50$ més propers, anomenats veïns. D'aquí, s'obtenen el nom del mètode, k veïns més propers, o *k-Nearest Neighbors* (KNN) en anglès, i la intensitat corresponent a la segmentació en escala de grisos I_G ,

$$i_G(r, c) = \frac{\text{nombre de veïns que són vas sanguini}}{50}.$$

La segmentació binària I_{BW} s'obté calculant les intensitats amb

$$i_{BW}(r, c) = \begin{cases} 1 & \text{si } i_G(r, c) > 0.5, \\ 0 & \text{en cas contrari.} \end{cases}$$

3.3.8 Mètode LMSE de Soares et al. (Segm2008SoaresLMSE)

Aquest mètode extret també de [26] segueix el mateix plantejament que el mètode GMM de Soares de la subsecció 3.3.6. Basat en la classificació supervisada i amb el mateix tractament de la mostra $\mathbf{x}$ de M píxels que el mètode mencionat, s'entrena ara el model de mínim error quadràtic, o *Linear Minimum Squared Error* (LMSE) en anglès, obtenint els valors dels pesos $\mathbf{w}$ i el biaix w_0 que minimitzen la funció d'error quadràtic amb $\mathbf{y}$, els valors corresponents dels píxels de la mostra a la imatge de veritat fonamental,

$$E(\mathbf{w}, w_0) = \sum_{i=1}^M ((\mathbf{w}^T \mathbf{x}_i + w_0) - y_i)^2.$$

La segmentació en escala de grisos I_G s'obté amb les intensitats a cada píxel donades en funció del vector de característiques del píxel corresponent $\mathbf{X}_{rc}$,

$$i_G(r, c) = \mathbf{w}^T \mathbf{X}_{rc} + w_0.$$

I la segmentació binària I_{BW} es calcula amb les intensitats donades per

$$i_{BW}(r, c) = \begin{cases} 1 & \text{si } i_G(r, c) > 0, \\ 0 & \text{en cas contrari.} \end{cases}$$

3.3.9 Mètode de segmentació de Bankhead et al. (Segm2012Bankhead)

Basat en l'article [27], aquest mètode emprà les capes de *Wavelet* que es definiran a continuació i un llindar de binarització que depèn de cada imatge.

Iniciant el processament amb la imatge en escala de grisos $I_0 = G(I)$ i considerat un conjunt J de nivells, que en aquest treball és $J = \{2, 3\}$, es calcula el procés següent pels

valors $j = 1, \dots, \max\{J\}$,

$$\begin{aligned} s_j &= 2^{j-1} - 1, \\ h_j &= \frac{1}{16} (1 \underbrace{0 \dots 0}_{s_j - \text{vegades}} 4 \underbrace{0 \dots 0}_{s_j - \text{vegades}} 6 \underbrace{0 \dots 0}_{s_j - \text{vegades}} 4 \underbrace{0 \dots 0}_{s_j - \text{vegades}} 1), \\ F_j &= h_j^T \cdot h_j, \\ I_j &= I_{j-1} * F_j. \end{aligned}$$

Cada capa de *Wavelet* és

$$W_j = I_{j-1} - I_j,$$

i la segmentació en escala de grisos ve donada com

$$I_G = \text{inv} \left(\sum_{j \in J} W_j \right).$$

La segmentació binària I_{BW} s'obté de calcular les intensitats

$$i_{BW}(r, c) = \begin{cases} 1 & \text{si } i_G(r, c) > T, \\ 0 & \text{en cas contrari,} \end{cases}$$

on T és el llindar calculat perquè es satisfaci que el 20% de píxels de la imatge I_{BW} corresponguin a la regió de no fons.

3.3.10 Mètode d'Azzopardi et al. (Segm2015Azzopardi)

Aquest mètode extret de [28] no sols considera els colors de la imatge, sinó que en té en compte la lluminositat determinada a la matriu I_L a partir de I per calcular la màscara I_M amb les intensitats determinades per

$$i_M(r, c) = \begin{cases} 1 & \text{si } i_L(r, c) \geq 0,5, \\ 0 & \text{en cas contrari.} \end{cases}$$

Aplicant aquesta màscara a la imatge $I_0 = G(I)$ s'obté la imatge I_1 d'intensitats

$$i_1(r, c) = \begin{cases} i_0(r, c) & \text{si } i_M(r, c) = 1, \\ 0 & \text{si } i_M(r, c) = 0, \end{cases}$$

de la qual s'aïlla la regió del camp visual útil de la retina i se'n millora el contrast, obtenint la imatge I_C on els vasos sanguinis estan enfosquits.

A continuació s'apliquen un seguit de filtres anomenats filtres *COmbined Selection of Filter REsponses* (COSFIRE) en anglès, resultats de combinar filtres DoG. Se'n diferencien dues col·leccions: els filtres simètrics F_{Si} , dissenyats per detectar segments de vasos sanguinis que aplicats a I_C resulten en la imatge I_S , i els filtres asimètrics F_{Aj} , per detectar bifurcacions i ramificacions que aplicats també a I_C resulten en la imatge I_A . Normalitzant la imatge

$$I_F = I_S + I_A$$

i aplicant-hi la màscara I_M , es forma la segmentació en escala de grisos I_G .

Per acabar el procés, s'obté la segmentació binària I_{BW} amb les intensitats a cada píxel donades per

$$i_{BW}(r, c) = \begin{cases} 1 & \text{si } i_G(r, c) \geq th, \\ 0 & \text{en cas contrari.} \end{cases}$$

A l'article se'n detalla la construcció i combinació dels filtres esmentats.

3.3.11 Mètode de segmentació de Bibiloni et al. (Segm2019Bibiloni)

El darrer mètode de segmentació extret de [29] aplica morfologia matemàtica difusa, un refinament de la morfologia matemàtica vista fins ara que es centra en el grau en què un píxel pot o no ser d'una regió basat en la seva relació amb l'element estructurant, en comptes de decidir directament si hi pertany o no. S'empren les notacions $\tilde{e}_P$ per l'erosió difusa amb implicació difusa P , $\tilde{\delta}_C$ per la dilatació difusa amb conjunció difusa C , i $\tilde{L}$ per l'element estructurant difús, definicions que es detallen a l'article citat.

Sigui $I_0 = G(I)$ la imatge en escala de grisos amb la que s'inicia el mètode, es millora el contrast a la imatge I_1 d'intensitats

$$i_1(r, c) = i_0(r, c)^{0,6126}.$$

Es calcula ara la imatge I_2 que destaca les estructures primes i obscures,

$$I_2 = \tilde{e}_{P_1}(\tilde{\delta}_{C_1}(I_1, \tilde{L}_1), -\tilde{L}_1) - I_1.$$

A continuació s'aplica a I_2 la màscara erosionada $I_{M_E} = \tilde{e}_{P_M}(I_M, \tilde{L}_2)$, on I_M és la màscara calculada de la regió fora del camp visual, obtenint la imatge I_3 amb

$$i_3(r, c) = i_2(r, c) \cdot i_{M_E}(r, c).$$


Comparant aquesta imatge I_3 amb $I_D = \tilde{\delta}_{C_3}(I_3, \tilde{L}_3)$, s'obté la imatge I_4 que elimina els punts aïllats, resultat obtingut de

$$i_4(r, c) = \min\{i_3(r, c), i_D(r, c)\}.$$

La segmentació en escala de grisos I_G resulta d'una dilatació final de I_4 normalitzada, i la segmentació binària I_{BW} d'aplicar histèresi (veure article [30]) sobre I_G amb els llindars $T_{inf} = 0, 12$ i $T_{sup} = 0, 24$.

3.4 Mètodes de segmentació binària

Partint de la base de dades a treballar explicada a la secció 3.1, s'han escollit els tres mètodes de binarització següents per convertir les imatges en escala de grisos I_G en imatges binàries en blanc i negre I_{BW} . S'estableix per defecte que les imatges binàries tinguin les intensitats 0 pels píxels de fons i 1 pels píxels de no fons.



3.4.1 Otsu

Extret de l'article [31], donat un llindar K general per a tota la segmentació en escala de grisos $I_G \in \mathcal{M}_{M \times N}(U_G)$ s'obté la segmentació binària $I_{BW} \in \mathcal{M}_{M \times N}(U_{BW})$ amb intensitats a cada píxel

$$i_{BW}(r, c) = \begin{cases} 1 & \text{si } i_G(r, c) > K, \\ 0 & \text{en cas contrari.} \end{cases}$$

El valor de K és el que maximitza la variància interclasse σ_B^2 entre el conjunt de píxels negres i el conjunt de píxels blancs resultants.

Sigui $C_T = \{c_t : 1 \leq t \leq T\}$ el conjunt de nivells d'intensitat que pot tenir I_G , on la intensitat corresponent al nivell c_t és $i_t \in U_G$, el nombre de píxels de I_G amb intensitat i_t és n_t , per tant $N = n_1 + \dots + n_T$ és el nombre total de píxels que té I_G , i on $p_t = n_t/N$ és la probabilitat que un píxel correspongui al nivell d'intensitat c_t . Es defineixen la classe de nivells corresponents a píxels de fons $C_0 = \{c_t : 1 \leq t \leq k\}$ i la classe de nivells corresponents a píxels de no fons $C_1 = \{c_t : k+1 \leq t \leq T\}$.

Donats els valors

$$\begin{aligned} \omega_0 &= P(C_0) = \sum_{t=1}^k p_t, & \omega_1 &= P(C_1) = \sum_{t=k+1}^T p_t, \\ \omega_T &= P(C_T) = \sum_{t=1}^T p_t = 1 = \omega_0 + \omega_1, \\ \mu_0 &= E(C_0) = \sum_{t=1}^k t \frac{p_t}{\omega_0}, & \mu_1 &= E(C_1) = \sum_{t=k+1}^T t \frac{p_t}{\omega_1}, \\ \mu_T &= E(C_T) = \sum_{t=1}^T t p_t = \omega_0 \mu_0 + \omega_1 \mu_1, \end{aligned}$$

la variància interclasse, que mesura com de separades estan les mitjanes de cada classe, ve donada per

$$\sigma_B^2 = \omega_0(\mu_0 - \mu_T)^2 + \omega_1(\mu_1 - \mu_T)^2.$$




Figura 3.2: Primera columna d'angiografies oculars originals, segona columna de segmentacions en escala de grisos, tercera columna de segmentacions binàries, per als mètodes de segmentació següents: (a) **Segm1989Chaudhuri**, (b) **Segm2001ZanaKlein**, (c) **Segm2002Heneghan**, (d) **Segm2003Chanwimaluang**, (e) **Segm2005Zapater**, (f) **Segm2008SoaresGMM**, (g) **Segm2008SoaresKNN**, (h) **Segm2008SoaresLMSE**, (i) **Segm-2012Bankhead**, (j) **Segm2015Azzopardi**, (k) **Segm2019Bibiloni**.

Si es defineixen les funcions

$$\omega(k) = \sum_{t=1}^k p_t \quad \text{i} \quad \mu(k) = \sum_{t=1}^k t p_t,$$

resulta que

$$\omega_0 = \omega(k), \quad \omega_1 = 1 - \omega(k), \quad \mu_0 = \frac{\mu(k)}{\omega(k)}, \quad \mu_1 = \frac{\mu_T - \mu(k)}{1 - \omega(k)} \quad \text{i} \quad \mu_T = \mu(T),$$

d'on

$$\sigma_B^2(k) = \frac{[\mu(T)\omega(k) - \mu(k)]^2}{\omega(k)[1 - \omega(k)]},$$

i el nivell d'intensitat k^* de la màxima variància interclasse,

$$\sigma_B^2(k^*) = \max_{1 \leq k \leq T} \sigma_B^2(k),$$

es normalitza per obtenir el llindar K dins $[0, 1]$,

$$K = \frac{k^* - 1}{T - 1}.$$

3.4.2 Otsu adaptatiu

El nom d'aquest mètode explicat a [32] sorgeix precisament del seu plantejament: per cada píxel i_{rc} s'obté un llindar k_{rc} basat en – o adaptat a – les intensitats del seu entorn. Així es decideix si un píxel és o no un píxel de fons,

$$i_{BW}(r, c) = \begin{cases} 1 & \text{si } i_G(r, c) > k_{rc}, \\ 0 & \text{en cas contrari.} \end{cases}$$

Sigui $M \times N$ la mida de la segmentació en escala de grisos I_G que es vol binaritzar. La mida de l'entorn d'un píxel qualsevol i_{rc} és per defecte $n \times n$ on

$$n = 2d + 1 \quad \text{amb} \quad d = \left\lfloor \frac{M \cdot N}{16} \right\rfloor,$$

és a dir, el delimitat pels píxels $i_{r-d, c-d}$ al cantó superior esquerre i $i_{r+d, c+d}$ al cantó inferior dret.

S'obté la imatge S , on la intensitat de cada píxel és la suma de totes les intensitats a la porció esquerra superior de la posició,

$$s(r, c) = i_G(r, c) + s(r-1, c) + s(r, c-1) - s(r-1, c-1).$$

A partir d'aquestes intensitats, es calcula la imatge E que suma únicament les intensitats dins l'entorn de cada píxel,

$$e(r, c) = s(r+d, c+d) - s(r+d, c-d-1) - s(r-d-1, c+d) + (r-d-1, c-d-1).$$

Finalment s'obté la matriu de llindars K on la intensitat de cada k_{rc} és el valor mig del seu entorn,

$$k(r, c) = \frac{e(r, c)}{n \cdot n}.$$

Per realitzar tots els càlculs s'estableixen per defecte les intensitats $i(r, c) = 0$ per a totes les files $r < 1$ i totes les columnes $c < 1$.

3.4.3 Medina-Carnicer

Pel patró que segueixen els vasos sanguinis en les angiografies, una forma ràpida d'identificar-los és seguint la seva trajectòria simplement amb una línia. És per això que, a diferència dels dos mètodes anteriors on es vol determinar si un píxel és un píxel de fons o de no fons, s'ha decidit aplicar aquest mètode de detecció de fronteres que permetria obtenir el recorregut principal dels vasos.

El nucli d'aquest procediment és la histèresi, que s'aplica a la imatge de fases de congruència I_{FC} calculada a partir de I_G seguint l'article [33]. Donats dos llindars $\hat{u}_1, \hat{u}_2$ amb $\hat{u}_1 < \hat{u}_2$, i sigui el valor 1 un punt de frontera i 0 el cas contrari, les intensitats a cada píxel de la imatge binària $I_{\hat{u}_1, \hat{u}_2}$ venen donades per

$$i_{\hat{u}_1, \hat{u}_2}(r, c) = \begin{cases} 1 & \text{si } i_{FC}(r, c) > \hat{u}_2, \\ h_{\hat{u}_1, \hat{u}_2}(r, c) & \text{si } \hat{u}_1 < i_{FC}(r, c) \leq \hat{u}_2, \\ 0 & \text{si } i_{FC}(r, c) \leq \hat{u}_1, \end{cases}$$

on

$$h_{\hat{u}_1, \hat{u}_2}(r, c) = \begin{cases} 1 & \text{si } \exists (\tilde{r}, \tilde{c}) \in V_{(r, c)} \text{ tal que } i_{FC}(\tilde{r}, \tilde{c}) > \hat{u}_2, \\ 0 & \text{en cas contrari,} \end{cases}$$

per $V_{(r, c)}$ el conjunt de posicions veïnades al píxel (r, c) ,

$$V_{(r, c)} = \{(\tilde{r}, \tilde{c}) \mid r-1 \leq \tilde{r} \leq r+1, c-1 \leq \tilde{c} \leq c+1\}.$$

És a dir, un píxel de i_G es considera un punt de frontera si la seva congruència de fase o la d'un veïnat supera el llindar superior $\hat{u}_2$, classificació introduïda per Canny a [30].

La clau doncs de l'article [34] en què es basa aquest mètode de binarització jau en l'elecció dels llindars $\hat{u}_1, \hat{u}_2$. Donats dos valors a, b , es defineix el conjunt de possibles llindars $C = \{(u_1, u_2) \mid a \leq u_1 \leq u_2 \leq b\}$. Sigui

$$A = \sum_{(u_1, u_2) \in C} I_{u_1, u_2} - I_{u_1, u_1}$$

la matriu del nombre de vegades que cada píxel s'ha classificat com punt de frontera exclusivament per histèresi, es normalitza al rang d'intensitats obtenint la imatge A_N . Se'n realitza l'histograma amb la funció

$$u(i) = \frac{\left| \{(r, c) \mid i_{FC}(r, c) = i, a_N(r, c) = i\} \right|}{\left| \{(r, c) \mid a_N(r, c) = i\} \right|}.$$

El primer i darrer màxims locals de $u(i)$ determinen els valors de $\hat{u}_1$ i $\hat{u}_2$, que maximitzen els píxels classificats com punts de frontera pel procés d'enllaçament i que milloren la connectivitat.

D'acord amb l'article de referència [34] i altra documentació on es menciona el mètode en qüestió, [29, 35], s'estableixen els valors $\hat{u}_1 = 0,01$ i $\hat{u}_2 = 0,25$. A més, per finalitzar el mètode i apropar els resultats de les fronteres de línia al gruix dels vasos sanguinis, s'aplica a la segmentació binària obtinguda una dilatació amb l'element estructurant

$$L = \begin{pmatrix} 0 & 1 & 0 \\ 1 & 1 & 1 \\ 0 & 1 & 0 \end{pmatrix}.$$

3.5 Funcions d'agregació

En aquesta secció s'especifiquen les funcions d'agregació extretes del contingut vist a la secció 2.3 que es fan servir per combinar les segmentacions en escala de grisos dels mètodes de segmentació en escala de grisos extrets de la secció 3.3. S'han escollit vuit funcions d'agregació diferents: les tres bàsiques de mínim, màxim i mitjana aritmètica, i cinc OWAs. Per facilitar-ne les mencions, s'ha decidit anomenar-les **Min**, **Max**, **Mean**, **Ex1**, **Ex2**, **MEOWA**, **MVOWA** i **QOWA**, com es detallen a continuació.

1. **Min**: correspon al mínim de tots els valors,

$$\min(\mathbf{x}) = \min_{i=1,\dots,n} x_i = \min\{x_1, x_2, \dots, x_n\}.$$

Això és la OWA amb vector de ponderacions $\mathbf{w} = (0, \dots, 0, 1)$.

2. **Max**: correspon al màxim de tots els valors,

$$\max(\mathbf{x}) = \max_{i=1,\dots,n} x_i = \max\{x_1, x_2, \dots, x_n\}.$$

Això és la OWA amb vector de ponderacions $\mathbf{w} = (1, 0, \dots, 0)$.

3. **Mean**: correspon a la mitjana aritmètica de tots els valors,

$$\text{mean}(\mathbf{x}) = \frac{1}{n} \sum_{i=1}^n x_i = \frac{1}{n} (x_1 + x_2 + \dots + x_n).$$

Això és la OWA amb vector de ponderacions $\mathbf{w} = (\frac{1}{n}, \dots, \frac{1}{n})$.

4. **Ex1**: correspon a la OWA del teorema 2.1, amb vector de ponderacions

$$w_i = \frac{1}{n} \sum_{j=i}^n \frac{1}{j} \text{ per } i = 1, \dots, n.$$

5. **Ex2**: correspon a la OWA del teorema 2.2, amb vector de ponderacions

$$w_i = \frac{2(n+1-i)}{n(n+1)} \text{ per } i = 1, \dots, n.$$

6. **MEOWA**: depèn del valor de la dispersió que es fixi. Si la dispersió és $\alpha \in [0, \frac{1}{2}]$, correspon a la MEOWA amb vector de ponderacions

$$w_i = (w_1^{n-i} w_n^{i-1})^{\frac{1}{n-1}}, \quad i = 2, \dots, n-1,$$

$$w_n = \frac{((n-1)\alpha - n)w_1 + 1}{(n-1)\alpha + 1 - nw_1}$$

i w_1 l'única solució a l'interval $(0, \frac{1}{n})$ de l'equació

$$w_1 [(n-1)\alpha + 1 - nw_1]^n = ((n-1)\alpha)^{n-1} [((n-1)\alpha - n)w_1 + 1].$$

Si $\alpha \in (\frac{1}{2}, 1]$, correspon a la MEOWA amb valor de dispersió $\tilde{\alpha} = 1 - \alpha$.

7. **MVOWA**: depèn del valor de la dispersió que es fixi. Si la dispersió és $\alpha \in [0, \frac{1}{2}]$, correspon a la MVOWA amb vector de ponderacions

$$\begin{aligned} w_j &= 0, \quad j < r, \\ w_r &= \frac{6(n-1)\alpha - 2(n-r-1)}{(n-r+1)(n-r+2)}, \\ w_j &= w_r + \frac{j-r}{n-r}(w_n - w_r), \quad r < j < n, \end{aligned}$$

i

$$w_n = \frac{2(2n-2r+1-6(n-1)\alpha)}{(n-r+1)(n-r+2)},$$

on r satisfà les desigualtats

$$n - 3(n-1)\alpha - 1 < r \leq n - 3(n-1)\alpha,$$

és a dir, $\mathbf{w} = (0, 0, \dots, 0, w_r, \dots, w_n)$ amb els valors donats.

Si $\alpha \in (\frac{1}{2}, 1]$, correspon a la MVOWA amb valor de dispersió $\tilde{\alpha} = 1 - \alpha$.

8. **QOWA**: s'empra l'agregació basada en el quantificador lingüístic “la majoria”, que és el que es considera més pertinent a l'hora de decidir si un píxel pertany o no a un vas sanguini. Té vector de ponderacions

$$w_i = Q\left(\frac{i}{n}\right) - Q\left(\frac{i-1}{n}\right) \quad \text{per } i = 1, \dots, n,$$

on

$$Q(t) = Q_{a,b}(t) = \begin{cases} 0 & \text{si } t \leq a, \\ \frac{t-a}{b-a} & \text{si } a < t < b, \\ 1 & \text{si } t \geq b, \end{cases}$$

per $a = 0.3$, $b = 0.8$.

3.6 Descripció del procés

Una vegada descrita a la secció 3.1 la base de dades de què es disposa, i partint dels fonaments teòrics treballats al capítol anterior 2, en aquest capítol s'han definit a la secció 3.3 els 11 mètodes de segmentació, dels quals se'n consideren a més els 11 mètodes de segmentació en escala de grisos corresponents, 3 mètodes de segmentació binària, secció 3.4, i 8 funcions d'agregació, secció 3.5. Els objectius són:

1. l'obtenció del millor procés de segmentació dels vasos d'una angiografia ocular,
2. i decidir si l'agregació és o no millor que les segmentacions individuals.

Cal doncs determinar i distingir quins són els processos candidats.

Cada procés es crea a partir d'una combinació entre els noms de mètodes de la taula 3.1 i les aplicacions de la taula 3.2, les abreviacions de les quals permeten generar una etiqueta concreta. Per exemple, l'etiqueta **BMGCd** correspondria al procés resultant d'aplicar

- (B) el millor mètode de segmentació binària d'entre **ot**, **oa** i **mc** a haver aplicat
- (M) la màscara del camp de visió sobre
- (GCd) la segmentació en escala de grisos del mètode de segmentació de Chaudhuri, i l'etiqueta **BRBGAMi** correspondria al procés resultant d'aplicar
- (B) el millor mètode de segmentació binària d'entre **ot**, **oa** i **mc** sobre
- (R) el nombre reduït obtingut d'entre
- (BG) els mètodes de segmentació en escala de grisos que, amb el corresponent millor mètode de segmentació binària d'entre **ot**, **oa** i **mc**, superen a altres 4 mètodes de segmentació en escala de grisos
- (AMi) aplicant l'agregació **Min**.

Taula 3.1: Taula d'abreviacions pels noms dels mètodes de segmentació i funcions d'agregació sota estudi.

Mètodes de segmentació	Segmentacions binàries	Funcions d'agregació
Cd Chaudhuri	ot Otsu	Mi Min
ZK Zana i Klein	oa Otsu adaptatiu	Ma Max
Hg Heneghan	mc Medina-Carnicer	Me Mean
Cw Chanwimaluang		E1 Ex1
Zp Zapater		E2 Ex2
GM GMM de Soares		ME MEOWA
KN KNN de Soares		MV MVOWA
LM LMSE de Soares		QO QOWA
Bk Bankhead		
Az Azzopardi		
Bb Bibiloni		

Taula 3.2: Taula d'abreviacions per les aplicacions a realitzar.

Aplicacions	
S	Mètode de segmentació original.
G	Mètode de segmentació en escala de grisos.
B	Millor mètode de segmentació binària entre ot , oa i mc .
M	Màscara del camp de visió.
A	Funció d'agregació.
F	Tots els mètodes.
R	Nombre reduït dels mètodes que superen a altres 4 mètodes.

Aleshores, l'esquema principal de l'experimentació que es duu a terme per assolir els objectius d'aquest treball s'especifica a la figura 3.3. Es diferencien per una banda els processos que no inclouen l'aplicació de cap funció d'agregació, i per altra banda els que sí ho fan. Per reduir el nombre de comparacions globals, es creen agrupacions menors de cada grup principal, dels quals se n'obté l'ordenació estadística obtinguda seguint els criteris dels contrastos d'hipòtesi especificats a la secció 2.5, calculats sobre les mètriques d'avaluació descrites a la secció 2.4 amb aquell mateix ordre. Les ordenacions de cada subgrup permetran alhora determinar els mètodes a escollir per fer

3. PROCÉS DE SEGMENTACIÓ I AGREGACIÓ

les agregacions sobre un nombre reduït de mètodes, i obtenir el millor procés de cada agrupació, que es tornaran a comparar per obtenir els millor processos de segmentació finals. Tots els processos de segmentació que s'inclouen a cada ordenació es detallen a la figura 3.4.




Figura 3.3: Esquema del procés d'experimentació seguit per tal d'assolir els objectius del treball.

Comparar la millor segmentació i la millor agregació permetran determinar a la vegada quin ha estat el millor procés de segmentació –el millor entre aquests dos obtinguts– i si s'obté un procés millor agregant o sense agregar –en funció de si el millor mètode ha estat el que inclou agregació o no–.




Figura 3.4: Processos de segmentació inclosos a cada ordenació.

EXPERIMENTACIÓ

Aquest capítol recull el resum de tots els processos experimentals que s'han dut a terme en aquest TFG, i que han permès prendre decisions sobre valors a aplicar i passes a seguir. D'alguns mètodes de segmentació s'ha requerit trobar paràmetres desconeguts o substituir els que s'ha considerat adient per valors òptims del problema actual, així com obtenir llimdars de binaritzacions concretes i altres paràmetres de les funcions d'agregació. A més, ha estat necessari l'estudi amb contrastos d'hipòtesi i altres tècniques estadístiques per poder decidir amb fonaments quin o quins són els millors processos de segmentació dels vasos sanguinis en angiografies oculars.

Partint de la notació dels processos de segmentació definida a la secció 3.6, aquestes motivacions distingeixen les dues seccions treballades: una centrada en l'obtenció de paràmetres (secció 4.1), i l'altra en trobar el millor procés de segmentació (secció 4.2).

Tot i ser enfocaments diferents, en tots dos casos es calculen, per cada imatge del conjunt a estudiar, els valors TP, TN, FP, FN de la comparació entre el resultat d'aplicar el procés de segmentació i la imatge de valors de veritat fonamental corresponent, amb els quals calcular els valors de les mètriques d'avaluació IoU, FPR, PPV, ACC, TPR, de les quals s'obtenen la mitjana mostral, μ_m , i la desviació típica mostral, σ_m .

Tots els resultats obtinguts amb les imatges i codis utilitzats es poden trobar al repositori de GitHub de l'enllaç <https://github.com/sintygc/mathematics-TFG-retinal-vessel-segmentation-aggregation>.

4.1 Obtenció de paràmetres

Per poder aplicar de manera adequada tots els processos de segmentació, ha estat necessari determinar el valor de diversos paràmetres. S'ha estudiat amb aquest fi el conjunt d'imatges d'entrenament especificat a la secció 3.1 per un conjunt de candidats a cada paràmetre, i s'han aplicat als resultats les mètriques d'avaluació de la secció 2.4.

D'entre els possibles paràmetres, en destaquen els de les binaritzacions que corresponen al valor d'un sol llindar. Per trobar-ne el valor òptim s'empra el mètode de la corba ROC, creada a partir de la relació entre les mètriques TPR i FPR per un conjunt de candidats a llindar. El llindar òptim és el que minimitza la mitjana aritmètica del quocient FPR/TPR de cada imatge, $\mu_m(FPR/TPR)$, ja que redueix al màxim el nombre de falsos positius FP detectats i en maximitza els vertaders positius TP.

S'ha emprat, per exemple, per trobar el llindar th de **Segm2001ZanaKlein** fixat un valor $k = 9$, tot i no saber encara si correspon a la combinació òptima, però que sí correspon al valor th_9 de **Segm2005Zapater**. Construïda la corba ROC de la figura 4.1, s'ha obtingut el llindar òptim corresponent al punt on es minimitza $\mu_m(FPR/TPR)$, i que de fet és el primer punt d'intersecció entre la corba i la recta de pendent 1 desplaçada des de la coordenada (1, 1) de la gràfica cap avall. El llindar obtingut ha estat $th = 0,44$ amb un coeficient de $\mu_m(FPR/TPR) = 0,1985$.




Figura 4.1: Corba ROC de línia contínua blava dels candidats a llindar th pel mètode **Segm2001ZanaKlein** amb $k = 9$ fixat, punt blau on es minimitza $\mu_m(FPR/TPR)$, recta de pendent 1 en línia discontinua blava, i segment diagonal de referència en línia de punts negres.

La taula 4.1 conté una mostra del llistat dels llindars que s'han calculat pels mètodes que ho requerien, seguint aquest mètode de la corba ROC. Es pot consultar el llistat de llindars complet a l'apèndix a la taula A.1.

La resta de paràmetres ja sí es basen directament en les mètriques IoU, FPR, PPV, ACC, TPR. Principalment se'n pren atenció únicament a la mesura IoU, ja que es considera la més adient pel problema en qüestió en ser d'importància detectar els vasos de la forma més completa possible. En cas que la mètrica IoU no sigui decisiva, es passa a analitzar la resta de mètriques en el mateix ordre en què s'han mencionat en la secció 2.4, fins a arribar a la que permet escollir un únic valor pel paràmetre estudiat.

Del mètode de segmentació **Segm2002Heneghan** es requereix obtenir el valor del paràmetre M que permet obtenir la màscara de la regió fora del camp visual. Calculada la mètrica IoU de comparar l'aplicació del mètode amb cada candidat de M a cada imatge del conjunt d'entrenament amb les respectives imatges de veritat fonamental, el màxim valor de la mitjana dels IoUs per cada M , $\mu_m(IoU)$ determina el valor òptim. A la taula 4.2 s'inclou una mostra dels candidats i el valor de $\mu_m(IoU)$ corresponent.

Taula 4.1: Taula reduïda de llindars òptims obtinguts amb el mètode de la corba ROC, on s'indica a cada fila el mètode de segmentació que aplica el llindar amb valor indicat, i el quocient $\mu_m(FPR/TPR)$ pel qual ha resultat ser l'òptim.

mètode	llindar	valor	$\mu_m(FPR/TPR)$
Segm2005Zapater	th_1	0,41	0,305454422
Segm2005Zapater	th_2	0,45	0,41791269
Segm2005Zapater	th_3	0,41	0,377421927
...	...	...	...
Segm2005Zapater	th_{19}	0,505882353	0,432354157
Segm2005Zapater	th_{20}	0,494117647	0,595863314
Segm2005Zapater	th_{21}	0,505882353	0,582025966
Segm2005Zapater	T	0,55	0,182799773
Segm2015Azzopardi	th	0,09	0,088227695

Taula 4.2: Taula d'una mostra dels candidats a M del mètode **Segm2002Heneghan**, i el respectiu valor $\mu_m(IoU)$. Se'n destaca en negreta el valor òptim.

M	$\mu_m(IoU)$
...	...
41	0,424399264
42	0,425768523
43	0,428590834
44	0,42905132
45	0,424869186
46	0,419465312
47	0,417394794
...	...

En cas d'haver-hi empat del valor $\mu_m(IoU)$ entre un subconjunt de candidats, se'n considerarien els valors $\mu_m(FPR)$ del mateix subconjunt, i el mínim correspondria al valor òptim del paràmetre. En cas contrari, es continuaria el mateix raonament per la resta de mètriques, i de no ser decisives s'estudiarien el temps d'execució i els resultats visuals.

A la taula 4.3 es llista una mostra de tots els processos que han requerit una cerca optimitzada d'algun paràmetre, amb el seu valor final i el valor de $\mu_m(IoU)$ corresponent (el paràmetre de cada mètode es troba explicat a la respectiva subsecció del capítol 3). A l'apèndix es pot trobar la taula completa A.2.

Taula 4.3: Taula reduïda de paràmetres òptims obtinguts, on s'indica a cada fila el procés de segmentació que inclou el paràmetre amb el valor trobat, i el coeficient $\mu_m(IoU)$ pel qual ha resultat ser l'òptim.

procés	paràmetre	valor	$\mu_m(IoU)$
Segm2001ZanaKlein	k	9	0,398110735
Segm2002Heneghan	M	44	0,42905132
Segm2008SoaresGMM	M	1000000	0,605857636
Segm2008SoaresKNN	M	1000	0,539082664
Segm2008SoaresLMSE	M	1000000	0,44877599
fullAggMEOWA	α	0,4	0,61592853
fullIMaggMEOWA	α	0,2	0,60802909
...	...	...	...
redBGAaggMVOWA	α	0,1	0,61820327
redBMGAaggMVOWA	α	0,4	0,61191948

Un darrer estudi basat en les mètriques d'avaluació, ha estat la tria de la màscara corresponent a la regió fora del camp visual. S'ha vist que diversos mètodes de segmentació dels explicats a la secció 3.3 –en concret **Segm2002Heneghan**, els tres de **Segm2008Soares**, **Segm2015Azzopardi** i **Segm2019Bibiloni**– inclouen en el seu procés el càlcul d'una màscara. Comparant-les amb les màscares de veritat fonamental de què es disposa, s'ha decidit que la màscara òptima a emprar en els processos de segmentació que ho determinin és la de **Segm2008Soares** amb $\mu_m(IoU) = 0,993004468$.

4.2 Comparativa de processos de segmentació

Arribant finalment al nucli del treball, aquesta secció aprofundeix en tot el procés comparatiu que s'ha dut a terme per trobar el millor procés de segmentació, i determinar si agregar és millor que segmentar. Fent ús de la notació especificada a les taules 3.1 i 3.2 de la secció 3.6, el plantejament a seguir és el següent:

1. S'ordenen els 11 mètodes de segmentació principals introduïts a la secció 3.3, **S**.
2. S'ordenen els 11 mètodes de segmentació amb la màscara aplicada, **MS**.
3. Per cada mètode de segmentació en escala de grisos (sense i amb màscara, **G** i **MG**), s'obté la millor segmentació binària entre Otsu, Otsu adaptatiu i Medina-Carnicer, **BG** i **BMG**.
4. S'ordenen els 11 mètodes de segmentació sense màscara amb la respectiva millor segmentació binària, **BG**.
5. S'ordenen els 11 mètodes de segmentació amb màscara amb la respectiva millor segmentació binària, **BMG**.
6. S'ordenen els mètodes guanyadors de cada un dels 4 conjunts de segmentació analitzats: les segmentacions principals, **S**, amb màscara, **MS**, i amb les respectives millors binaritzacions, **BG** i **BMG**.
7. Aquesta passa no pertany al procés comparatiu, però sí és necessària per la seva continuació. A partir dels resultats obtinguts fins al moment, s'apliquen les agregacions sobre:
 - a) tots els mètodes de segmentació principals en escala de grisos, **FA**,
 - b) tots els mètodes de segmentació principals en escala de grisos amb màscara, **FMA**,
 - c) els mètodes de segmentació en escala de grisos amb la segmentació binària original que superin a altres 4 mètodes sota les mateixes premises, **RSA**,
 - d) els mètodes de segmentació en escala de grisos amb la segmentació binària original i màscara que superin a altres 4 mètodes sota les mateixes premises, **RMSA**,
 - e) els mètodes de segmentació en escala de grisos amb la respectiva millor segmentació binària que superin a altres 4 mètodes sota les mateixes premises, **RBGA**,

- f) els mètodes de segmentació en escala de grisos amb màscara i amb la respectiva millor segmentació binària que superin a altres 4 mètodes sota les mateixes premisses, **RBMGA**.
8. Per cada agregació aplicada –**FA, FMA, RSA, RMSA, RBGA, RBMGA**– s’obté la millor segmentació binària entre **ot, oa i mc, BFA, BFMA, BRSA, BRMSA, BRBGA, BRBMGA**.
9. S’ordenen els processos dins cada conjunt d’aplicació d’agregacions.
10. S’ordenen els 6 millors processos d’entre tots els conjunts d’aplicació d’agregacions.
11. Finalment es comparen el millor mètode de segmentació sense agregació amb el millor mètode de segmentació aplicant agregació.

Es determina que un procés és millor que un altre en funció del nombre de processos dels quals hi ha evidències estadístiques que obtinguï millors resultats. Per tant serà necessari comparar tots els mètodes dos a dos, comprovant abans que efectivament hi ha evidències que no tots els mètodes considerats són estadísticament iguals. En cas de què més d’un procés superi al mateix nombre de processos, és a dir que hi hagi empat, d’aquests serà millor el procés al qual superen el menor nombre de processos. En els casos on tot i així no es decideixi, es passarà a realitzar el mateix estudi per la següent mesura d’execució restringint els processos només als del cas d’empat. D’arribar a realitzar-se l’estudi amb totes les mètriques, serà millor el procés que tingui menor temps d’execució.

L’estudi estadístic a seguir aplica a cada una de les passes mencionades, tant d’ordenació com d’obtenció de la millor segmentació binària. Únicament difereix el nombre de processos sobre el que es realitza.

Totes aquestes comparacions es fan partint dels valors mitjans, calculats sobre el conjunt d’imatges de prova. És a dir, dos processos A, B es comparen en funció de la relació estadística inicial entre $\mu(IoU_A)$ i $\mu(IoU_B)$, d’on obtenir $\mu(IoU_A) > \mu(IoU_B)$ s’entendrà com que el procés A és millor que el B , $\mu(IoU_A) < \mu(IoU_B)$ s’entendrà com que el procés B és millor que l’ A , i $\mu(IoU_A) = \mu(IoU_B)$ s’entendrà com que cap procés és estadísticament millor que l’altre.

Cal esmentar que dels tests que no han decidit i pels que s’ha recorregut a la comparació de diagrames de caixes, s’ometen els detalls realitzats i se n’indiquen directament les conclusions. A més es destaca que la majoria d’ordenacions s’han realitzat de forma exacta i sense empats, però en casos puntuals s’ha optat per no resoldre certs desempats que no eren significatius per a les fases posteriors de l’experimentació.

Es posa d’exemple la primera ordenació dels 11 mètodes de segmentació considerats, i de la resta s’indiquen solament els resultats obtinguts. Siguin **SCd, SZK, SHg, SCw, SZp, SGM, SKN, SLM, SBk, SAz, SBb** els 11 mètodes de segmentació a ordenar (veure abreviacions a les taules 3.1 i 3.2). Es calculen de cada mètode les dades bàsiques que permetran realitzar els estudis posteriors, indicades a la taula 4.4: $\mu_m(IoU_{S_i})$, $\sigma(IoU_{S_i})$, el p -valor del contrast de normalitat individual, i el resultat del mateix contrast i de l’ajustat. Els contrastos realitzats són, per cada mètode de segmentació S_i ,

$$\begin{cases} H_0 : \text{la mostra de } IoU_{S_i} \text{ prové d'una distribució normal,} \\ H_1 : \text{la mostra de } IoU_{S_i} \text{ no prové d'una distribució normal.} \end{cases}$$

Taula 4.4: Resultats calculats sobre la mesura d'avaluació IoU dels mètodes de segmentació principals: mitjana, desviació típica, p -valors de normalitat individual, resultat de normalitat individual i resultat de normalitat ajustada, on si el valor de les columnes de normalitat és 0, s'accepta H_0 , si és 1 es rebutja H_1 .

Mètode	μ_m	σ	p -valor	norm. ind.	norm. aj.
SCd	0,26434137	0,14620291	0,32434870	0	0
SZK	0,40187506	0,18709641	0,03305219	1	0
SHg	0,44764614	0,12660563	0,00091351	1	1
SCw	0,50876309	0,04169307	0,87617595	0	0
SZp	0,45898856	0,13130150	0,27041907	0	0
SGM	0,61344543	0,05612000	0,18852137	0	0
SKN	0,55287972	0,06682427	0,22356030	0	0
SLM	0,46461331	0,08132498	0,17877215	0	0
SBk	0,58140398	0,03442106	0,03084557	1	0
SAz	0,62279456	0,02921057	0,32331272	0	0
SBb	0,57906973	0,07226697	0,72252007	0	0

Com es pot veure a la columna dels resultats de les normalitats ajustades, no tots els mètodes provenen d'una distribució normal. Per tant no cal estudiar l'homoscedasticitat i el test de Kruskal-Wallis per la igualtat de totes les mitjanes

$$\begin{cases} H_0 : \mu(IoU_{S_1}) = \dots = \mu(IoU_{S_{11}}), \\ H_1 : \text{hi ha alguna mitjana diferent,} \end{cases}$$

retorna un p -valor de $1,332422 \times 10^{-15}$, per tant hi ha evidències estadístiques de què no totes les mitjanes són iguals. Així doncs, es procedeix a aplicar el test de Mann-Whitney per parelles amb ajust de Bonferroni, que retorna alhora els p -valors de realitzar el següent contrast d'igualtat de mitjanes per cada S_i i S_j amb $j < i$,

$$\begin{cases} H_0 : \mu(IoU_{S_i}) = \mu(IoU_{S_j}), \\ H_1 : \mu(IoU_{S_i}) \neq \mu(IoU_{S_j}), \end{cases}$$

i permeten obtenir el resultat final de la taula a l'apèndix A.3, on es pot comprovar que hi ha mètodes estadísticament diferents.

Donat que s'han trobat diferències estadístiques, es vol estudiar quina és la seva relació mitjançant els contrastos de diferència pertinents. Per això es realitzen abans els contrastos per parelles d'igualtat de variància, i els de diferència de variància pels quals han resultat diferents, amb les relacions finals de la taula a l'apèndix A.4. I amb l'estudi de normalitat i igualtat de variàncies fet, es realitzen els contrastos que permeten obtenir la taula 4.5 de relacions de mitjanes finals.

A partir d'aquesta taula 4.5, es crea la taula 4.6 d'ordenació dels mètodes, on s'indica de cada mètode a quants altres mètodes supera estadísticament, quants en té que són estadísticament superiors a ell, i quina posició en l'ordenació final ocupa.

Com es pot observar, hi ha tres parells on no ha decidit l'ordenació, i com s'ha explicat anteriorment es procedeix a fer l'estudi amb la mesura d'execució FPR només

4.2. Comparativa de processos de segmentació

Taula 4.5: Resultats calculats sobre la mesura d'avaluació IoU dels mètodes de segmentació principals: contrast d'igualtat i desigualtat de mitjanes per parelles, on = indica que el mètode de la fila és estadísticament equivalent al de la columna, < indica que el mètode de la fila és estadísticament inferior al de la columna, i > indica que el mètode de la fila és estadísticament superior al de la columna. La resta de casos no aplica.

	SCd	SZK	SHg	SCw	SZp	SGM	SKN	SLM	SBk	SAz	SBb
SCd	-	-	-	-	-	-	-	-	-	-	-
SZK	=	-	-	-	-	-	-	-	-	-	-
SHg	=	=	-	-	-	-	-	-	-	-	-
SCw	>	=	=	-	-	-	-	-	-	-	-
SZp	=	=	=	=	-	-	-	-	-	-	-
SGM	>	>	>	>	>	-	-	-	-	-	-
SKN	>	=	>	=	=	<	-	-	-	-	-
SLM	>	=	=	=	=	<	<	-	-	-	-
SBk	>	>	>	>	>	=	=	>	-	-	-
SAz	>	>	>	>	>	=	>	>	>	-	-
SBb	>	>	>	>	>	<	=	>	=	=	-

Taula 4.6: Resultats calculats sobre la mesura d'avaluació IoU dels mètodes de segmentació principals: a quants altres mètodes supera, quants altres mètodes el superen, i quina posició de l'ordenació ocupen.

	supera a	el superen	posició
SCd	0	7	11
SZK	0	4	8
SHg	0	5	10
SCw	1	4	6
SZp	0	4	8
SGM	8	0	1
SKN	3	2	5
SLM	1	5	7
SBk	6	1	3
SAz	8	0	1
SBb	6	1	3

en aquests casos d'empat. Atès que el raonament és exactament el mateix –sols que per comparar-se dos únics processos no es realitzen ni l'estudi d'igualtat de mitjanes per més de dues mitjanes ni l'homoscedasticitat–, s'inclouen tots els resultats d'ordenació dels mètodes de segmentació a la taula 4.7. Aquesta taula conté els mètodes en la posició final obtinguda, en ordre de millor mètode a pitjor, amb l'etiqueta de cada mètode concret considerat –els mètodes de **BG** i **BMG** ja porten la millor segmentació binària obtinguda– i a quants altres mètodes supera estadísticament, destacant en negreta només els mètodes que n'han superat a més de 4 i que seran els emprats en les agregacions posteriors.

Una vegada aplicades les agregacions, es tornen a calcular les millors segmentacions binàries per cada procés considerat, i s'ordenen també de forma agrupada tots els processos, amb els resultats de les taules 4.8 i 4.9, de les agregacions a tots els mètodes i de les agregacions a una reducció de mètodes respectivament.

Finalment s'ordenen els millors processos de segmentació sense agregació i amb agregació, amb els resultats a la taula 4.10, i es comparen el millor de cadascun, amb l'ordenació final a la taula 4.11. Cal destacar que dels processos de segmentació sense

Taula 4.7: Ordenacions finals de les diferents agrupacions de mètodes de segmentació, en ordre. De cada agrupació s'especifiquen el nom de cada mètode i a quants altres mètodes del grup superen estadísticament. S'indiquen només en negreta els mètodes que han superat a més que 4 altres mètodes.

Posició	S	>	MS	>	BG	>	BMG	>
1	SAz	8	MSAz	8	ot-GGM	9	ot-MGGM	9
2	SGM	8	MSGM	8	ot-GAz	8	ot-MGAz	8
3	SBk	6	MSBk	4	ot-GKN	6	ot-MGKN	7
4	SBb	6	MSBb	4	oa-GZK	5	ot-MGBb	5
5	SKN	3	MSKN	3	ot-GBb	4	oa-MGLM	4
6	SCw	1	MSCw	1	oa-GCd	2	ot-MGZp	0
7	SLM	1	MSLM	1	oa-GCw	1	ot-MGHg	0
8	SZp	0	MSZp	0	ot-GZp	0	oa-MGZK	0
9	SZK	0	MSZK	0	ot-GHg	0	oa-MGCw	0
10	SHg	0	MSHg	0	oa-GBk	0	oa-MGCd	0
11	SCd	0	MSCd	0	oa-GLM	0	oa-MGBk	0

Taula 4.8: Ordenacions finals de les diferents agrupacions de processos de segmentació amb agregació de tots els mètodes, en ordre. De cada agrupació s'especifiquen el nom de cada mètode i a quants altres mètodes del grup superen estadísticament.

Posició	FA	>	FMA	>
1	ot-FAME	5	ot-FMAME	5
2	ot-FAMV	5	ot-FMAMV	5
3	ot-FAQO	5	ot-FMAQO	5
4	ot-FAMe	4	ot-FMAMi	4
5	ot-FAE2	2	oa-FMAME	3
6	ot-FAE1	1	oa-FMAE2	2
7	ot-FAMi	0	oa-FMAE1	1
8	ot-FAMa	0	oa-FMAMa	0

Taula 4.9: Ordenacions finals de les diferents agrupacions de processos de segmentació amb agregació d'un nombre reduït de mètodes, en ordre. De cada agrupació s'especifiquen el nom de cada mètode i a quants altres mètodes del grup superen estadísticament.

Posició	RSA	>	RMSA	>	RBGA	>	RBMGA	>
1	ot-RSAMe	4	ot-RMSAMi	5	ot-RBGAE1	6	ot-RBMGAMi	6
2	ot-RSAMV	4	ot-RMSAMe	5	ot-RBGAMi	4	ot-RBMGAQO	6
3	ot-RSAME	4	ot-RMSAMa	5	ot-RBGAE2	4	ot-RBMGAME	5
4	ot-RSAE2	3	ot-RMSAE1	1	ot-RBGAMe	2	ot-RBMGAMV	4
5	ot-RSAQO	2	ot-RMSAE2	1	ot-RBGAMV	2	ot-RBMGAME	3
6	ot-RSAE1	1	ot-RMSAMV	1	ot-RBGAME	2	ot-RBMGAE2	2
7	ot-RSAMi	1	ot-RMSAQO	1	ot-RBGAQO	1	ot-RBMGAE1	1
8	ot-RSAMa	0	ot-RMSAME	0	oa-RBGAMa	0	ot-RBMGAMa	0

agregació, tornant a la taula de resultats 4.7, s'omet el millor procés del conjunt **BG**, que per si mateix ja inclou la màscara de Soares i que té exactament els mateixos resultats que el millor procés del conjunt **BMG**.

4.3 Discussió de resultats

En aquest capítol s'han detallat tota l'experimentació feta amb els seus resultats. Respecte a l'obtenció de paràmetres: la corba ROC ha permès obtenir llimdars de binaritzacions

Taula 4.10: Ordenacions finals dels millors processos de segmentació sense i amb agregació. De cada agrupació de processos s'especifiquen l'ordre, el nom de cada procés i a quants altres processos del grup superen estadísticament.

Posició	sense agregació	>	Posició	amb agregació	>
1	ot-MGGM	2	1	ot-RSAMe	3
2	SAz	0	2	ot-FAME	2
3	MSAz	0	3	ot-FMAME	1
			4	ot-RMSAMi	1
			5	ot-RBGAEI	1
			6	ot-RBMGAMi	0

Taula 4.11: Ordenació final entre el millor procés de segmentació sense agregació i el millor procés de segmentació amb agregació. S'especifiquen l'ordre, el nom de cada procés i a quants altres processos superen estadísticament.

Posició	procés	>
1	ot-RSAMe	1
2	ot-MGGM	0

que reduïen els falsos positius FP sense sacrificar els vertaders positius TP al minimitzar el quocient FPR/TPR ; dels paràmetres escollits a optimitzar s'han obtingut els resultats fent ús de les mesures d'avaluació IoU, FPR, PPV, ACC, TPR en aquest mateix ordre de preferència, i amb l'estudi fet sota els candidats que s'han considerat adients; i sortint de l'obtenció d'un paràmetre concret, però emprant igualment de la mateixa forma les mesures d'avaluació, s'ha arribat a la conclusió que la millor màscara de la regió fora del camp visual era la corresponent a la dels mètodes de Soares.

Pel que fa a la comparativa de tots els processos de segmentació considerats, l'estudi s'ha basat en les evidències estadístiques mitjançant els contrastos d'hipòtesi pertinents. Per analitzar la relació entre més d'un procés, la lògica ha estat comprovar si hi ha evidències que algun procés sigui estadísticament diferent i seguir amb els contrastos pertinents per anar trobant la relació que hi ha entre tots els parells: si són estadísticament equivalents o algun dels dos és estadísticament millor que l'altre. Obtenir aquests resultats dos a dos ha permès determinar l'ordenació de les diferents agrupacions que s'han definit: de cada mètode en escala de grisos, quina era la seva millor segmentació binària; de totes les agrupacions, distingides entre binarització original o determinada sobre la segmentació en escala de grisos, amb o sense agregació de tots els mètodes o d'un nombre reduït, i sense o amb màscara del camp visual; dels millors processos entre els que s'han inclòs o no agregació; i finalment dels dos millors processos de cada agrupació, per concloure finalment quin és el millor procés de segmentació del problema sota estudi i si és millor segmentar o agregar.

Dels resultats, en destaca primerament que la binarització de Medina-Carnicer no ha resultat òptima en cap cas. Atès que és un mètode adaptat que té origen en la detecció de fronteres no aprecia el gruix dels vasos, pel que encara que se'n detecti correctament el recorregut, els trams gruixats s'afinen i els trams fins s'agruixen. A més, el baix valor dels paràmetres escollits, $\hat{u}_1 = 0,01$ i $\hat{u}_2 = 0,25$, han provocat que es puguin detectar erròniament molts més vasos dels que realment ho són. A la figura 4.2 s'inclouen tres resultats amb la binarització de Medina-Carnicer, on es pot apreciar la diferència amb la imatge de veritat fonamental i les altres dues binaritzacions.




Figura 4.2: D'esquerra a dreta: imatge de veritat fonamental i processos **GZK**, **FAE2** i **RBGMV**. Amb les binaritzacions (a) Medina-Carnicer, (b) Otsu, (c) Otsu adaptatiu.

Respecte als processos finals, ressalta el fet que dels que no inclouen agregació amb els resultats de la taula 4.7, els dos millors mètodes sempre són el d'Azzopardi o el GMM de Soares, mentre que l'ordenació dels altres mètodes pot variar molt, posant com a exemple la segmentació de Bankhead, que a l'ordenació de segmentacions originals està en tercera posició però amb la millor binarització calculada i màscara aplicada queda en darrer lloc. Això podria indicar dues coses: que Bankhead no dona resultats tan sòlids com per prendre importància en les agregacions, i que la binarització que s'emptra és molt millor que les tres que s'ha considerat aplicar. Però la millor agregació resulta que sí que té en compte el mètode de Bankhead tot i no aplicar-se la mateixa binarització, a més d'Azzopardi, GMM de Soares i Bibiloni.

Pel que fa als processos amb agregacions aplicades, no ha obtingut un millor resultat qualsevol que tingués aplicada la màscara de la regió fora del camp visual, tot i que sembli que qualsevol resultat amb màscara hauria de ser millor que sense ja que s'eviten molts falsos positius FP. A més, una agregació més complexa tampoc garanteix un millor resultat. Al final, el procés òptim de tots els considerats ha estat el que combina quatre mètodes de segmentació en escala de grisos, que no sempre s'ha demostrat que fossin millors que tots els altres, sense màscara aplicada, i agregats simplement amb la mitjana aritmètica. A la figura 4.3 es pot observar un exemple d'una angiografia amb la imatge original, la segmentació de veritat fonamental definida per un expert, el resultat obtingut amb el millor procés de segmentació sense agregació, i el resultat obtingut amb el millor procés de segmentació, que és amb agregació.




Figura 4.3: D'esquerra a dreta: angiografia original, segmentació de veritat fonamental, resultat del millor procés de segmentació sense agregació, **ot-MGGM**, i resultat del millor procés de segmentació, que és amb agregació, **ot-RSAMe**.

CONCLUSIONS I TREBALL FUTUR

Es dona per finalitzat l'estudi dels diferents processos que s'han considerat en aquest TFG per segmentar els vasos sanguinis d'angiografies del fons ocular. Al capítol 2 s'ha introduït tota la base teòrica necessària per entendre què és una imatge, què fan les diferents passes dels mètodes de segmentació i de les funcions d'agregació, quines mètriques d'avaluació s'empren per fer tota l'experimentació i els contrastos d'hipòtesi que es fan servir per obtenir els resultats estadístics. El capítol 3 entra en detall amb el problema en qüestió: amb quin tipus d'imatge es treballa, quins mètodes de segmentació es consideren, així com els mètodes de segmentació binària i les funcions d'agregació que s'apliquen, i el procés d'estudi que es duu a terme. Tots els resultats obtinguts en l'experimentació s'expliquen i s'analitzen al capítol 4.

5.1 Conclusions

Realitzada tota l'experimentació i obtinguts tots els resultats, es pot concloure que el millor procés de segmentació, **ot-RSAME**, inclou una agregació que combina amb mitjana aritmètica les segmentacions en escala de grisos dels mètodes d'Azzopardi, GMM de Soares, Bankhead i Bibiloni en aquest ordre, sense afegir-hi la màscara addicional del camp no visual, i l'afirmació final és que, en efecte, agregar és millor que no aplicar cap combinació de resultats.

Després d'haver completat l'estudi d'aquest treball, destaca el fet que tot i que la conclusió ha estat que agregar ha resultat millor, també ha depès completament de cada elecció que s'ha pres, des de quins mètodes de segmentació s'estudiaven, quins mètodes de binarització, quines funcions d'agregacions, fins i tot les mètriques d'avaluació i en quin ordre s'han aplicat, i per descomptat també quines imatges i quantes s'han emprat com a base de dades. No tota intuïció inicial que es pugui tenir sobre quins seran els resultats finals és científicament certa per molt lògica que sembli, com és el que ha passat amb l'ús o no de la màscara de la regió fora del camp visual.

Es considera necessari remarcar aquest punt: els resultats obtinguts són exclusius dels mètodes aplicats, de les mètriques i l'ordre establerts, i de les poques angiografies sobre les quals s'ha realitzat l'experimentació que a més ha inclòs imatges amb i sense patologies.

5.2 Treball futur

Aquesta observació final obre la porta directament a continuar amb l'estudi sobre segmentacions d'angiografies. Seria de gran rellevància ampliar el conjunt de dades sobre la qual es treballa, ja que augmentar el volum d'imatges, i en conseqüència de dades, consolidaria la validesa estadística dels resultats i la capacitat de generalització dels processos considerats.

Referent a variacions de l'estudi actual, ha estat evident que l'elecció dels mètodes de binarització podria haver variat completament els resultats finals. No s'ha conclòs que el mètode de binarització de Medina-Carnicer hagi estat pitjor que els altres dos, sinó que l'elecció dels seus paràmetres i de la forma d'adaptar-lo al problema no ha estat del tot adient, de manera que es podria aprofundir en aquest apartat.

Finalment, i com ja s'ha esmentat, aquest treball s'ha restringit als mètodes escollits. Amb el pas dels anys i el progrés de la tecnologia, evolucionen també la capacitat i la rapidesa dels processos existents, i se'n creen de nous i millors. L'estudi de la segmentació en angiografies roman un camp obert amb un ampli marge de millora que continuarà sent objecte d'investigació fins a assolir un rendiment equiparable al dels especialistes clínics i, eventualment, superar-lo.

DEMOSTRACIONS I RESULTATS

En aquest apèndix s'inclouen les demostracions i els resultats que s'han emprat al llarg del TFG, però la inclusió dels quals s'ha omès del cos principal per fluïdesa de la lectura.

Proposició A.1. La mesura orness satisfà les següents propietats:

- i) Siguin $OWA_{\mathbf{w}}$ una funció OWA i $OWA_{\mathbf{w}_d}$ la seva OWA inversa. Les seves mesures orness es relacionen per

$$\text{orness}(OWA_{\mathbf{w}}) = 1 - \text{orness}(OWA_{\mathbf{w}_d}).$$

- ii) L'orness d'una OWA és 0 si, i només si, és la funció mínim $\min$, on $\mathbf{w} = (0, \dots, 0, 1)$.

- iii) L'orness d'una OWA és 1 si, i només si, és la funció màxim $\max$, on $\mathbf{w} = (1, 0, \dots, 0)$.

- iv) L'orness de la mitjana aritmètica M , on $\mathbf{w} = (\frac{1}{n}, \dots, \frac{1}{n})$, és $\frac{1}{2}$, però també pot ser $\frac{1}{2}$ per a altres OWAs.

Demostració. Es demostren una a una les propietats mencionades.

- i) $\text{orness}(OWA_{\mathbf{w}_d}) = 1 - \text{orness}(OWA_{\mathbf{w}})$.

$$\begin{aligned} \text{orness}(OWA_{\mathbf{w}_d}) &= \sum_{i=1}^n w_{n-i+1} \frac{n-i}{n-1} = \\ &= 1 - 1 + \sum_{i=1}^n w_{n-i+1} \frac{n-i}{n-1} = 1 - \sum_{i=1}^n w_i + \sum_{i=1}^n w_{n-i+1} \frac{n-i}{n-1} = \\ &= 1 + \sum_{i=1}^n w_{n-i+1} \left(\frac{n-i}{n-1} - 1 \right) = 1 - \sum_{i=1}^n w_{n-i+1} \frac{i-1}{n-1} = \\ &= 1 - \sum_{i=1}^n w_i \frac{n-i}{n-1} = 1 - \text{orness}(OWA_{\mathbf{w}}). \end{aligned}$$

- ii) $\text{orness}(OWA_{\mathbf{w}}) = 0 \iff OWA_{\mathbf{w}} = \min, \mathbf{w} = (0, \dots, 0, 1)$.

$$\Leftrightarrow \text{orness}(\min) = \sum_{i=1}^{n-1} 0 \frac{n-i}{n-1} + 1 \frac{n-n}{n-1} = 0.$$

$$\Rightarrow \text{Per } i = 1, \dots, n-1, \frac{n-i}{n-1} > 0. \text{ Llavors,}$$

$$\begin{aligned} \text{orness}(OWA_{\mathbf{w}}) = 0 &\Rightarrow \sum_{i=1}^n w_i \frac{n-i}{n-1} = 0 \Rightarrow \sum_{i=1}^{n-1} w_i \frac{n-i}{n-1} = 0 \Rightarrow \\ &\Rightarrow w_i = 0, \quad i = 1, \dots, n-1, \end{aligned}$$

$$\sum_{i=1}^n w_i = 1 \Rightarrow w_n = 1.$$

Per tant, $\mathbf{w} = (0, \dots, 0, 1)$, és a dir, $OWA_{\mathbf{w}} = \min$.

iii) $\text{orness}(OWA_{\mathbf{w}}) = 1 \iff OWA_{\mathbf{w}} = \max, \mathbf{w} = (1, 0, \dots, 0)$.

$$\Leftrightarrow \text{orness}(\max) = 1 \frac{n-1}{n-1} + \sum_{i=2}^n 0 \frac{n-i}{n-1} = 1.$$

$$\Rightarrow \text{Per } i = 2, \dots, n, \frac{i-1}{n-1} > 0. \text{ Llavors,}$$

$$\begin{aligned} \text{orness}(OWA_{\mathbf{w}}) = 1 &\Rightarrow \sum_{i=1}^n w_i \frac{n-i}{n-1} = 1 \Rightarrow \sum_{i=1}^n w_i \frac{n-i}{n-1} - \sum_{i=1}^n w_i = 0 \Rightarrow \\ &\Rightarrow - \sum_{i=1}^n w_i \frac{i-1}{n-1} = 0 \Rightarrow - \sum_{i=2}^n w_i \frac{i-1}{n-1} = 0 \Rightarrow \\ &\Rightarrow w_i = 0, \quad i = 2, \dots, n, \end{aligned}$$

$$\sum_{i=1}^n w_i = 1 \Rightarrow w_1 = 1.$$

Per tant, $\mathbf{w} = (1, 0, \dots, 0)$, és a dir, $OWA_{\mathbf{w}} = \max$.

iv) $\text{orness}(M) = \frac{1}{2}$ on $\mathbf{w} = (\frac{1}{n}, \dots, \frac{1}{n})$, però $\text{orness}(OWA_{\mathbf{w}}) = \frac{1}{2} \nRightarrow OWA_{\mathbf{w}} = M$.

Primer es prova que $\text{orness}(M) = \frac{1}{2}$:

$$\begin{aligned} \text{orness}(M) &= \sum_{i=1}^n \frac{1}{n} \frac{n-i}{n-1} = \frac{1}{n(n-1)} \left(\sum_{i=1}^n n - \sum_{i=1}^n i \right) = \frac{1}{n(n-1)} \left(n^2 - \frac{(1+n)n}{2} \right) \\ &= \frac{1}{n(n-1)} \left(\frac{2n^2 - n^2 - n}{2} \right) = \frac{1}{n(n-1)} \left(\frac{n(n-1)}{2} \right) = \frac{1}{2}. \end{aligned}$$

Considerant ara, per exemple, la OWA on $\mathbf{w} = (\frac{1}{2}, 0, \dots, 0, \frac{1}{2})$, resulta que

$$\text{orness}(OWA_{\mathbf{w}}) = \frac{1}{2} \frac{n-1}{n-1} + \sum_{i=2}^{n-1} 0 + \frac{1}{2} \frac{n-n}{n-1} = \frac{1}{2},$$

de manera que efectivament s'ha trobat una altra OWA amb orness de valor $\frac{1}{2}$ però que no és la M .

□

Proposició A.2. L'entropia satisfà les següents propietats:

- i) Siguin $OWA_{\mathbf{w}}$ una funció OWA i $OWA_{\mathbf{w}_d}$ la seva OWA inversa. Les seves entropies es relacionen per

$$\text{Disp}(\mathbf{w}) = \text{Disp}(\mathbf{w}_d).$$

De fet, l'entropia d'un vector és constant respecte a permutacions d'aquest.

- ii) S'obté el mínim de Disp si, i només si, $\mathbf{w}$ és tal que $w_k = 1$ i $w_i = 0 \forall i \neq k$, és a dir, a l'ordre estàtic, i l'entropia d'aquest vector de ponderacions val 0.
- iii) Si no s'especifica l'orness, s'obté el màxim de Disp a $OWA_{\mathbf{w}} = M$, és a dir, a la mitjana aritmètica on $\mathbf{w} = (\frac{1}{n}, \dots, \frac{1}{n})$, i l'entropia d'aquest vector de ponderacions val $\log n$.

Demostració. Es demostren una a una les propietats mencionades.

- i) $\text{Disp}(\mathbf{w}_d) = \text{Disp}(\mathbf{w})$.

$$\begin{aligned} \text{Disp}(\mathbf{w}_d) &= - \sum_{i=1}^n w_{n-i+1} \log w_{n-i+1} = \\ &= -w_n \log w_n - w_{n-1} \log w_{n-1} - \dots - w_2 \log w_2 - w_1 \log w_1 = \\ &= -w_1 \log w_1 - w_2 \log w_2 - \dots - w_{n-1} \log w_{n-1} - w_n \log w_n = \\ &= - \sum_{i=1}^n w_i \log w_i = \\ &= \text{Disp}(\mathbf{w}). \end{aligned}$$

- ii) $\min(\text{Disp}(\mathbf{w})) = 0 \iff \mathbf{w}$ és tal que $w_k = 1$ i $w_i = 0 \forall i \neq k$.

$$\Leftarrow) \text{Disp}(\mathbf{w}) = -1 \log 1 - \sum_{i \neq k}^n 0 \log 0 = 0.$$

$\Rightarrow) w_i \in [0, 1] \forall i = 1, \dots, n \Rightarrow \log w_i \leq 0 \forall i = 1, \dots, n \Rightarrow -w_i \log w_i \geq 0 \forall i = 1, \dots, n$, per tant $\text{Disp}(\mathbf{w}) \geq 0$ i $\min(\text{Disp}(\mathbf{w})) = 0$. D'aquí s'obté el vector de ponderacions:

$$\text{Disp}(\mathbf{w}) = 0 \iff - \sum_{i=1}^n w_i \log w_i \iff w_i \log w_i = 0 \forall i = 1, \dots, n$$

Això passa si, i només si, per a cada i es té o $w_i = 0$ o $\log w_i = 0$, és a dir, si $w_i = 0$ o $w_i = 1$. Per ser $\mathbf{w}$ vector de ponderacions, $\sum_{i=1}^n w_i = 1$, per tant $\mathbf{w}$ és tal que $w_k = 1$ per algun valor k entre 1 i n , i $w_i = 0 \forall i \neq k$.

- iii) $\max(\text{Disp}(\mathbf{w})) = \log n$ quan $\mathbf{w} = (\frac{1}{n}, \dots, \frac{1}{n})$.

Es prova amb el mètode dels multiplicadors de Lagrange resolent el problema d'optimització

$$\begin{aligned} \max \quad & \text{Disp}(\mathbf{w}) = - \sum_{i=1}^n w_i \log w_i \\ \text{subjecte a} \quad & \sum_{i=1}^n w_i = 1, \\ & w_i \geq 0, \quad i = 1, \dots, n. \end{aligned}$$

La funció de Lagrange és

$$L(\mathbf{w}, \lambda) = - \sum_{i=1}^n w_i \log w_i + \lambda \left(\sum_{i=1}^n w_i - 1 \right),$$

on $\lambda \in \mathbb{R}$ és un multiplicador de Lagrange. S'obté $\mathbf{w}$ resolent el sistema següent:

$$\begin{aligned} \frac{\partial L}{\partial w_j} = 0 & \Rightarrow -\log w_j - 1 + \lambda = 0 \Rightarrow w_j = e^{\lambda-1}, \quad j = 1, \dots, n, \\ \frac{\partial L}{\partial \lambda} = 0 & \Rightarrow \sum_{i=1}^n w_i - 1 = 0 \Rightarrow \sum_{i=1}^n e^{\lambda-1} - 1 = 0 \Rightarrow n e^{\lambda-1} = 1 \Rightarrow e^{\lambda-1} = \frac{1}{n}. \end{aligned}$$

Per tant, $w_j = \frac{1}{n}$ per $j = 1, \dots, n$, és a dir, $\mathbf{w} = (\frac{1}{n}, \dots, \frac{1}{n})$, i el valor de l'entropia d'aquest vector és

$$\text{Disp}\left(\frac{1}{n}, \dots, \frac{1}{n}\right) = - \sum_{i=1}^n \frac{1}{n} \log \frac{1}{n} = - \frac{n}{n} \log \frac{1}{n} = -(\log 1 - \log n) = \log n.$$

L'única solució obtinguda no és un mínim per la propietat *ii*, i la matriu hessiana de l'entropia,

$$H(\text{Disp}(\mathbf{w}))_{ij} = \frac{\partial^2 \text{Disp}}{\partial w_i \partial w_j}(\mathbf{w}) = \begin{cases} -\frac{1}{w_i} & \text{si } i = j, \\ 0 & \text{si } i \neq j, \end{cases}$$

per ser diagonal amb entrades negatives, prova que l'entropia és una funció estrictament còncava a l'interior del seu domini, $w_i \in (0, 1)$, $i = 1, \dots, n$, cosa que garanteix que la solució obtinguda sí correspon al màxim.

□

Proposició A.3. Sigui $\alpha = \text{orness}(\text{MEOWA}_{\mathbf{w}})$, la MEOWA satisfà les següents propietats:

- i) Si $\alpha = 0$, la MEOWA és la OWA min, amb vector de ponderacions $\mathbf{w} = (0, \dots, 0, 1)$, i el valor màxim de l'entropia és 0.
- ii) Si $\alpha = 1$, la MEOWA és la OWA max, amb vector de ponderacions $\mathbf{w} = (1, 0, \dots, 0)$, i el valor màxim de l'entropia torna a ser 0.
- iii) Si $\alpha = \frac{1}{2}$, la MEOWA és la OWA M , amb vector de ponderacions $\mathbf{w} = (\frac{1}{n}, \dots, \frac{1}{n})$, i el valor màxim de l'entropia és $\log n$.

Demostració. Sigui $\alpha = \text{orness}(MEOWA_{\mathbf{w}})$, es demostren una a una les propietats mencionades emprant les propietats de l'orness i de l'entropia, vistes a les proposicions 2.4 i 2.5 respectivament.

i) $\alpha = 0 \Rightarrow MEOWA_{\mathbf{w}} = \min$, on $\mathbf{w} = (0, \dots, 0, 1)$, i $\max(\text{Disp}(\mathbf{w})) = 0$.

Per la propietat *ii* de l'orness a la proposició 2.4, si $\alpha = 0$, la MEOWA resulta ser la OWA min amb vector de ponderacions $\mathbf{w} = (0, \dots, 0, 1)$, i per la propietat de l'entropia *ii* de la proposició 2.5, com $\text{Disp}(\mathbf{w}) = 0$, el valor màxim de l'entropia resulta ser 0.

ii) $\alpha = 1 \Rightarrow MEOWA_{\mathbf{w}} = \max$, on $\mathbf{w} = (1, 0, \dots, 0)$, i $\max(\text{Disp}(\mathbf{w})) = 0$.

Per la propietat de l'orness *iii* de la proposició 2.4, si $\alpha = 1$, la MEOWA resulta ser la OWA max, amb vector de ponderacions $\mathbf{w} = (1, 0, \dots, 0)$, i per la propietat *ii* de l'entropia a la proposició 2.5, el valor màxim de l'entropia torna a ser 0.

iii) $\alpha = \frac{1}{2} \Rightarrow MEOWA_{\mathbf{w}} = M$, on $\mathbf{w} = (\frac{1}{n}, \dots, \frac{1}{n})$, i $\max(\text{Disp}(\mathbf{w})) = \log n$.

De la propietat *iv* de l'orness (de la proposició 2.4), hi ha més d'una OWA que pot tenir $\alpha = \frac{1}{2}$, però una d'elles –la mitjana aritmètica– és la que maximitza l'entropia, com s'ha vist a la propietat *iii* de l'entropia (proposició 2.5), per tant la solució del problema en aquest cas és el vector de ponderacions $(\frac{1}{n}, \dots, \frac{1}{n})$, amb valor màxim de l'entropia $\log n$.

□

Proposició A.4. La solució del problema d'optimització plantejat a la definició 2.3.18 subjecte a $\alpha \in (0, \frac{1}{2})$ ve donada per

$$w_i = (w_1^{n-i} w_n^{i-1})^{\frac{1}{n-1}}, \quad i = 2, \dots, n-1,$$

$$w_n = \frac{((n-1)\alpha - n)w_1 + 1}{(n-1)\alpha + 1 - nw_1},$$

i w_1 l'única solució a l'interval $(0, \frac{1}{n})$ de l'equació

$$w_1 [(n-1)\alpha + 1 - nw_1]^n = ((n-1)\alpha)^{n-1} [((n-1)\alpha - n)w_1 + 1].$$

Demostració. Siguin $n > 1$ i $\alpha \in (0, \frac{1}{2})$, primer es demostraran les expressions enunciades emprant el mètode dels multiplicadors de Lagrange, i després la unicitat de w_1 amb el perquè de l'interval on pertany.

La funció de Lagrange del problema d'optimització plantejat és

$$L(\mathbf{w}, \lambda_1, \lambda_2) = - \sum_{i=1}^n w_i \log w_i + \lambda_1 \left(\sum_{i=1}^n w_i \frac{n-i}{n-1} - \alpha \right) + \lambda_2 \left(\sum_{i=1}^n w_i - 1 \right),$$

on $\lambda_1, \lambda_2 \in \mathbb{R}$ són els multiplicadors de Lagrange.

Per trobar els valors de $\mathbf{w}$, λ_1 i λ_2 , es resol el sistema d'equacions que surt d'igualar les derivades parcials de $L(\mathbf{w}, \lambda_1, \lambda_2)$ a 0:

$$\begin{aligned}\frac{\partial L}{\partial w_j} = 0 &\Rightarrow -\log w_j - 1 + \lambda_1 \frac{n-j}{n-1} + \lambda_2 = 0, \quad j = 1, \dots, n, \\ \frac{\partial L}{\partial \lambda_1} = 0 &\Rightarrow \sum_{i=1}^n w_i \frac{n-i}{n-1} - \alpha = 0, \\ \frac{\partial L}{\partial \lambda_2} = 0 &\Rightarrow \sum_{i=1}^n w_i - 1 = 0.\end{aligned}$$

De les primeres n equacions es té que:

- per $j = n$: $-\log w_n - 1 + \lambda_2 = 0 \Rightarrow \lambda_2 = 1 + \log w_n$,
- per $j = 1$: $-\log w_1 - 1 + \lambda_1 + \lambda_2 = 0 \Rightarrow \lambda_1 = \log w_1 - \log w_n$,
- per $j = 2, \dots, n-1$ i emprant les λ_1 i λ_2 trobades,

$$\begin{aligned}-\log w_j - 1 + (\log w_1 - \log w_n) \frac{n-j}{n-1} + (1 + \log w_n) &= 0 \\ \log w_j &= \frac{n-j}{n-1} \log w_1 - \frac{n-j}{n-1} \log w_n + \frac{n-1}{n-1} \log w_n \\ \log w_j &= \frac{n-j}{n-1} \log w_1 + \frac{j-1}{n-1} \log w_n \\ w_j &= \sqrt[n-1]{w_1^{n-j} w_n^{j-1}}.\end{aligned}$$

Així doncs, el sistema a resoldre passa a ser el següent:

$$\begin{aligned}\frac{\partial L}{\partial w_j} = 0 &\Rightarrow w_j = \sqrt[n-1]{w_1^{n-j} w_n^{j-1}}, \quad j = 2, \dots, n-1, \\ \frac{\partial L}{\partial \lambda_1} = 0 &\Rightarrow \sum_{i=1}^n w_i \frac{n-i}{n-1} - \alpha = 0, \\ \frac{\partial L}{\partial \lambda_2} = 0 &\Rightarrow \sum_{i=1}^n w_i - 1 = 0.\end{aligned}$$

Per facilitar els càlculs, s'introdueixen a les equacions les notacions

$$u_1 = \sqrt[n-1]{w_1}, \quad u_n = \sqrt[n-1]{w_n},$$

de forma que el sistema plantejat queda com

$$\frac{\partial L}{\partial w_j} = 0 \Rightarrow w_j = u_1^{n-j} u_n^{j-1}, \quad j = 2, \dots, n-1, \quad (\text{A.1})$$

$$\frac{\partial L}{\partial \lambda_1} = 0 \Rightarrow \sum_{i=1}^n u_1^{n-i} u_n^{i-1} (n-i) = \alpha(n-1), \quad (\text{A.2})$$

$$\frac{\partial L}{\partial \lambda_2} = 0 \Rightarrow \sum_{i=1}^n u_1^{n-i} u_n^{i-1} = 1. \quad (\text{A.3})$$

Es calculen els sumatoris pertinents:

$$\begin{aligned}
\sum_{i=1}^n u_1^{n-i} u_n^i &= \sum_{i=1}^n u_1^{n-i} u_n^i \frac{u_1 - u_n}{u_1 - u_n} = \frac{1}{u_1 - u_n} \left(\sum_{i=1}^n u_1^{n-i+1} u_n^i - \sum_{i=1}^n u_1^{n-i} u_n^{i+1} \right) \\
&= \frac{1}{u_1 - u_n} \left(u_1^n u_n + \sum_{i=2}^n u_1^{n-i+1} u_n^i - \sum_{i=1}^{n-1} u_1^{n-i} u_n^{i+1} - u_n^{n+1} \right) \\
&= \frac{1}{u_1 - u_n} \left(u_1^n u_n + \sum_{i=1}^{n-1} u_1^{n-i} u_n^{i+1} - \sum_{i=1}^{n-1} u_1^{n-i} u_n^{i+1} - u_n^{n+1} \right) = \frac{u_1^n u_n - u_n^{n+1}}{u_1 - u_n},
\end{aligned} \tag{A.4}$$

$$\begin{aligned}
\sum_{i=1}^n u_1^{n-i} u_n^{i-1} &= \sum_{i=1}^n u_1^{n-i} u_n^{i-1} \frac{u_1 - u_n}{u_1 - u_n} = \frac{1}{u_1 - u_n} \left(\sum_{i=1}^n u_1^{n-i+1} u_n^{i-1} - \sum_{i=1}^n u_1^{n-i} u_n^i \right) \\
&= \frac{1}{u_1 - u_n} \left(u_1^n + \sum_{i=2}^n u_1^{n-i+1} u_n^{i-1} - \sum_{i=1}^{n-1} u_1^{n-i} u_n^i - u_n^n \right) \\
&= \frac{1}{u_1 - u_n} \left(u_1^n + \sum_{i=1}^{n-1} u_1^{n-i} u_n^i - \sum_{i=1}^{n-1} u_1^{n-i} u_n^i - u_n^n \right) = \frac{u_1^n - u_n^n}{u_1 - u_n},
\end{aligned} \tag{A.5}$$

$$\begin{aligned}
\sum_{i=1}^n i u_1^{n-i} u_n^{i-1} &= \sum_{i=1}^n i u_1^{n-i} u_n^{i-1} \frac{u_1 - u_n}{u_1 - u_n} = \frac{1}{u_1 - u_n} \left(\sum_{i=1}^n i u_1^{n-i+1} u_n^{i-1} - \sum_{i=1}^n i u_1^{n-i} u_n^i \right) \\
&= \frac{1}{u_1 - u_n} \left(u_1^n + \sum_{i=2}^n i u_1^{n-i+1} u_n^{i-1} - \sum_{i=1}^{n-1} i u_1^{n-i} u_n^i - n u_n^n \right) = \\
&= \frac{1}{u_1 - u_n} \left(u_1^n + \sum_{i=1}^{n-1} (i+1) u_1^{n-i} u_n^i - \sum_{i=1}^{n-1} i u_1^{n-i} u_n^i - n u_n^n \right) = \\
&= \frac{1}{u_1 - u_n} \left(u_1^n - n u_n^n + \sum_{i=1}^{n-1} u_1^{n-i} u_n^i + u_n^n - u_n^n \right) = \\
&= \frac{1}{u_1 - u_n} \left(u_1^n - n u_n^n + \sum_{i=1}^n u_1^{n-i} u_n^i - u_n^n \right) = \\
\stackrel{(A.4)}{=} & \frac{1}{u_1 - u_n} \left(u_1^n - n u_n^n + \frac{u_1^n u_n - u_n^{n+1}}{u_1 - u_n} - u_n^n \right) = \\
&= \frac{1}{(u_1 - u_n)^2} (u_1^{n+1} - n u_n^n (u_1 - u_n) - u_1 u_n^n),
\end{aligned} \tag{A.6}$$

$$\begin{aligned}
\sum_{i=1}^n (n-i) u_1^{n-i} u_n^{i-1} &= n \sum_{i=1}^n u_1^{n-i} u_n^{i-1} - \sum_{i=1}^n i u_1^{n-i} u_n^{i-1} \\
&\stackrel{(A.5), (A.6)}{=} n \frac{u_1^n - u_n^n}{u_1 - u_n} - \frac{1}{(u_1 - u_n)^2} (u_1^{n+1} - n u_n^n (u_1 - u_n) - u_1 u_n^n) \\
&= \frac{1}{(u_1 - u_n)^2} (n u_1^n (u_1 - u_n) - u_1 (u_1^n - u_n^n)).
\end{aligned}$$

Amb aquests sumatoris es poden trobar els valors de w_1 i w_n emprant les equacions (A.2) i (A.3) del sistema:

$$\begin{aligned}
& \begin{cases} \sum_{i=1}^n u_1^{n-i} u_n^{i-1} (n-i) = \alpha(n-1) \\ \sum_{i=1}^n u_1^{n-i} u_n^{i-1} = 1 \end{cases} \\
& \Rightarrow \begin{cases} \frac{1}{(u_1 - u_n)^2} (n u_1^n (u_1 - u_n) - u_1 (u_1^n - u_n^n)) = \alpha(n-1) \\ \frac{u_1^n - u_n^n}{u_1 - u_n} = 1 \end{cases} \\
& \Rightarrow \begin{cases} n u_1^n (u_1 - u_n) - u_1 (u_1^n - u_n^n) = \alpha(n-1) (u_1 - u_n)^2 \\ u_1^n - u_n^n = u_1 - u_n \end{cases} \\
& \Rightarrow \begin{cases} n u_1^n - u_1 = \alpha(n-1) u_1 - \alpha(n-1) u_n \\ u_1^{n-1} - \frac{u_n}{u_1} u_n^{n-1} = 1 - \frac{u_n}{u_1} \end{cases} \\
& \Rightarrow \begin{cases} u_n = \frac{u_1}{\alpha(n-1)} (\alpha(n-1) - n u_1^{n-1} + 1) \\ w_1 - \frac{u_n}{u_1} w_n = 1 - \frac{u_n}{u_1} \end{cases} \\
& \Rightarrow \begin{cases} (\alpha(n-1))^{n-1} u_n^{n-1} = u_1^{n-1} (\alpha(n-1) - n w_1 + 1)^{n-1} \\ \alpha(n-1) w_1 - (\alpha(n-1) - n w_1 + 1) w_n = \alpha(n-1) - (\alpha(n-1) - n w_1 + 1) \end{cases} \\
& \Rightarrow \begin{cases} (\alpha(n-1))^{n-1} w_n = w_1 (\alpha(n-1) - n w_1 + 1)^{n-1} \\ w_n = \frac{(\alpha(n-1) - n) w_1 + 1}{\alpha(n-1) - n w_1 + 1} \end{cases} \\
& \Rightarrow \begin{cases} (\alpha(n-1))^{n-1} ((\alpha(n-1) - n) w_1 + 1) = w_1 (\alpha(n-1) - n w_1 + 1)^n, \\ w_n = \frac{(\alpha(n-1) - n) w_1 + 1}{\alpha(n-1) - n w_1 + 1}, \end{cases}
\end{aligned}$$

i desfent la notació emprada, s'arriba a les expressions enunciades:

$$\begin{cases} \frac{\partial L}{\partial w_j} = 0 & \Rightarrow w_j = (w_1^{n-j} w_n^{j-1})^{\frac{1}{n-1}}, \quad j = 2, \dots, n-1, \\ \frac{\partial L}{\partial \lambda_1} = 0 & \Rightarrow (\alpha(n-1))^{n-1} ((\alpha(n-1) - n) w_1 + 1) = w_1 (\alpha(n-1) - n w_1 + 1)^n, \\ \frac{\partial L}{\partial \lambda_2} = 0 & \Rightarrow w_n = \frac{(\alpha(n-1) - n) w_1 + 1}{\alpha(n-1) - n w_1 + 1}. \end{cases}$$

Per acabar la demostració, s'estudia la solució w_1 de l'equació

$$w_1 [(n-1)\alpha + 1 - n w_1]^n = ((n-1)\alpha)^{n-1} [((n-1)\alpha - n) w_1 + 1]. \quad (\text{A.7})$$

Cal fixar-se que la part de la dreta de la igualtat és un polinomi de grau 1 i la part de l'esquerra un polinomi de grau $n + 1$, per tant les solucions w_1 d'aquesta equació corresponen als punts d'intersecció entre la corba

$$f(w_1) = w_1[(n-1)\alpha + 1 - nw_1]^n$$

i la recta

$$g(w_1) = ((n-1)\alpha)^{n-1}[(n-1)\alpha - n]w_1 + 1.$$

Se n'estudia, doncs, el seu comportament, recordant que $w_1 \in [0, 1]$ per ser una ponderació i que s'ha restringit $\alpha \in (0, \frac{1}{2})$.

Es calculen de g els talls amb els eixos i la monotonia:

- $g(0) = ((n-1)\alpha)^{n-1} > 0 \Rightarrow g$ talla l'eix OY al punt $(0, ((n-1)\alpha)^{n-1})$,
- $0 = ((n-1)\alpha)^{n-1}[(n-1)\alpha - n]w_1 + 1 \Rightarrow \tilde{w}_1 = \frac{1}{n - (n-1)\alpha} \in \left(\frac{1}{n}, 1\right) \Rightarrow g$ talla l'eix OX al punt $\left(\frac{1}{n - (n-1)\alpha}, 0\right)$,
- $g'(w_1) = -((n-1)\alpha)^{n-1}(n - (n-1)\alpha) < 0 \Rightarrow g$ és decreixent.

Ara s'estudia el comportament de f :

- $f(0) = 0 \Rightarrow f$ passa per l'origen de coordenades $(0, 0)$.
- De la primera derivada

$$\begin{aligned} f'(w_1) &= [(n-1)\alpha - nw_1 + 1]^n - n^2 w_1 [(n-1)\alpha - nw_1 + 1]^{n-1} = \\ &= ((n-1)\alpha - nw_1 + 1 - n^2 w_1) [(n-1)\alpha - nw_1 + 1]^{n-1}, \end{aligned}$$

cal notar que

$$f'\left(\frac{1}{n}\right) = ((n-1)\alpha - n) [(n-1)\alpha]^{n-1} = g'\left(\frac{1}{n}\right),$$

i que, de fet,

$$f\left(\frac{1}{n}\right) = \frac{1}{n} [(n-1)\alpha]^n = g\left(\frac{1}{n}\right),$$

és a dir, a $w_1 = \frac{1}{n}$, f i g coincideixen i són tangents.

A més, s'obtenen els punts crítics de la igualtat $f'(w_1) = 0$:

$$\begin{cases} (n-1)\alpha - nw_1 + 1 - n^2 w_1 = 0 & \Rightarrow \widehat{w}_1 = \frac{(n-1)\alpha + 1}{n(n+1)} \in \left(0, \frac{1}{n}\right), \\ (n-1)\alpha - nw_1 + 1 = 0 & \Rightarrow \widetilde{w}_1 = \frac{(n-1)\alpha + 1}{n} \in \left(\frac{1}{n}, 1\right), \end{cases}$$

on $f(\widetilde{w}_1) = 0$, per tant $(\widetilde{w}_1, 0)$ és un altre punt de tall de f amb l'eix OX .

- Amb la segona derivada,

$$\begin{aligned} f''(w_1) &= -2n^2[(n-1)\alpha - nw_1 + 1]^{n-1} + n^3(n-1)w_1[(n-1)\alpha - nw_1 + 1]^{n-2} = \\ &= -n^2(2((n-1)\alpha + 1) - nw_1(n+1))[(n-1)\alpha - nw_1 + 1]^{n-2}, \end{aligned}$$

s'estudia la curvatura als punts d'interès:

$$f''(0) = -2n^2[(n-1)\alpha + 1]^{n-1} < 0,$$

$$f''(\widehat{w}_1) = -n((n-1)\alpha + 1) \left[\frac{n((n-1)\alpha + 1)}{n+1} \right]^{n-2} < 0,$$

$$f''\left(\frac{1}{n}\right) = n^2(n-1)(1-2\alpha)[(n-1)\alpha]^{n-2} > 0,$$

$$f''(\widetilde{w}_1) = 0,$$

$$f''(1) = n^2(n(1-2\alpha) + 2(1-\alpha) + n^2)[-(n-1)(1-\alpha)]^{n-2} \begin{cases} > 0 & \text{per } n \text{ parell,} \\ < 0 & \text{per } n \text{ senar.} \end{cases}$$

D'aquests càlculs s'extreu que la recta g és decreixent i talla els eixos de coordenades en valors positius, i que la corba f comença creixent fins arribar a un màxim, decreix fins a un mínim o un punt d'inflexió sobre l'eix de coordenades, i creix o decreix per la resta de valors. Més en detall es poden concloure els següents punts, que es visualitzen a la figura A.1 amb les corresponents etiquetes.

- A $w_1 = 0$ la corba f val 0 i la recta g talla l'eix d'ordenades a un valor superior. A més, la recta és decreixent i la corba en aquest punt és creixent i convexa.
- La corba f té un màxim a $\widehat{w}_1 \in (0, \frac{1}{n})$.
- A $w_1 = \frac{1}{n}$ la recta f i la corba g es tallen i tenen el mateix pendent. A més, per ser $f''(\frac{1}{n}) > 0$, en un entorn d'aquest punt la corba és convexa, per tant està per sobre de la recta.
- La recta, que es troba per sota de la corba, segueix decreixent fins tallar l'eix de coordenades a $\check{w}_1 > \frac{1}{n}$.
- La corba talla l'eix de coordenades a $\widetilde{w}_1 \in (\check{w}_1, 1)$, i en aquest punt hi té un mínim, si n és parell, o un punt d'inflexió, si n és senar.
- Si n és parell, des del punt mínim la corba segueix creixent i té un valor positiu a $w_1 = 1$, i si n és senar, des del punt d'inflexió la corba segueix decreixent i té un valor negatiu a $w_1 = 1$.

Per tant, pels punts (b) i (c), el màxim de la corba es troba per damunt de la recta, i, com els únics punts crítics de la corba han estat aquest màxim a $\widehat{w}_1$ i el mínim o punt d'inflexió a $\widetilde{w}_1 > \frac{1}{n}$, es pot assegurar que la corba i la recta intersequen una única vegada entre 0 i $\frac{1}{n}$, és a dir, existeix una única solució de l'equació (A.7) a $w_1 \in (0, \frac{1}{n})$.




Figura A.1: Desglossament gràfic de les característiques clau de la corba f , en verd, i la recta g , en vermell. Per entendre'n millor el comportament, es recomana consultar l'enllaç de GeoGebra: <https://www.geogebra.org/m/q2b5abwx>.

Ara bé, en el cas que n sigui senar, s'ha vist que la corba té un punt d'inflexió a $\widetilde{w}_1$ i que decreix a partir de llavors. Pels punts (d) i (e), una intersecció amb $w_1 > \frac{1}{n}$ succeiria només en un valor $w_1 > \widehat{w}_1$. Per acabar la demostració s'estudia com afectaria això al valor w_n .

Recordant que l'expressió de w_n depèn del valor de w_1 , es pot considerar la funció

$$w_n(w_1) = \frac{(\alpha(n-1) - n)w_1 + 1}{\alpha(n-1) - nw_1 + 1},$$

que és una funció racional. Més en concret, $w_n(w_1)$ és una hipèrbola amb asymptota vertical exactament a

$$w_1 = \frac{\alpha(n-1) + 1}{n} = \widehat{w}_1,$$

i a més és decreixent perquè

$$w'_n = \frac{-\alpha(n-1)^2(1-\alpha)}{(\alpha(n-1) - nw_1 + 1)^2} < 0.$$

Per tant, la hipèrbola és de la forma de la figura A.2a i, com $w_n(1) = 1$, sempre passa pel punt $Q = (1, 1)$. Visualitzant aquest fet amb més claredat a la figura A.2b es veu que per qualsevol $w_1 \in (\widehat{w}_1, 1)$ l'altura de la hipèrbola resulta en un valor major que 1, i considerar aquesta altra possible solució de w_1 que duu a un valor $w_n > 1$ contradiria la restricció $\sum_{i=1}^n w_i = 1$ del problema plantejat.

□

Proposició A.5. La solució del problema d'optimització plantejat a la definició 2.3.20 subjecte a $\alpha \in (0, \frac{1}{2})$ ve donada pel vector $\mathbf{w} = (0, \dots, 0, w_r, \dots, w_n)$, és a dir,

$$w_j = 0, \quad j < r, \tag{A.8}$$

$$w_r = \frac{6(n-1)\alpha - 2(n-r-1)}{(n-r+1)(n-r+2)}, \tag{A.9}$$

$$w_n = \frac{2(2n-2r+1) - 6(n-1)\alpha}{(n-r+1)(n-r+2)}, \tag{A.10}$$




Figura A.2: Desglossament gràfic del comportament de la hipèrbola w_n , en blau. Per entendre'n millor el comportament, es pot consultar el gràfic a l'enllaç de GeoGebra: <https://www.geogebra.org/m/arefzevn>.

i

$$w_j = w_r + \frac{j-r}{n-r}(w_n - w_r), \quad r < j < n, \quad (\text{A.11})$$

on r satisfà les desigualtats

$$n - 3(n-1)\alpha - 1 < r \leq n - 3(n-1)\alpha. \quad (\text{A.12})$$

Demostració. Siguin $n > 1$ i $\alpha \in (0, \frac{1}{2})$, primer es demostren les expressions enuncia-des emprant el mètode dels multiplicadors de Lagrange, i després la validesa de les desigualtats mencionades per triar el valor de r .

La funció de Lagrange del problema d'optimització plantejat és

$$L(\mathbf{w}, \lambda_1, \lambda_2) = \frac{1}{n} \sum_{i=1}^n w_i^2 + \lambda_1 \left(\sum_{i=1}^n w_i \frac{n-i}{n-1} - \alpha \right) + \lambda_2 \left(\sum_{i=1}^n w_i - 1 \right),$$

on $\lambda_1, \lambda_2 \in \mathbb{R}$ són els multiplicadors de Lagrange.

Per trobar els valors de $\mathbf{w}$, λ_1 i λ_2 , es resol el sistema d'equacions que surt d'igualar les derivades parcials de $L(\mathbf{w}, \lambda_1, \lambda_2)$ a 0:

$$\begin{aligned} \frac{\partial L}{\partial w_j} = 0 &\Rightarrow \frac{2}{n} w_j + \lambda_1 \frac{n-j}{n-1} + \lambda_2 = 0, \quad j = 1, \dots, n, \\ \frac{\partial L}{\partial \lambda_1} = 0 &\Rightarrow \sum_{i=1}^n w_i \frac{n-i}{n-1} - \alpha = 0, \end{aligned} \quad (\text{A.13})$$

$$\frac{\partial L}{\partial \lambda_2} = 0 \Rightarrow \sum_{i=1}^n w_i - 1 = 0. \quad (\text{A.14})$$

Suposant que $\mathbf{w} = (0, \dots, 0, w_r, \dots, w_n)$, amb $w_r \neq 0$ i $r < n$ —ja que, si no, es tindria $\mathbf{w} = (0, \dots, 0, 1)$, que és la solució per a $\alpha = 0$ —, de les primeres n equacions s'obté:

- per $j = n$,

$$\frac{2}{n} w_n + \lambda_2 = 0 \Rightarrow \lambda_2 = -\frac{2}{n} w_n,$$

- per $j = r$,

$$\frac{2}{n} w_r + \lambda_1 \frac{n-r}{n-1} + \lambda_2 = 0 \Rightarrow \lambda_1 = \frac{2(n-1)}{n(n-r)}(w_n - w_r),$$

- per $j = r + 1, \dots, n - 1$ i emprant les λ_1 i λ_2 trobades,

$$\begin{aligned} \frac{2}{n} w_j + \frac{n-j}{n-1} \cdot \frac{2(n-1)}{n(n-r)} (w_n - w_r) - \frac{2}{n} w_n &= 0 \\ w_j &= \frac{n-j}{n-r} w_r + \frac{j-r}{n-r} w_n = w_r + \frac{j-r}{n-r} (w_n - w_r). \end{aligned}$$

Amb $w_j = 0$ per $j = 1, \dots, r - 1$, aquest resultat de w_j per $j = r + 1, \dots, n - 1$, i els resultats dels següents sumatoris, s'empren les dues equacions restants per trobar els valors de w_r i w_n .

Es calculen un seguit de sumatoris:

$$\begin{aligned} \sum_{i=r}^n ((i+1)^3 - i^3) &= (n+1)^3 - r^3 \\ \Rightarrow \sum_{i=r}^n (3i^2 + 3i + 1) &= (n-r+1)((n+1)^2 + r(n+1) + r^2) \\ \Rightarrow 3 \sum_{i=r}^n i^2 + 3 \frac{(n+r)(n-r+1)}{2} + (n-r+1) &= (n-r+1)((n+1)^2 + r(n+1) + r^2), \\ \sum_{i=r}^n 1 &= n-r+1, \\ \sum_{i=r}^n i &= \frac{(n+r)(n-r+1)}{2}, \\ \sum_{i=r}^n i^2 &= \frac{1}{6} (n-r+1) [2((n+1)^2 + r(n+1) + r^2) - 3(n+r) - 2] = \\ &= \frac{1}{6} (n-r+1) (2n^2 + n + 2r^2 - r + 2nr), \\ \sum_{i=r}^n \left(w_r + \frac{i-r}{n-r} (w_n - w_r) \right) &= \left(w_r - \frac{r}{n-r} (w_n - w_r) \right) \sum_{i=r}^n 1 + \frac{1}{n-r} (w_n - w_r) \sum_{i=r}^n i \\ &= \left(w_r - \frac{r}{n-r} (w_n - w_r) \right) (n-r+1) + \frac{1}{n-r} (w_n - w_r) \frac{(n+r)(n-r+1)}{2} \\ &= \frac{n-r+1}{n-r} \left((n-r)w_r + \frac{1}{2}(n-r)(w_n - w_r) \right) = \frac{1}{2} (n-r+1) (w_n + w_r), \quad (\text{A.15}) \\ \sum_{i=r}^n \left(\frac{n-i}{n-r} w_r + \frac{i-r}{n-r} w_n \right) \frac{n-i}{n-1} &= \frac{1}{(n-r)(n-1)} \sum_{i=r}^n [(n-i)^2 w_r + (i-r)(n-i) w_n] \\ &= \frac{1}{(n-r)(n-1)} \left[(n^2 w_r - nr w_n) \sum_{i=r}^n 1 + ((n+r)w_n - 2nw_r) \sum_{i=r}^n i + (w_r - w_n) \sum_{i=r}^n i^2 \right] \\ &= \frac{1}{(n-r)(n-1)} \left[(n^2 w_r - nr w_n)(n-r+1) + ((n+r)w_n - 2nw_r) \frac{(n+r)(n-r+1)}{2} + \right. \\ &\quad \left. + (w_r - w_n) \frac{1}{6} (n-r+1) (2n^2 + n + 2r^2 - r + 2nr) \right] \\ &= \frac{(n-r+1)}{6(n-1)} [w_r (2(n-r) + 1) + w_n (n-r-1)]. \quad (\text{A.16}) \end{aligned}$$

Substituint a (A.14):

$$\begin{aligned}\frac{\partial L}{\partial \lambda_2} = 0 &\Rightarrow \sum_{i=1}^n w_i - 1 = 0 \Rightarrow \sum_{i=r}^n \left(w_r + \frac{i-r}{n-r} (w_n - w_r) \right) = 1 \\ &\Rightarrow \frac{1}{2} (n-r+1) (w_n + w_r) = 1 \Rightarrow w_n = \frac{2}{n-r+1} - w_r,\end{aligned}\quad (\text{A.17})$$

Substituint a (A.13):

$$\begin{aligned}\frac{\partial L}{\partial \lambda_1} = 0 &\Rightarrow \sum_{i=1}^n w_i \frac{n-i}{n-1} - \alpha = 0 \Rightarrow \sum_{i=r}^n \left(\frac{n-i}{n-r} w_r + \frac{i-r}{n-r} w_n \right) \frac{n-i}{n-1} = \alpha \\ &\Rightarrow \frac{(n-r+1)}{6(n-1)} [w_r(2(n-r)+1) + w_n(n-r-1)] = \alpha \\ &\Rightarrow \frac{(n-r+1)}{6(n-1)} \left[w_r(2(n-r)+1) + \left(\frac{2}{n-r+1} - w_r \right) (n-r-1) \right] = \alpha \\ &\Rightarrow \frac{(n-r+1)}{6(n-1)} \left[w_r(n-r+2) + \frac{2}{n-r+1} (n-r-1) \right] = \alpha \\ &\Rightarrow w_r = \frac{6(n-1)\alpha - 2(n-r-1)}{(n-r+1)(n-r+2)},\end{aligned}\quad (\text{A.18})$$

i

$$\begin{aligned}w_n &= \frac{2}{n-r+1} - w_r = \frac{2}{n-r+1} - \frac{6(n-1)\alpha - 2(n-r-1)}{(n-r+1)(n-r+2)} \\ &= \frac{2(2n-2r+1) - 6(n-1)\alpha}{(n-r+1)(n-r+2)}.\end{aligned}\quad (\text{A.19})$$

De moment ja s'han obtingut totes les expressions enunciades. Es pretén ara provar les desigualtats.

Els resultats als quals s'ha arribat són factibles quan $w_r \in (0, 1]$ per $r = 2, \dots, n-1$ i $w_n \in (0, 1)$, o quan $w_1 \in (0, 1)$ per $r = 1$ i $w_n \in (0, 1)$, fets que donen peu a trobar els límits d' α en cada cas:

- $w_r \in (0, 1]$ per $r = 2, \dots, n-1$ i $w_n \in (0, 1)$:

$$\begin{aligned}w_r \in (0, 1] &\Rightarrow 0 < \frac{6(n-1)\alpha - 2(n-r-1)}{(n-r+1)(n-r+2)} \leq 1 \\ &\Rightarrow \frac{n-r-1}{3(n-1)} < \alpha \leq \frac{(n-r)^2 + 5(n-r)}{6(n-1)}, \\ w_n \in (0, 1) &\Rightarrow 0 < \frac{2(2n-2r+1) - 6(n-1)\alpha}{(n-r+1)(n-r+2)} < 1 \\ &\Rightarrow \frac{2n-2r+1}{3(n-1)} > \alpha > -\frac{(n-r)(n-r+1)}{6(n-1)}.\end{aligned}\quad (\text{A.20})$$

$$\text{Com } \frac{n-r-1}{3(n-1)} > -\frac{(n-r)(n-r+1)}{6(n-1)}, \quad \text{i } \frac{(n-r)^2 + 5(n-r)}{6(n-1)} \geq \frac{2n-2r+1}{3(n-1)},$$

$$\alpha \in \left(\frac{n-r-1}{3(n-1)}, \frac{2n-2r+1}{3(n-1)} \right).$$

- $w_1 \in (0, 1)$ per $r = 1$ i $w_n \in (0, 1)$:

$$\begin{aligned}
w_1 \in (0, 1) &\Rightarrow 0 < \frac{6(n-1)\alpha - 2(n-2)}{n(n+1)} < 1 \\
&\Rightarrow \frac{n-2}{3(n-1)} < \alpha < \frac{2(n-2) + n(n+1)}{6(n-1)}, \\
w_n \in (0, 1) &\Rightarrow 0 < \frac{2(2n-1) - 6(n-1)\alpha}{n(n+1)} < 1 \\
&\Rightarrow \frac{2n-1}{3(n-1)} > \alpha > \frac{2(2n-1) - n(n+1)}{6(n-1)}. \tag{A.21}
\end{aligned}$$

$$\begin{aligned}
\text{Com } \frac{n-2}{3(n-1)} &\geq \frac{2(2n-1) - n(n+1)}{6(n-1)}, \quad \text{i} \quad \frac{2(n-2) + n(n+1)}{6(n-1)} \geq \frac{2n-1}{3(n-1)}, \\
\alpha &\in \left(\frac{n-2}{3(n-1)}, \frac{2n-1}{3(n-1)} \right).
\end{aligned}$$

A partir d'aquests llindars d' α , es troben els de r :

$$\begin{cases} \frac{n-r-1}{3(n-1)} < \alpha & \Rightarrow r > (n-1) - 3(n-1)\alpha, \\ \frac{2n-2r+1}{3(n-1)} > \alpha & \Rightarrow r < (n-1) - 3(n-1)\alpha + \frac{3}{2}(n-1)\alpha + \frac{3}{2}. \end{cases}$$

Es pot comprovar així que, per ser r natural i donat un valor de l'orness α , es podrien obtenir dos possibles valors per r . Per tal d'obtenir-ne només un, es defineix la següent partició disjunta per α ,

$$\alpha \in \left(0, \frac{1}{2}\right) \subset \bigcup_{r=2}^{n-1} J_{r,n} \cup J_{1,n} \text{ on } \begin{cases} J_{r,n} = \left(\frac{n-r-1}{3(n-1)}, \frac{n-r}{3(n-1)} \right), & r = 2, \dots, n, \\ J_{1,n} = \left(\frac{n-2}{3(n-1)}, \frac{2n-1}{3(n-1)} \right), & r = 1, \end{cases}$$

i es comprova que, en efecte, és solució del problema sota estudi, de tal manera que es podria trobar el valor de r en funció d' α a partir de les desigualtats

$$(n-1) - 3(n-1)\alpha < r \leq n - 3(n-1)\alpha.$$

Amb l'ajuda del contingut de [36], es prova que per $\alpha \in \left(0, \frac{1}{2}\right)$ i $1 < r < n$, el vector trobat $\mathbf{w}^* = (0, \dots, 0, w_r^*, \dots, w_n^*)$ amb

$$w_j^* = 0, \quad j < r, \tag{A.22}$$

$$w_r^* = \frac{6(n-1)\alpha - 2(n-r-1)}{(n-r+1)(n-r+2)}, \tag{A.23}$$

$$w_n^* = \frac{2(2n-2r+1) - 6(n-1)\alpha}{(n-r+1)(n-r+2)}, \tag{A.24}$$

i

$$w_j^* = w_r^* + \frac{j-r}{n-r}(w_n^* - w_r^*), \quad r < j < n, \tag{A.25}$$

on

$$\alpha \in \left(0, \frac{1}{2}\right) \subset \bigcup_{r=2}^{n-1} J_{r,n} \cup J_{1,n} \text{ on } \begin{cases} J_{r,n} = \left(\frac{n-r-1}{3(n-1)}, \frac{n-r}{3(n-1)}\right) & , r = 2, \dots, n, \\ J_{1,n} = \left(\frac{n-2}{3(n-1)}, \frac{2n-1}{3(n-1)}\right) & , r = 1, \end{cases}$$

és solució del problema d'optimització

$$\begin{aligned} \min \quad & f(\mathbf{w}) = \frac{1}{n} \sum_{i=1}^n w_i^2 - \frac{1}{n^2} \\ \text{subjecte a} \quad & h_1(\mathbf{w}) = \sum_{i=1}^n w_i \frac{n-i}{n-1} - \alpha = 0, \\ & h_2(\mathbf{w}) = \sum_{i=1}^n w_i - 1 = 0, \\ & g_i(\mathbf{w}) = -w_i \leq 0, \quad i = 1, \dots, n. \end{aligned} \tag{A.26}$$

Cal provar que $\mathbf{w}^*$ satisfà les condicions suficients de segon ordre de KKT per a l'optimització, això és, els punts següents:

i) $\exists \lambda_1^*, \lambda_2^* \in \mathbb{R}, \mu_1^*, \dots, \mu_n^* \geq 0$ tals que

- $\mu^* \geq \mathbf{0}$,
- $Df(\mathbf{w}^*) + \lambda^{*T} D\mathbf{h}(\mathbf{w}^*) + \mu^{*T} D\mathbf{g}(\mathbf{w}^*) = \mathbf{0}^T$,
- $\mu^{*T} \mathbf{g}^*(\mathbf{w}^*) = \mathbf{0}$.

ii) $\mathbf{w}^* \in \mathbb{R}^n$ és un punt factible.

iii) $\forall \mathbf{y} \in \tilde{T}(\mathbf{w}^*, \mu^*)$ amb $\mathbf{y} \neq \mathbf{0}$ es satisfà $\mathbf{y}^T \mathbf{L}(\mathbf{w}^*, \lambda^*, \mu^*) \mathbf{y} > \mathbf{0}$, on

$$\tilde{T}(\mathbf{w}^*, \mu^*) = \{ \mathbf{y} : D\mathbf{h}(\mathbf{w}^*)\mathbf{y} = \mathbf{0}, Dg_i(\mathbf{w}^*)\mathbf{y} = 0, i \in \tilde{J}(\mathbf{w}^*, \mu^*) \}$$

$$\text{amb } \tilde{J}(\mathbf{w}^*, \mu^*) = \{ i : g_i(\mathbf{w}^*) = 0, \mu_i^* > 0 \}.$$

Es prova, doncs, cada punt:

i) Ja s'ha vist abans que

$$\begin{aligned} \text{per } j = n, \quad & \lambda_2^* = -\frac{2}{n} w_n^* \in \mathbb{R}, \\ \text{per } j = r, \quad & \lambda_1^* = \frac{2(n-1)}{n(n-r)} (w_n^* - w_r^*) \in \mathbb{R}. \end{aligned}$$

Sabent que $Df(\mathbf{w}^*) + \lambda^{*T} D\mathbf{h}(\mathbf{w}^*) + \mu^{*T} D\mathbf{g}(\mathbf{w}^*) = \mathbf{0}^T$, és a dir, que

$$\frac{2}{n} w_k^* + \lambda_1^* \frac{n-k}{n-1} + \lambda_2^* - \mu_k^* = 0, \quad k = 1, \dots, n,$$

s'estudien els valors de μ^* :

- Si $k = r + 1, \dots, n - 1$:

$$\begin{aligned}\mu_k^* &= \frac{2}{n} w_k^* + \lambda_1^* \frac{n-k}{n-1} + \lambda_2^* \\ &= \frac{2}{n} \left(w_r^* + \frac{k-r}{n-r} (w_n^* - w_r^*) \right) + \frac{n-k}{n-1} \cdot \frac{2(n-1)}{n(n-r)} (w_n^* - w_r^*) - \frac{2}{n} w_n^* \\ &= 0.\end{aligned}\tag{A.27}$$

- Si $k = r$:

$$\mu_r^* = \frac{2}{n} w_r^* + \lambda_1^* \frac{n-r}{n-1} + \lambda_2^* = \frac{2}{n} w_r^* + \frac{2}{n} (w_n^* - w_r^*) - \frac{2}{n} w_n^* = 0.$$

- Si $k = n$:

$$\mu_n^* = \frac{2}{n} w_n^* + \lambda_1^* \frac{n-n}{n-1} + \lambda_2^* = \frac{2}{n} w_n^* - \frac{2}{n} w_n^* = 0.$$

Per tant, $\mu_k^* = 0$ i $\mu_k^* g_k(\mathbf{w}^*) = 0$ per $k = r, \dots, n$. Falta veure què passa per $k = 1, \dots, r - 1$ amb $r > 1$, on ja s'havia vist que $w_k^* = 0$, i per tant $\mu_k^* g_k(\mathbf{w}^*) = 0$:

$$\begin{aligned}\mu_k^* &= \frac{2}{n} w_k^* + \lambda_1^* \frac{n-k}{n-1} + \lambda_2^* \\ &= \frac{n-k}{n-1} \cdot \frac{2(n-1)}{n(n-r)} (w_n^* - w_r^*) - \frac{2}{n} w_n^* \\ &= \frac{2}{n(n-r)} ((r-k) w_n^* - (n-k) w_r^*).\end{aligned}\tag{A.28}$$

Es vol provar que $\mu_k^* \geq 0$, és a dir, que

$$\begin{aligned}(r-k) w_n^* - (n-k) w_r^* &\geq 0 \\ (r-k) \frac{2(2n-2r+1) - 6(n-1)\alpha}{(n-r+1)(n-r+2)} - (n-k) \frac{6(n-1)\alpha - 2(n-r-1)}{(n-r+1)(n-r+2)} &\geq 0 \\ \alpha &\leq \frac{(r-k)(2n-2r+1) + (n-k)(n-r-1)}{3(n-1)(n+r-2k)},\end{aligned}$$

que és cert per la hipòtesi $\alpha \in J_{r,n} = \left[\frac{n-r-1}{3(n-1)}, \frac{n-r}{3(n-1)} \right]$ i perquè

$$\frac{(r-k)(2n-2r+1) + (n-k)(n-r-1)}{3(n-1)(n+r-2k)} \geq \frac{n-r}{3(n-1)}.$$

Per tant, en efecte, $\mu_1^*, \dots, \mu_n^* \geq 0$.

- ii) Per provar que $\mathbf{w}^*$ és un punt factible, cal provar que els vectors $\nabla h_i(\mathbf{w}^*)$, $\nabla g_j(\mathbf{w}^*)$ amb $i = 1, 2$ i $j \in J(\mathbf{w}^*) = \{j : g_j(\mathbf{w}^*) = 0\} = \{1, \dots, r-1\}$ són linealment independents. Siguin doncs

$$\begin{aligned}\nabla h_1(\mathbf{w}^*) &= \left(\frac{n-1}{n-1}, \frac{n-2}{n-1}, \dots, \frac{1}{n-1}, 0 \right), \\ \nabla h_2(\mathbf{w}^*) &= (1, \dots, 1), \\ \nabla g_1(\mathbf{w}^*) &= (-1, 0, \dots, 0), \\ \nabla g_2(\mathbf{w}^*) &= (0, -1, 0, \dots, 0), \\ &\vdots \\ \nabla g_{r-1}(\mathbf{w}^*) &= (0, \dots, 0, \overbrace{-1}^{(r-1)}, 0, \dots, 0),\end{aligned}$$

es considera la matriu $M = [\nabla h_1^T, \nabla h_2^T, \nabla g_1^T, \dots, \nabla g_{r-1}^T] \in \mathbb{R}^{n \times (r+1)}$ i es calcula el determinant de la submatriu quadrada $(r+1) \times (r+1)$:

$$\begin{vmatrix} 1 & 1 & -1 & 0 & \dots & 0 \\ \frac{n-2}{n-1} & 1 & 0 & -1 & \dots & 0 \\ \frac{n-3}{n-1} & 1 & 0 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ \frac{n-(r-1)}{n-1} & 1 & 0 & 0 & \dots & -1 \\ \frac{n-r}{n-1} & 1 & 0 & 0 & \dots & 0 \\ \frac{n-(r+1)}{n-1} & 1 & 0 & 0 & \dots & 0 \end{vmatrix} = (-1)^{r-1} \begin{vmatrix} \frac{n-r}{n-1} & 1 \\ \frac{n-(r+1)}{n-1} & 1 \end{vmatrix} = \frac{(-1)^{r-1}}{n-1} \neq 0,$$

i queda demostrat que $\mathbf{w}^*$ és un punt factible.

iii) Finalment es vol provar que $\mathbf{y}^T \mathbf{L}(\mathbf{w}^*, \lambda^*, \mu^*) \mathbf{y} > \mathbf{0}$, que és el mateix que provar que la matriu hessiana és definida positiva a $\tilde{T}(\mathbf{w}^*, \mu^*)$:

$$\begin{aligned} \mathbf{L}(\mathbf{w}^*, \lambda^*, \mu^*) &= \mathbf{F}(\mathbf{w}^*) + \lambda_1^* \mathbf{H}_1(\mathbf{w}^*) + \lambda_2^* \mathbf{H}_2(\mathbf{w}^*) + \sum_{j=1}^n \mu_j^* \mathbf{G}_j(\mathbf{w}^*) = \\ &= \begin{pmatrix} \frac{2}{n} & 0 & \dots & 0 \\ 0 & \frac{2}{n} & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \frac{2}{n} \end{pmatrix} + \lambda_1^*(0) + \lambda_2^*(0) + \sum_{j=1}^n \mu_j^*(0) = \\ &= \frac{2}{n} \begin{pmatrix} 1 & 0 & \dots & 0 \\ 0 & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 1 \end{pmatrix}. \end{aligned}$$

Demostrades les hipòtesis, pel teorema SOSC per a problemes amb inequacions a les restriccions, queda provat que $\mathbf{w}^*$, així com s'ha definit, és en efecte un mínim local del problema plantejat. De fet, per ser el domini $[0, 1]^n$ i la funció a optimitzar convexos (la hessiana de la funció és semidefinida positiva), aquest mínim és global, concloent així la demostració. $\square$

Taula A.1: Taula completa de llindars òptims obtinguts amb el mètode de la corba ROC, on s'indica a cada fila el mètode de segmentació que aplica el llindar amb valor indicat, i el quocient $\mu_m(FPR/TPR)$ per al qual ha resultat ser l'òptim.

mètode	llindar	valor	$\mu_m(FPR/TPR)$
Segm2005Zapater	th_1	0,41	0,305454422
Segm2005Zapater	th_2	0,45	0,41791269
Segm2005Zapater	th_3	0,41	0,377421927
Segm2005Zapater	th_4	0,42	0,313155431
Segm2005Zapater	th_5	0,42745098	0,312083872
Segm2005Zapater	th_6	0,44	0,311980812
Segm2005Zapater	th_7	0,43	0,3016472
Segm2005Zapater	th_8	0,43	0,347948553
Segm2005Zapater	th_9	0,44	0,198522786
Segm2005Zapater	th_{10}	0,458823529	0,31047212
Segm2005Zapater	th_{11}	0,44	0,282830384
Segm2005Zapater	th_{12}	0,48627451	0,327528653
Segm2005Zapater	th_{13}	0,45	0,347315378
Segm2005Zapater	th_{14}	0,47	0,424422001
Segm2005Zapater	th_{15}	0,46	0,409654434
Segm2005Zapater	th_{16}	0,46	0,477545765
Segm2005Zapater	th_{17}	0,45	0,485130153
Segm2005Zapater	th_{18}	0,46	0,554516595
Segm2005Zapater	th_{19}	0,505882353	0,432354157
Segm2005Zapater	th_{20}	0,494117647	0,595863314
Segm2005Zapater	th_{21}	0,505882353	0,582025966
Segm2005Zapater	T	0,55	0,182799773
Segm2015Azzopardi	th	0,09	0,088227695

Taula A.2: Taula completa de paràmetres òptims obtinguts, on s'indica a cada fila el procés de segmentació que inclou el paràmetre amb el valor trobat, i el coeficient $\mu_m(IoU)$ pel qual ha resultat ser l'òptim.

procés	paràmetre	valor	$\mu_m(IoU)$
Segm2001ZanaKlein	k	9	0,398110735
Segm2002Heneghan	M	44	0,42905132
Segm2008SoaresGMM	M	1000000	0,605857636
Segm2008SoaresKNN	M	1000	0,539082664
Segm2008SoaresLMSE	M	1000000	0,44877599
fullAggMEOWA	α	0,4	0,61592853
fullMAggMEOWA	α	0,2	0,60802909
redSAggMEOWA	α	0,3	0,63214487
redSMAggMEOWA	α	0,2	0,63108984
redBGAggMEOWA	α	0,2	0,62125071
redBMGAggMEOWA	α	0,3	0,61297356
fullAggMVOWA	α	0,3	0,61790551
fullMAggMVOWA	α	0,2	0,61285379
redSAggMVOWA	α	0,3	0,63308276
redSMAggMVOWA	α	0,2	0,63108984
redBGAggMVOWA	α	0,1	0,61820327
redBMGAggMVOWA	α	0,4	0,61191948

Taula A.3: Resultats calculats sobre la mesura d'avaluació IoU dels mètodes de segmentació principals: contrast d'igualtat de mitjanes per parelles, on = indica que el mètode de la fila és estadísticament equivalent al de la columna i ≠ indica que són estadísticament diferents. La resta de casos no aplica.

	SCd	SZK	SHg	SCw	SZp	SGM	SKN	SLM	SBk	SAz	SBb
SCd	-	-	-	-	-	-	-	-	-	-	-
SZK	=	-	-	-	-	-	-	-	-	-	-
SHg	=	=	-	-	-	-	-	-	-	-	-
SCw	≠	=	=	-	-	-	-	-	-	-	-
SZp	=	=	=	=	-	-	-	-	-	-	-
SGM	≠	≠	≠	≠	≠	-	-	-	-	-	-
SKN	≠	=	≠	=	=	≠	-	-	-	-	-
SLM	≠	=	=	=	=	≠	≠	-	-	-	-
SBk	≠	≠	≠	≠	≠	=	=	≠	-	-	-
SAz	≠	≠	≠	≠	≠	=	≠	≠	≠	-	-
SBb	≠	≠	≠	≠	≠	≠	=	≠	=	=	-

Taula A.4: Resultats calculats sobre la mesura d'avaluació IoU dels mètodes de segmentació principals: contrast d'igualtat i desigualtat de variàncies per parelles, on = indica que el mètode de la fila és estadísticament equivalent al de la columna, < indica que la variància del mètode de la fila és estadísticament inferior al de la columna, i > indica que la variància del mètode de la fila és estadísticament superior al de la columna. La resta de casos no aplica.

	SCd	SZK	SHg	SCw	SZp	SGM	SKN	SLM	SBk	SAz	SBb
SCd	-	-	-	-	-	-	-	-	-	-	-
SZK	=	-	-	-	-	-	-	-	-	-	-
SHg	<	=	-	-	-	-	-	-	-	-	-
SCw	<	<	<	-	-	-	-	-	-	-	-
SZp	=	=	=	>	-	-	-	-	-	-	-
SGM	<	<	=	=	<	-	-	-	-	-	-
SKN	<	<	=	>	<	=	-	-	-	-	-
SLM	<	<	=	>	<	=	=	-	-	-	-
SBk	<	<	<	=	<	=	<	<	-	-	-
SAz	<	<	<	=	<	<	<	<	=	-	-
SBb	<	<	=	>	<	=	=	=	>	>	-

BIBLIOGRAFIA

- [1] S. Chaudhuri, S. Chatterjee, N. Katz, M. Nelson, and M. Goldbaum, "Detection of blood vessels in retinal images using two-dimensional matched filters," *IEEE Transactions on medical imaging*, vol. 8, no. 3, pp. 263–269, 1989. 1.1, 3.3.1
- [2] Zana and Klein, "A registration algorithm of eye fundus images using a bayesian hough transform," in *Image Processing And Its Applications, 1999. Seventh International Conference on (Conf. Publ. No. 465)*, vol. 2. IET, 1999, pp. 479–483. 1.1
- [3] F. Zana and J.-C. Klein, "Segmentation of vessel-like patterns using mathematical morphology and curvature evaluation," *IEEE transactions on image processing*, vol. 10, no. 7, pp. 1010–1019, 2001. 1.1, 3.3.2
- [4] J. Staal, M. D. Abràmoff, M. Niemeijer, M. A. Viergever, and B. Van Ginneken, "Ridge-based vessel segmentation in color images of the retina," *IEEE transactions on medical imaging*, vol. 23, no. 4, pp. 501–509, 2004. 1.1, 3.1
- [5] M. Y. S. Ali, M. Abdel-Nasser, M. Jabreel, A. Valls, and M. Baget, "Segmenting the optic disc using a deep learning ensemble model based on OWA operators," in *Artificial Intelligence Research and Development*. IOS Press, 2021, pp. 305–314. 1.1, 2.4
- [6] S. Lu, "Accurate and efficient optic disc detection and segmentation by a circular transformation," *IEEE Transactions on medical imaging*, vol. 30, no. 12, pp. 2126–2133, 2011. 1.1
- [7] R. C. Gonzalez, *Digital image processing*. Pearson education india, 2009. 2.1, 2.2
- [8] G. Beliakov, A. Pradera, and T. Calvo, *Aggregation Functions: A Guide for Practitioners*, 1st ed. Springer Berlin, Heidelberg, 2007. 2.3, 2.3
- [9] R. Bellman and M. Giertz, "On the analytic formalism of the theory of fuzzy sets," *Information Sciences*, vol. 5, pp. 149–156, 1973. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/0020025573900091> 2.3
- [10] P. S. Bullen, *Handbook of means and their inequalities*. Springer Science & Business Media, 2013, vol. 560. 2.3
- [11] R. Yager, "On ordered weighted averaging aggregation operators in multicriteria decisionmaking," *IEEE Transactions on Systems, Man, and Cybernetics*, vol. 18, no. 1, pp. 183–190, 1988. 2.3, 2.3, 2.3

- [12] J. J. Dujmović, "Two integrals related to means," *Publikacije Elektrotehničkog fakulteta. Serija Matematika i fizika*, no. 412/460, pp. 232–236, 1973. [Online]. Available: <http://www.jstor.org/stable/43668034> 2.3
- [13] J. J. Dujmović, "Weighted conjunctive and disjunctive means and their application in system evaluation," *Publikacije Elektrotehničkog fakulteta. Serija Matematika i fizika*, pp. 147–158, 1974. 2.3
- [14] B. S. Ahn, "On the properties of owa operator weights functions with constant level of orness," *IEEE Transactions on Fuzzy Systems*, vol. 14, no. 4, pp. 511–515, 2006. 2.3
- [15] R. Fullér and P. Majlender, "An analytic approach for obtaining maximal entropy owa operator weights," *Fuzzy sets and Systems*, vol. 124, no. 1, pp. 53–57, 2001. 2.3
- [16] —, "On obtaining minimal variability OWA operator weights," *Fuzzy sets and systems*, vol. 136, no. 2, pp. 203–215, 2003. 2.3
- [17] R. R. Yager, "Quantifier guided aggregation using OWA operators," *International journal of intelligent systems*, vol. 11, no. 1, pp. 49–73, 1996. 2.3
- [18] —, "Connectives and quantifiers in fuzzy sets," *Fuzzy sets and systems*, vol. 40, no. 1, pp. 39–75, 1991. 2.3
- [19] T. Fawcett, "An introduction to ROC analysis," *Pattern recognition letters*, vol. 27, no. 8, pp. 861–874, 2006. 2.4
- [20] G. Casella and R. Berger, *Statistical inference*. Chapman and Hall/CRC, 2024. 2.5
- [21] M. B. Brown and A. B. Forsythe, "Robust tests for the equality of variances," *Journal of the American Statistical Association*, vol. 69, no. 346, pp. 364–367, 1974. [Online]. Available: <https://www.tandfonline.com/doi/abs/10.1080/01621459.1974.10482955> 2.5
- [22] A. Hoover, V. Kouznetsova, and M. Goldbaum, "Locating blood vessels in retinal images by piecewise threshold probing of a matched filter response," *IEEE Transactions on Medical imaging*, vol. 19, no. 3, pp. 203–210, 2000. 3.1
- [23] C. Heneghan, J. Flynn, M. O’Keefe, and M. Cahill, "Characterization of changes in blood vessel width and tortuosity in retinopathy of prematurity using image analysis," *Medical image analysis*, vol. 6, no. 4, pp. 407–429, 2002. 3.3.3
- [24] T. Chanwimaluang and G. Fan, "An efficient blood vessel detection algorithm for retinal images using local entropy thresholding," in *2003 IEEE International Symposium on Circuits and Systems (ISCAS)*, vol. 5. IEEE, 2003, pp. V–V. 3.3.4
- [25] G. Ayala, T. León, and V. Zapater, "Different averages of a fuzzy set with an application to vessel segmentation," *IEEE Transactions on Fuzzy Systems*, vol. 13, no. 3, pp. 384–393, 2005. 3.3.5

- [26] J. Soares, J. Leandro, R. M. Cesar-Jr, H. Jelinek, and M. J. Cree, "Using the 2-D morlet wavelet with supervised classification for retinal vessel segmentation," in *Brazilian Symposium on Computer Graphics and Image Processing*. IEEE, 2005, p. 10. 3.3.6, 3.3.7, 3.3.8
- [27] P. Bankhead, C. N. Scholfield, J. G. McGeown, and T. M. Curtis, "Fast retinal vessel detection and measurement using wavelets and edge location refinement," *PloS one*, vol. 7, no. 3, p. e32435, 2012. 3.3.9
- [28] G. Azzopardi, N. Strisciuglio, M. Vento, and N. Petkov, "Trainable cosfire filters for vessel delineation with application to retinal images," *Medical image analysis*, vol. 19, no. 1, pp. 46–57, 2015. 3.3.10
- [29] P. Bibiloni, M. González-Hidalgo, and S. Massanet, "A real-time fuzzy morphological algorithm for retinal vessel segmentation," *Journal of real-time image processing*, vol. 16, no. 6, pp. 2337–2350, 2019. 3.3.11, 3.4.3
- [30] J. Canny, "A computational approach to edge detection," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. PAMI-8, no. 6, pp. 679–698, 1986. 3.3.11, 3.4.3
- [31] N. Otsu *et al.*, "A threshold selection method from gray-level histograms," *Automatica*, vol. 11, no. 285-296, pp. 23–27, 1975. 3.4.1
- [32] D. Bradley and G. Roth, "Adaptive thresholding using the integral image," *Journal of graphics tools*, vol. 12, no. 2, pp. 13–21, 2007. 3.4.2
- [33] P. Kovesei *et al.*, "Image features from phase congruency," *Videre: Journal of computer vision research*, vol. 1, no. 3, pp. 1–26, 1999. 3.4.3
- [34] R. Medina-Carnicer, R. Muñoz-Salinas, E. Yeguas-Bolivar, and L. Diaz-Mas, "A novel method to look for the hysteresis thresholds for the canny edge detector," *Pattern Recognition*, vol. 44, no. 6, pp. 1201–1211, 2011. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0031320310005741> 3.4.3
- [35] M. González-Hidalgo, S. Massanet, A. Mir, and D. Ruiz-Aguilera, "Edge image aggregation method using ordered weighted averaging functions," in *2016 IEEE International Conference on Fuzzy Systems (FUZZ-IEEE)*. IEEE, 2016, pp. 1355–1362. 3.4.3
- [36] E. K. Chong and S. H. Žak, *An introduction to optimization*. John Wiley & Sons, 2013, vol. 75. A